

**IDENTIFIKASI *SUPPORT RESISTANCE* PADA
SAHAM SEKTOR ENERGI IDX MENGGUNAKAN
METODE *K-MEANS CLUSTERING* DAN
*BACKTESTING ALGORITMIK***

PROPOSAL SKRIPSI



Oleh :

ARDI FAJAR MAULANA

15-2022-165

**PROGRAM STUDI INFORMATIKA
FAKULTAS TEKNOLOGI INDUSTRI
INSTITUT TEKNOLOGI NASIONAL
BANDUNG
2025**

**Identifikasi *Support Resistance* Pada Saham Sektor
Energi IDX Menggunakan Metode *K-Means Clustering*
dan *Backtesting Algoritmik***

PROPOSAL SKRIPSI

**Diajukan Sebagai Salah Satu Syarat untuk Memperoleh Gelar
Sarjana**



Oleh :

ARDI FAJAR MAULANA

15-2022-165

**PROGRAM STUDI INFORMATIKA
FAKULTAS TEKNOLOGI INDUSTRI
INSTITUT TEKNOLOGI NASIONAL
BANDUNG
2025**

KATA PENGANTAR

Puji syukur kehadiran Tuhan Yang Maha Esa atas segala rahmat dan karunia-Nya, sehingga penulis berhasil menyelesaikan penyusunan proposal skripsi ini. Penulisan proposal skripsi ini disusun sebagai salah satu syarat untuk memperoleh Gelar Sarjana Komputer pada Program Studi Informatika Fakultas Teknologi Industri Institut Teknologi Nasional Bandung. Penyelesaian proposal skripsi ini tidak terlepas dari dukungan dan bimbingan dari berbagai pihak. Oleh karena itu, penulis mengucapkan terima kasih yang sebesar-besarnya kepada:

- (1) Kedua orang tua dan keluarga penulis yang senantiasa memberikan doa, dukungan moral, motivasi, serta kasih sayang yang tak ternilai selama proses perkuliahan hingga penyusunan proposal skripsi ini;
- (2) Ibu Marisa Premitasari, S.T., M.T. selaku dosen pembimbing skripsi yang telah meluangkan waktu, tenaga, dan pikiran untuk memberikan bimbingan, arahan, serta masukan yang sangat berharga kepada penulis selama proses penyusunan proposal skripsi ini.;
- (3) Seluruh dosen Program Studi Informatika Institut Teknologi Nasional Bandung yang telah memberikan ilmu pengetahuan, wawasan, serta pengalaman selama penulis menempuh pendidikan;
- (4) Seluruh mahasiswa Program Studi Informatika Institut Teknologi Nasional Bandung angkatan 2022 yang telah menjadi rekan belajar, berdiskusi, dan saling memberikan dukungan selama masa perkuliahan.

Penulis menyadari bahwa proposal skripsi ini masih jauh dari kata sempurna. Oleh karena itu, kritik dan saran yang membangun sangat penulis harapkan demi perbaikan di masa mendatang. Akhir kata, semoga hasil penelitian ini dapat memberikan kontribusi yang berarti bagi pengembangan ilmu pengetahuan, khususnya di bidang analisis keuangan komputasi dan investasi.

Bandung, 12 Oktober 2025

Ardi Fajar Maulana

DAFTAR ISI

	Halaman
KATA PENGANTAR.....	i
DAFTAR ISI.....	ii
DAFTAR GAMBAR.....	iv
DAFTAR TABEL	v
BAB I PENDAHULUAN.....	1
1.1. Latar Belakang.....	1
1.2. Rumusan Masalah.....	4
1.3. Tujuan	4
1.4. Ruang Lingkup	5
1.5. Metode Penelitian	5
1.6. Kontribusi Penelitian	6
1.7. Sistematika Penulisan	7
BAB II TINJAUAN PUSTAKA.....	9
2.1. Roadmap	9
2.2. Kajian Literatur.....	10
2.3. Pasar Modal dan Bursa Efek Indonesia	15
2.3.1. Pasar Modal	15
2.3.2. Struktur dan Mekanisme Bursa Efek Indonesia.....	16
2.3.3. Karakteristik Perdagangan Saham di Indonesia	17
2.4. Sektor Energi di Bursa Efek Indonesia.....	17
2.4.1. Profil dan Klasifikasi Sektor Energi IDX	18
2.4.2. Volatilitas dan Dinamika Harga Saham Sektor Energi..	19
2.4.3. Faktor yang Mempengaruhi Pergerakan Harga Saham Energi	19
2.5. Analisis Teknikal pada Pasar Modal	20
2.5.1. Konsep dan Prinsip Dasar Analisis Teknikal.....	21
2.5.2. Teori Support dan Resistance	22
2.5.3. Pivot Points dan Metode Identifikasi Konvensional.....	23

2.5.4. Keterbatasan Metode Konvensional dalam Identifikasi S/R	24
2.6. Machine Learning untuk Analisis Pasar Modal.....	25
2.6.1. Supervised Learning dan Unsupervised Learning	26
2.6.2. K-Means Clustering	27
2.6.3. Penerapan Clustering dalam Analisis Finansial.....	28
2.7. Perprocessing Data dan Featur Engineering.....	29
2.7.1. Data Harga Historis Saham (Open High Low Close)	30
2.7.2. Feature Scaling dan Standarisasi	30
2.7.3. Z-Score Standardization.....	31
2.7.4. Normalisasi dalam K-Means Clustering.....	33
2.8. Backtesting Algoritmik.....	34
2.8.1. Metodologi Backtesting Strategi Trading.....	34
2.8.2. Metrik Evaluasi Performa Trading	35
2.8.3. Validasi Out-of-Sampe Testing	38
BAB III METODOLOGI PENELITIAN	39
3.1. Desain Penelitian.....	39
3.2. Data Penelitian	43
3.2.1. Sumber dan Jenis Data	44
3.2.2. Sampel Data	44
3.3. Prosedur Penelitian	45
3.3.1. Data Splitting	46
3.3.2. Deteksi Pivot Point	47
3.3.3. Filtering.....	48
3.3.4. Standarisasi Data.....	49
3.3.5. K-Means Clustering.....	50
3.3.6. Zone Scoring.....	51
3.4. Evaluasi Model.....	52
3.4.1. Backtesting Algorithmic	52
3.4.2. Metrik Evaluasi Performa	53
DAFTAR PUSTAKA	55

DAFTAR GAMBAR

	Halaman
Gambar 2.1.1. Roadmap Penelitian.....	9
Gambar 2.3.2.1. Struktur Pasar Modal (IDX, 2020).....	16
Gambar 2.5.2.1. Support dan Resistance Tradisional (BrokerForex, 2018).....	22
Gambar 2.5.3.1. Visualisasi Classical Pivot Points (Truedata, 2025).....	23
Gambar 2.6.2.1. K-Means Clustering (DQLab, 2022).....	27
Gambar 2.7.3.1. Data Sebelum dan Sesudah Z-Score Normalization (Neri Van Otten, 2025)	32
Gambar 2.7.4.1. Dampak Skala pada K-Means With vs Without Normalization	33
Gambar 2.8.2.1. Risk-Reward Ratio 1:1, 1:2, 1:3	36
Gambar 3.1.1. Kerangka Penelitian	40
Gambar 3.2.1.1. Alur Pengambilan Data	44
Gambar 3.2.2.1. Sampel Data	45
Gambar 3.3.2.1. Alur Deteksi Pivot Point	47
Gambar 3.3.3.1. Alur Filtering	48
Gambar 3.3.4.1. Alur Standarisasi Data.....	49
Gambar 3.3.5.1. Alur K-Means Clustering.....	50
Gambar 3.3.6.1. Alur Scoring Zona	51

DAFTAR TABEL

	Halaman
Tabel 2.1 Kajian Literatur	10

BAB I

PENDAHULUAN

1.1. Latar Belakang

Pasar modal, khususnya di negara berkembang, menghadirkan peluang keuntungan yang signifikan sekaligus risiko yang substansial. Sektor energi di Indonesia, yang mencakup minyak, gas, dan batu bara, merupakan salah satu pilar utama di Bursa Efek Indonesia (IDX) namun juga terkenal dengan tingkat volatilitasnya yang ekstrem. Fluktuasi harga di sektor ini sering kali dipengaruhi oleh determinan makroekonomi global, sentimen pasar, dan perubahan kebijakan (Asma Awan *et al.*, 2023). Data historis menunjukkan bahwa sektor ini mengalami fluktuasi yang signifikan, seperti yang terlihat pada tren penurunan substansial sepanjang Januari hingga Agustus 2021 (Tyas, 2025). Volatilitas yang tinggi ini menciptakan lingkungan perdagangan yang menantang, di mana investor dan trader memerlukan alat analisis yang presisi untuk mengidentifikasi titik masuk (*entry*) dan keluar (*exit*) pasar serta mengelola risiko secara efektif.

Selain faktor makroekonomi global, ketidakpastian politik juga menjadi salah satu pendorong utama volatilitas pasar saham, khususnya di negara berkembang. Penelitian menunjukkan bahwa ketidakpastian politik dan peristiwa politik besar seperti pemilu, konflik internal, maupun perubahan rezim kebijakan cenderung meningkatkan volatilitas pasar dan memperbesar premi risiko yang diminta investor (Ahir *et al.*, 2020; Souffargi, 2024). Dalam konteks Indonesia, risiko politik dan geopolitik yang bersumber dari dinamika kebijakan pemerintah, konflik kepentingan di sektor energi, serta keterlibatan aktor politik dalam perusahaan energi dapat memperkuat ketidakpastian dan menekan kinerja pasar modal (Prihandono, 2023; Saputra, 2023). Kondisi ini menyebabkan level support dan resistance yang terbentuk secara historis dapat mengalami pergeseran drastis ketika terjadi shock politik, sehingga diperlukan pendekatan identifikasi zona harga yang objektif, adaptif terhadap perubahan rezim pasar, dan teruji secara kuantitatif

melalui data harga historis yang sudah menginternalisasi dampak faktor politik tersebut.

Secara historis, level *support* (batas bawah) dan *resistance* (batas atas) atau *S/R* telah menjadi alat utama dalam analisis teknikal untuk mengelola risiko dan mengidentifikasi peluang pasar (Öztürk, 2024; TDS Editorial, 2021). Namun, metode tradisional dalam menentukan level *S/R* umumnya masih bergantung pada pengamatan visual dan penarikan garis secara manual pada grafik harga (TDS Editorial, 2021). Pendekatan konvensional ini memiliki kelemahan mendasar karena sifatnya yang sangat subjektif dan mudah dipengaruhi oleh kesalahan manusia (*human error*) (TDS Editorial, 2021). Apa yang dianggap oleh satu analis sebagai level *support* yang kuat, bisa jadi diabaikan oleh analis lainnya. Sementara itu, *pivot points* tradisional yang cenderung lebih objektif tetap memiliki keterbatasan, sebab daya prediktifnya rendah dan tidak efektif ketika diterapkan di pasar dengan tingkat volatilitas tinggi seperti sektor energi. Akibatnya, subjektivitas dan keterbatasan efektivitas metode konvensional tersebut menimbulkan masalah berupa inkonsistensi serta rendahnya keandalan dalam proses pengambilan keputusan perdagangan

Untuk mengatasi masalah subjektivitas, telah terjadi pergeseran menuju pendekatan komputasional dan kuantitatif. *Machine learning*, khususnya algoritma *unsupervised learning*, menawarkan solusi yang kuat. Algoritma *K-Means clustering* telah diidentifikasi sebagai alat yang ampuh untuk tugas ini, sebagaimana divalidasi oleh penelitian seperti yang dilakukan oleh Öztürk (2024). *K-Means* dapat menganalisis data harga historis dalam jumlah besar dan secara otomatis serta objektif mengelompokkan (*meng-cluster*) titik-titik harga di mana telah terjadi konsentrasi aksi harga (pembalikan) yang signifikan. Dengan demikian, *K-Means* mengubah identifikasi *S/R* dari “seni” menggambar garis subjektif menjadi “sains” pengelompokan data yang objektif. Penggunaan data historis selama enam tahun dalam penelitian ini juga sejalan dengan metodologi yang digunakan oleh Öztürk (2024), yang memberikan preseden akademis yang kuat untuk periode analisis data.

Meskipun demikian, penerapan *K-Means* hanya mendeteksi *pivot points* dan langsung mengelompokkannya (pendekatan dua tahap) kesenjangan penelitian (*research gap*) yang fatal. *K-Means* adalah algoritma berbasis jarak (*Euclidean*) dan sangat sensitif terhadap skala fitur. Dalam dataset harga enam tahun, harga dari tahun 2018 (misalnya Rp 1.000) dan harga dari tahun 2024 (misalnya Rp 4.000) memiliki skala yang sangat berbeda. Tanpa normalisasi, algoritma akan secara keliru menganggap harga Rp 4.000 lebih penting dan mengabaikan level Rp 1.000, meskipun level tersebut mungkin telah diuji berkali-kali dan secara statistik lebih kuat. Temuan oleh *Wongoutong (2024)* secara empiris membuktikan hal ini; untuk dataset dengan fitur yang memiliki “unit yang berbeda” (*different units*), mengabaikan penskalaan fitur (seperti standarisasi *Z-score*) secara signifikan “memperburuk akurasi, presisi, dan *recall*” dibandingkan dengan penggunaan data yang telah diskalakan. *Wongoutong (2024)* secara spesifik menemukan bahwa standarisasi *Z-score* (Tahap 3 dalam model ini) memberikan kinerja yang “superior”. Kesenjangan ini diperparah dengan kegagalan untuk memfilter *pivot* yang tidak relevan (*Dhakal, 2024*) dan kegagalan mengonversi centroid *K-Means* (titik tunggal) menjadi “zona” harga, yang merupakan representasi *S/R* yang lebih realistis secara fundamental di pasar.

Penelitian ini mengusulkan solusi untuk mengisi kesenjangan tersebut melalui metodologi hibrida enam tahap yang metodologis dan tervalidasi secara statistik. Model yang diusulkan secara sistematis: (1) mendeteksi *pivot points*, (2) memfilter *pivot* yang relevan secara kontekstual (di bawah harga saat ini untuk *support*, di atas untuk *resistance*), (3) melakukan standarisasi *Z-score* untuk menghilangkan bias skala (*Wongoutong, 2024*), (4) mengelompokkan *pivot* yang telah dinormalisasi secara objektif menggunakan *K-Means* (*Öztürk, 2024*), (5) mengonversi *cluster centroid* menjadi “zona” harga (*min-max cluster*), dan (6) memberi skor pada zona berdasarkan kekuatan (jumlah sentuhan) dan kedekatan. Proses ini menghasilkan level *S/R* yang tidak hanya objektif tetapi juga valid secara statistik dan relevan secara kontekstual, yang kemudian menjadi data primer penelitian ini. Untuk melengkapi siklus penelitian, efektivitas dari zona *S/R* yang

dihasilkan ini akan diuji secara empiris menggunakan *algorithmic backtesting*, sebuah metode standar untuk menguji strategi pada data historis (Letteri et al., 2023). *Backtest* ini akan mengukur “ketahanan” (*robustness*) dari level yang dihasilkan *machine learning* di berbagai kondisi pasar (Dhakal, 2024), memberikan validasi kuantitatif atas efektivitas model pada studi kasus saham sektor energi IDX.

1.2. Rumusan Masalah

Saham sektor energi di Bursa Efek Indonesia (BEI) ditandai oleh volatilitas tinggi akibat sensitivitas terhadap faktor global seperti fluktuasi nilai tukar rupiah dan suku bunga acuan (Dewi & Nikmah, 2025; Kusmini & Wibowo, 2025), dengan dampak signifikan dari guncangan harga minyak dunia jangka pendek (+1,22, $p < 0,01$) (Tri Wahyudi et al., 2025). Penentuan level Support dan Resistance (S&R) menjadi penting untuk manajemen risiko efektif (Enow, 2023), namun metode tradisional yang mengandalkan interpretasi visual pivot points bersifat subjektif dan mengandung bias behavioral tinggi (Ozturk, 2023; Ghanem, 2024), serta gagal menangkap kepadatan statistik harga yang sesungguhnya (Akhtar & Raza, 2024).

1. Bagaimana algoritma hibrida enam tahap (Pivot Points, Filtering, Z-score, K-Means, Penentuan Zona, dan Scoring) dapat menentukan zona Support dan Resistance pada saham sektor energi di BEI berdasarkan data harga 6 tahun terakhir?
2. Seberapa efektif zona Support dan Resistance hasil K-Means dalam memprediksi pembalikan atau penahanan harga berdasarkan hasil backtesting saham sektor energi di BEI?
3. Bagaimana ketahanan (*robustness*) zona Support dan Resistance yang dihasilkan model hibrida pada periode ketidakpastian politik domestik yang tinggi ?

1.3. Tujuan

Penelitian ini bertujuan untuk mengembangkan model hibrida enam tahap berbasis algoritma *K-Means clustering* dalam mengidentifikasi zona *support* dan

resistance pada saham sektor energi di Bursa Efek Indonesia. Model hibrida enam tahap yang dirancang mencakup tahapan deteksi *pivot points*, *filtering* kontekstual, standarisasi *Z-score*, *clustering K-Means*, konversi zona harga, serta pemberian skor berbasis kekuatan, guna menghasilkan level *support* dan *resistance* yang objektif serta valid secara statistik berdasarkan data historis enam tahun terakhir. Melalui proses *algorithmic backtesting*, penelitian ini akan menilai efektivitas zona tersebut dalam memprediksi pembalikan maupun penahanan harga dengan mengukur metrik kinerja seperti akurasi prediksi, *win rate*, akurasi prediksi pembalikan harga, dan *risk-reward ratio*, sehingga diharapkan dapat menghasilkan alat analisis yang lebih presisi dan andal bagi para investor.

1.4. Ruang Lingkup

1. Penelitian difokuskan pada saham sektor energi (minyak, gas, dan batu bara) yang terdaftar di Bursa Efek Indonesia (BEI).
2. Data harga historis yang digunakan adalah data 6 tahun terakhir (*daily timeframe*) untuk setiap saham yang dianalisis.
3. Model hibrida yang dikembangkan terdiri dari enam tahap: *Pivot Points Detection*, *Contextual Filtering*, *Z-score Standardization*, *K-Means Clustering*, *Price Zone Conversion*, dan *Zone Scoring*.
4. Implementasi algoritma menggunakan bahasa pemrograman Python.
5. Evaluasi efektivitas menggunakan *algorithmic backtesting* dengan metrik kinerja meliputi *win rate*, akurasi prediksi pembalikan harga, dan *risk-reward ratio*.

1.5. Metode Penelitian

Penelitian ini menggunakan pendekatan kuantitatif berbasis data historis dengan desain penelitian bersifat *explanatory*, yang bertujuan untuk mengembangkan serta memvalidasi model hibrida enam tahap dalam mengidentifikasi zona *support* dan *resistance* pada saham sektor energi. Metodologi penelitian dirancang secara sistematis dan terstruktur untuk mentransformasi data mentah harga historis (*high, low, open, close*) menjadi dataset

baru berupa zona-zona *support* dan *resistance* yang akan dievaluasi efektivitasnya. Alur penelitian dimulai dengan pengumpulan data harga historis saham sektor energi (minyak, gas, dan batu bara) dari Bursa Efek Indonesia selama enam tahun terakhir, yang diperoleh melalui platform tepercaya seperti *Yahoo Finance* atau *API* resmi BEI dalam format *daily timeframe*. Data mentah ini kemudian melalui enam tahap pemrosesan: (1) deteksi *pivot points* menggunakan formula standar berbasis *high-low-close*, (2) *filtering* kontekstual untuk memisahkan *support* (di bawah *current price*) dan *resistance* (di atas *current price*), (3) standarisasi *Z-Score* untuk menghilangkan bias skala, (4) *K-Means clustering* untuk mengelompokkan *pivot points* secara objektif, (5) konversi *cluster centroid* menjadi *price zones* dengan batas minimum dan maksimum, serta (6) pemberian skor pada zona berdasarkan kekuatan (jumlah sentuhan) dan kedekatan terhadap harga saat ini. Hasil dari keseluruhan proses ini menghasilkan dataset baru yang berisi daftar zona *support* dan *resistance* dengan atribut-atribut spesifik seperti batas zona, centroid, jumlah sentuhan historis, dan skor kepercayaan.

Dataset zona baru yang telah dihasilkan kemudian dievaluasi efektivitasnya melalui *algorithmic backtesting* pada data historis yang belum pernah dilihat oleh model (*out-of-sample*). Strategi *backtesting* dilakukan dengan memberikan sinyal *entry* ketika harga menyentuh zona *support* (*buy signal*) atau *resistance* (*sell signal*) berdasarkan skor zona, dengan strategi *exit* berupa target keuntungan di zona lawan atau *stop loss* ketika harga melewati batas zona. Efektivitas model diukur menggunakan metrik kinerja komprehensif seperti *win rate* (persentase transaksi yang menghasilkan keuntungan), akurasi prediksi pembalikan harga, serta *risk-reward ratio*.

1.6. Kontribusi Penelitian

Penelitian ini memberikan kontribusi terhadap pengembangan metodologi yang lebih objektif dalam mengidentifikasi zona *support* dan *resistance* pada saham sektor energi di Bursa Efek Indonesia melalui penerapan algoritma hibrida enam tahap berbasis *K-Means clustering*. Dengan mengatasi kelemahan metode

konvensional yang cenderung subjektif dan rawan kesalahan manusia, model ini mengintegrasikan beberapa teknik, yakni deteksi pivot points, contextual filtering, standarisasi Z-score, objective clustering, konversi zona harga, serta pemberian skor berdasarkan kekuatan statistik. Inovasi tersebut tidak hanya menawarkan pendekatan yang terukur secara kuantitatif, tetapi juga memberikan solusi praktis bagi investor dan trader dalam meningkatkan akurasi analisis teknikal pada pasar dengan tingkat volatilitas tinggi. Dengan demikian, penelitian ini memperluas literatur akademik di bidang machine learning untuk analisis pasar modal sekaligus menghadirkan alat bantu pengambilan keputusan yang lebih andal bagi manajemen risiko dalam perdagangan saham sektor energi.

1.7. Sistematika Penulisan

Sistematika penulisan laporan proposal skripsi ini terdiri dari lima bab dengan rincian sebagai berikut :

BAB I PENDAHULUAN

Bab ini membahas latar belakang penelitian terkait volatilitas tinggi saham sektor energi di Bursa Efek Indonesia serta keterbatasan metode konvensional dalam menentukan level *support* dan *resistance*. Selain itu, dijelaskan pula rumusan masalah mengenai subjektivitas analisis tradisional dan perlunya pendekatan komputasional berbasis *machine learning*, tujuan pengembangan model hibrida enam tahap dengan algoritma *K-Means clustering*, serta ruang lingkup penelitian yang mencakup saham sektor energi dengan data historis enam tahun dan evaluasi melalui *algorithmic backtesting*. Bab ini juga memberikan gambaran umum untuk membantu pembaca memahami konteks penelitian yang dilakukan.

BAB II TINJAUAN PUSTAKA

Bab ini membahas landasan teoritis yang menjadi dasar penelitian, meliputi konsep analisis teknikal dalam pasar modal, teori support dan resistance serta pivot points, karakteristik dan volatilitas sektor energi di Indonesia, algoritma K-Means clustering dan unsupervised learning, teknik standarisasi Z-score dalam

preprocessing data, serta metodologi algorithmic backtesting. Bab ini juga mengkaji penelitian-penelitian terdahulu yang relevan untuk mengidentifikasi research gap dan memposisikan kontribusi penelitian ini dalam literatur akademis.


BAB III METODOLOGI PENELITIAN

Bab ini memaparkan mengenai metode yang digunakan dalam penelitian beserta penerapannya, mulai dari perancangan desain penelitian, pengumpulan dan pengolahan data harga historis, penerapan model hibrida enam tahap berbasis K-Means clustering untuk membentuk zona support dan resistance, hingga prosedur evaluasi kinerja model melalui pengujian backtesting algoritmik pada data historis.

BAB II

TINJAUAN PUSTAKA

2.1. Roadmap



Gambar 2.1.1. Roadmap Penelitian

Roadmap penelitian ini menggambarkan perkembangan pendekatan dalam identifikasi level support dan resistance pada pasar saham menggunakan metode K-Means Clustering dan backtesting algoritmik. Penelitian-penelitian awal seperti Letteri et al. (2023) dan Öztürk (2024) menjadi dasar dengan fokus pada penerapan backtesting untuk menguji strategi trading serta identifikasi level support dan resistance menggunakan algoritma clustering. Namun, beberapa keterbatasan ditemukan, seperti kurangnya preprocessing data dan penyesuaian yang memadai. Studi Wongoutong (2024) kemudian mengevaluasi pengaruh feature scaling terhadap akurasi K-Means, namun belum diterapkan secara spesifik pada analisis pasar saham.

Penelitian berkembang menuju penerapan yang lebih kontekstual dan dinamis, seperti yang dilakukan oleh Akhtar & Raza (2024) yang memperkenalkan identifikasi support dan resistance secara dinamis menggunakan machine learning,

meskipun belum mengonversi hasil centroid ke zona harga. Studi Dhakal (2024) memperluas pendekatan dengan strategi trading hibrida berbasis machine learning, sedangkan Tri Wahyudi et al. (2025) menyoroti dampak makroekonomi harga minyak terhadap saham energi Indonesia. Berdasarkan arah perkembangan tersebut, penelitian saat ini berjudul “Identifikasi Support Resistance pada Saham Sektor Energi IDX Menggunakan Metode K-Means Clustering dan Backtesting Algoritmik” hadir untuk mengisi kekurangan penelitian terdahulu dengan mengintegrasikan preprocessing yang optimal, konversi centroid ke zona harga, serta validasi empiris melalui backtesting algoritmik untuk menghasilkan strategi trading yang lebih akurat dan adaptif.

2.2. Kajian Literatur

Tabel 2.2.1 Kajian Literatur

No	Nama Peneliti	Judul Peneliti	Hasil
1	Öztürk, C. (2024)	Market Analysis with K-Means Clustering Algorithm: Identifying Support and Resistance Levels	Algoritma K-Means clustering secara otomatis mengelompokkan data harga historis untuk mengidentifikasi level support dan resistance secara objektif tanpa interpretasi subjektif.
2	Wongoutong, C. (2024)	Impact of Feature Scaling on K-Means Clustering Performance for Features with Different Units	Dataset dengan fitur yang memiliki unit berbeda, scaling fitur sebelum K-Means menghasilkan akurasi, presisi, recall, dan F-score yang lebih baik dibandingkan menggunakan raw data.

No	Nama Peneliti	Judul Peneliti	Hasil
3	Dhakal, S. (2024)	An Algorithmic Trading Approach: Merging Machine Learning With Multi-Indicator Strategies for Optimal Performance	Model hibrida yang menggabungkan machine learning dengan analisis teknikal untuk mempertahankan win rate yang tinggi selama backtesting, menunjukkan robustness model di berbagai kondisi pasar.
4	Letteri, I., et al. (2023)	Backtesting Trading Strategies: Application on Historical Market Data	Backtesting merupakan metode yang digunakan untuk memvalidasi efektivitas strategi trading sebelum diterapkan dalam kondisi pasar real-time.
5	Akhtar, N. & Raza, A. (2024)	Machine Learning Dynamic Support and Resistance by AlgoAlpha	Indikator Machine Learning Dynamic Support and Resistance memanfaatkan teknik machine learning canggih untuk mengidentifikasi level support dan resistance dinamis. Indikator ini menggunakan algoritma K-means clustering untuk secara dinamis mengidentifikasi level harga kunci berdasarkan data harga historis.

No	Nama Peneliti	Judul Peneliti	Hasil
6	Tri Wahyudi, et al. (2025)	Impact of Global Oil Price Shocks on Energy Stocks: Short-term and Long-term Analysis	Meskipun sektor energi tidak menghadapi dampak jangka panjang yang signifikan dari volatilitas harga minyak global, fluktuasi harga minyak jangka pendek tetap mempengaruhi sektor ini secara substansial.
7	Asma Awan, et al. (2023)	The Macroeconomic Determinants of Stock Price Volatility in Pakistan: An Empirical Investigation	Volatilitas harga saham di pasar negara berkembang dipengaruhi secara signifikan oleh determinan makroekonomi global, sentimen pasar, dan perubahan kebijakan. Faktor-faktor eksternal ini menciptakan fluktuasi harga yang substansial yang memerlukan tools analisis yang presisi untuk manajemen risiko.
8	Tyas, F.K. (2025)	Analisis Fluktuasi Harga Saham Sektor Energi di Bursa Efek Indonesia	Harga saham di sektor energi mengalami fluktuasi yang signifikan pada tahun 2021. Dari bulan Januari hingga Agustus 2021, indeks harga saham sektor energi mengalami

No	Nama Peneliti	Judul Peneliti	Hasil
			penurunan yang signifikan, menunjukkan tingkat volatilitas yang tinggi di sektor ini yang memerlukan strategi manajemen risiko yang efektif.
9	Kusmini, S. & Wibowo, A. (2025)	Market Uncertainty and Asymmetric Information in Indonesian Energy Sector 2021-2024	Penelitian yang mengkaji hubungan antara ketidakpastian pasar dan asimetri informasi di sektor energi Indonesia dari 2021 hingga 2024 menemukan bahwa peningkatan volatilitas berdampak negatif pada efisiensi pasar. Ketidakpastian dan kesenjangan informasi menghambat kemampuan pasar untuk sepenuhnya merefleksikan informasi yang tersedia.
10	Luis, A. & Elisabete, V. (2023)	Technical Analysis, Fundamental Analysis, and Ichimoku Dynamics: A Bibliometric Analysis	Selama 30 tahun terakhir, riset mengenai technical analysis, fundamental analysis, dan Ichimoku dynamics menunjukkan peningkatan signifikan, dengan minat yang terus

No	Nama Peneliti	Judul Peneliti	Hasil
			tumbuh pada topik <i>Ichimoku</i> yang masih jarang dikaji. Analisis terhadap 1710 publikasi mengungkap tren riset, kolaborasi global, serta munculnya tema-tema baru yang bermanfaat bagi pengembangan strategi trading, peramalan harga, dan pengambilan keputusan investasi.

2.3. Pasar Modal dan Bursa Efek Indonesia

Pasar modal merupakan institusi keuangan yang memfasilitasi transaksi jual-beli instrumen keuangan jangka panjang seperti saham, obligasi, dan efek lainnya antara investor dan emiten (Katifa et al., 2025). Pasar modal Indonesia, khususnya Bursa Efek Indonesia (BEI), telah menunjukkan resiliensi yang signifikan dalam menghadapi dinamika ekonomi global dan domestik. Peran strategis pasar modal Indonesia dalam mendukung pertumbuhan ekonomi tercermin dari meningkatnya aktivitas penghimpunan dana dan kapitalisasi pasar yang terus berkembang (Sarjan et al., 2025). Struktur pasar modal yang solid dan regulasi yang ketat oleh Otoritas Jasa Keuangan (OJK) menjadikan pasar ini sebagai pilihan investasi yang menarik bagi investor domestik dan internasional (Katifa et al., 2025). Dalam konteks penelitian ini, pemahaman mendalam tentang pasar modal Indonesia dan mekanisme perdagangannya sangat penting untuk mengelola risiko dan mengidentifikasi peluang investasi, terutama pada sektor-sektor dengan volatilitas tinggi seperti energi.

2.3.1. Pasar Modal

Pasar modal adalah sistem keuangan terorganisir yang menyediakan fasilitas untuk transaksi efek berjangka panjang dengan jangka waktu lebih dari satu tahun (Katifa et al., 2025). Pasar modal memiliki dua fungsi utama: fungsi ekonomi dan fungsi keuangan. Dari sisi fungsi ekonomi, pasar modal menyediakan sarana bagi perusahaan untuk mendapatkan dana guna membiayai operasional dan ekspansi bisnis, sementara dari sisi fungsi keuangan, pasar modal memberikan kesempatan kepada investor untuk menginvestasikan dananya dengan harapan memperoleh keuntungan (Sarjan et al., 2025). Pasar modal Indonesia telah berkembang menjadi salah satu pasar modal terbesar di Asia Tenggara, dengan lebih dari 800 emiten tercatat dan kapitalisasi pasar yang terus meningkat (Sarjan et al., 2025). Mekanisme transparansi dan regulasi yang ketat oleh Otoritas Jasa Keuangan (OJK) berdasarkan Undang-Undang Nomor 8 Tahun 1995 tentang Pasar Modal dan Undang-Undang Nomor 21 Tahun 2011 tentang

OJK memastikan bahwa pasar modal beroperasi dengan prinsip-prinsip keadilan, ketertiban, dan efisiensi (Katifa et al., 2025). Keberadaan institusi pendukung seperti Bursa Efek Indonesia (BEI), Kustodian Sentral Efek Indonesia (KSEI), dan Kliring Penjaminan Efek Indonesia (KPEI) memperkuat infrastruktur pasar modal yang handal.

2.3.2. Struktur dan Mekanisme Bursa Efek Indonesia



Gambar 2.3.2.1. Struktur Pasar Modal (IDX, 2020)

Bursa Efek Indonesia (BEI) adalah lembaga penyelenggara kegiatan perdagangan efek yang memiliki peran sentral dalam ekosistem pasar modal Indonesia (Katifa et al., 2025). Struktur organisasi BEI terdiri dari beberapa divisi fungsional yang mengatur segmentasi pasar, perdagangan, serta pengawasan. BEI menyelenggarakan pasar reguler dan pasar akseleran yang memfasilitasi transaksi berbagai jenis efek termasuk saham, obligasi, dan produk derivatif (Sarjan et al., 2025). Mekanisme perdagangan di BEI menggunakan sistem perdagangan elektronik (trading system) yang canggih dengan waktu perdagangan yang telah ditetapkan, mulai dari sesi pre-opening hingga sesi closing dengan call auction untuk penentuan harga penutup (Katifa et al., 2025). Fraksi harga (price fraction) yang diterapkan berbeda-beda sesuai dengan rentang harga saham, dengan tujuan meningkatkan efisiensi dan likuiditas pasar. Pembentukan indeks saham seperti Indeks Harga Saham Gabungan (IHSG), LQ45, dan indeks-indeks

sektor lainnya memberikan gambaran tentang kondisi dan performa pasar secara keseluruhan (Sarjan et al., 2025). Sistem clearing dan settlement yang dikelola oleh KPEI dan KSEI memastikan bahwa setiap transaksi berjalan dengan aman dan terpercaya, dengan regulatory framework yang kuat untuk melindungi kepentingan investor (Katifa et al., 2025).

2.3.3. Karakteristik Perdagangan Saham di Indonesia

Perdagangan saham di Indonesia memiliki karakteristik unik yang dipengaruhi oleh kondisi ekonomi, regulasi, dan komposisi investor. Likuiditas pasar yang tinggi, terutama pada saham-saham unggulan yang masuk dalam indeks LQ45, menjadi daya tarik utama bagi investor institusional dan retail (Sarjan et al., 2025). Volatilitas harga saham di pasar Indonesia cenderung lebih tinggi dibandingkan dengan pasar maju, terutama karena pengaruh faktor makroekonomi global seperti fluktuasi nilai tukar rupiah, suku bunga acuan, dan harga komoditas (Octavia et al., 2022). Karakteristik distribusi kepemilikan saham juga mempengaruhi dinamika perdagangan, di mana perusahaan-perusahaan besar sering kali memiliki free float yang relatif rendah, yang dapat memicu pergerakan harga yang signifikan ketika ada aktivitas jual-beli dalam volume besar (Katifa et al., 2025). Selain itu, partisipasi investor retail yang semakin meningkat sejak tahun 2020 menambah dimensi baru dalam perilaku pasar, dengan sentimen pasar yang kadang-kadang berfluktuasi berdasarkan emosi dan asimetri informasi (Sarjan et al., 2025). Mekanisme perdagangan seperti Full Periodic Call Auction (FCA) yang diimplementasikan untuk saham-saham tertentu juga mempengaruhi karakteristik volatilitas dan likuiditas pasar (Pasaribu & Wibowo, 2025).

2.4. Sektor Energi di Bursa Efek Indonesia

Sektor energi merupakan salah satu sektor strategis di pasar modal Indonesia dengan kontribusi signifikan terhadap ekonomi nasional. Sektor ini mencakup emiten-emiten yang bergerak di bidang minyak dan gas bumi, batubara,

dan energi terbarukan. Pada tahun 2024, sektor energi menunjukkan kinerja yang luar biasa dengan peningkatan yang substansial, menjadi salah satu sektor dengan volatilitas tertinggi di pasar modal Indonesia (Kusmini & Wibowo, 2025). Sektor energi memiliki puluhan saham yang terdaftar dengan kapitalisasi pasar yang signifikan, berkontribusi sekitar 9-14% dari total kapitalisasi pasar BEI (Sakinah et al., 2024). Volatilitas yang tinggi pada sektor ini mencerminkan sensitivitasnya terhadap fluktuasi harga komoditas global, kebijakan energi nasional, dan kondisi ekonomi makro internasional (Octavia et al., 2022). Pemahaman mendalam tentang karakteristik dan dinamika sektor energi sangat penting bagi investor yang ingin mengalokasikan portfolio ke sektor ini dengan manajemen risiko yang efektif.

2.4.1. Profil dan Klasifikasi Sektor Energi IDX

Sektor energi di Indonesia dapat diklasifikasikan menjadi beberapa subsegmen berdasarkan jenis sumber energi dan model bisnis. Pertama, subsegmen minyak dan gas bumi (upstream, midstream, dan downstream) yang mencakup eksplorasi, produksi, pengolahan, dan distribusi minyak dan gas. Kedua, subsegmen batubara yang mencakup penambangan, pengolahan, dan penjualan batubara untuk keperluan pembangkit listrik dan industri. Ketiga, subsegmen energi terbarukan yang sedang berkembang pesat mencakup panel surya, turbin angin, dan energi biomassa (Sakinah et al., 2024). Perusahaan-perusahaan besar dalam sektor energi seperti PT Pertamina, PT Energi Mega Persada, PT Medco Energi, dan PT Golden Energy Mines memiliki pengaruh signifikan terhadap performa indeks sektor. Setiap subsegmen memiliki karakteristik risiko yang berbeda, di mana subsegmen minyak dan gas sangat terpapar terhadap fluktuasi harga minyak dunia, sementara subsegmen batubara terpapar terhadap perubahan permintaan global dan kebijakan lingkungan (Octavia et al., 2022). Klasifikasi sektor energi di IDX mengikuti standar Global Industry Classification Standard (GICS) yang memfasilitasi analisis komparatif dengan pasar global (Sakinah et al., 2024). Pemahaman tentang profil dan

klasifikasi ini membantu investor dan analis dalam memilih saham yang sesuai dengan preferensi risiko dan strategi investasi mereka.

2.4.2. Volatilitas dan Dinamika Harga Saham Sektor Energi

Volatilitas saham sektor energi di Indonesia mencerminkan kondisi pasar yang dinamis dan kompleks. Data historis menunjukkan bahwa saham-saham di sektor energi mengalami fluktuasi harga yang signifikan, terutama dalam merespons perubahan harga minyak dunia, kebijakan moneter, dan perkembangan geopolitik global (Kusmini & Wibowo, 2025). Penelitian yang dilakukan oleh Kusmini dan Wibowo (2025) menggunakan World Uncertainty Index (WUI) sebagai ukuran ketidakpastian ekonomi dan politik global menemukan bahwa peningkatan volatilitas berdampak negatif terhadap efisiensi pasar, mengindikasikan bahwa ketidakpastian dan kesenjangan informasi menghambat kemampuan pasar untuk sepenuhnya merefleksikan informasi yang tersedia. Dinamika ini menciptakan peluang trading bagi investor yang memahami pola-pola pergerakan harga, namun juga meningkatkan risiko bagi investor yang tidak melakukan manajemen risiko dengan baik (Sakinah et al., 2024). Fluktuasi harga saham sektor energi sering kali menunjukkan pola volatility clustering, di mana periode volatilitas tinggi cenderung diikuti oleh periode volatilitas tinggi lainnya, yang dapat dimodelkan dengan teknik seperti GARCH (Generalized Autoregressive Conditional Heteroskedasticity) untuk forecasting yang lebih akurat (Sakinah et al., 2024).

2.4.3. Faktor yang Mempengaruhi Pergerakan Harga Saham Energi

Pergerakan harga saham sektor energi dipengaruhi oleh berbagai faktor makroekonomi dan mikroekonomi yang saling terkait. Faktor makroekonomi utama mencakup harga minyak mentah dunia, nilai tukar rupiah terhadap dolar Amerika, suku bunga acuan Bank Indonesia (BI-7 Day Reverse Repo Rate), dan kondisi ekonomi global (Octavia et al., 2022). Penelitian Octavia et al. (2022) menemukan bahwa nilai tukar, suku bunga,

dan kebijakan dividen berpengaruh signifikan terhadap volatilitas harga saham sektor energi. Lebih lanjut, Hasanah dan Syarif (2023) menganalisis hubungan antara volatilitas pasar saham, Foreign Portfolio Investment (FPI), dan indikator makroekonomi pada saham syariah sektor energi periode 2011-2023 menggunakan metode Autoregressive Distributed Lag (ARDL), menemukan bahwa volatilitas dalam jangka panjang dipengaruhi secara positif oleh aktivitas FPI, sementara dalam jangka pendek dipengaruhi oleh nilai tukar dan volatilitas periode sebelumnya. Faktor mikroekonomi mencakup kinerja keuangan perusahaan, strategi bisnis, tingkat produksi, dan efisiensi operasional (Sakinah et al., 2024). Selain itu, sentimen investor dan asimetri informasi juga memainkan peran penting dalam mempengaruhi pergerakan harga saham di pasar Indonesia, terutama pada kondisi ketidakpastian ekonomi yang tinggi (Kusmini & Wibowo, 2025). Faktor geopolitik dan kebijakan energi pemerintah juga dapat memicu perubahan signifikan pada harga saham sektor energi.

2.5. Analisis Teknikal pada Pasar Modal

Analisis teknikal merupakan salah satu metodologi utama dalam menganalisis pergerakan harga saham dengan menggunakan data historis harga, volume transaksi, dan pola grafik untuk mengidentifikasi peluang perdagangan (Setiawan & Wijaya, 2024). Berbeda dengan analisis fundamental yang berfokus pada nilai intrinsik perusahaan, analisis teknikal mengasumsikan bahwa semua informasi yang tersedia sudah tercermin dalam harga pasar saat ini (Öztürk, 2024). Penelitian bibliometrik yang dilakukan menunjukkan bahwa selama tiga puluh tahun terakhir, riset mengenai analisis teknikal dan strategi trading menunjukkan peningkatan signifikan, dengan minat yang terus berkembang pada topik-topik terkait (Luis & Elisabete, 2023). Analisis teknikal memiliki keunggulan dalam mengidentifikasi tren jangka pendek dan titik-titik balik harga yang berguna untuk tujuan trading jangka pendek (Ardiansyah et al., 2025). Namun, keterbatasannya adalah tingkat subjektivitas yang tinggi dalam interpretasi pola grafik, yang

mendorong pengembangan pendekatan yang lebih objektif berbasis komputasi dan machine learning (Öztürk, 2024).


2.5.1. Konsep dan Prinsip Dasar Analisis Teknikal

Analisis teknikal adalah metode evaluasi yang didasarkan pada asumsi bahwa pergerakan harga di masa lalu dan volume perdagangan dapat digunakan untuk mengantisipasi pergerakan harga di masa depan (Wijaya, 2025). Berbeda dengan Analisis Fundamental yang meneliti nilai intrinsik perusahaan, Analisis Teknikal berfokus secara eksklusif pada data pasar (Wijaya, 2025). Metodologi ini dibangun di atas tiga prinsip inti yang berasal dari Teori Dow:

- **Harga Mencerminkan Segalanya (Price Discounts Everything):** Prinsip ini mengasumsikan bahwa semua informasi yang relevan baik itu fundamental, makroekonomi, politik, maupun sentimen pasar sudah tercermin dalam harga aset saat ini (Sertifikasiku, 2024).
- **Harga Bergerak dalam Tren (Prices Move in Trends):** Analisis teknikal meyakini bahwa harga cenderung bergerak dalam tren yang dapat diidentifikasi (naik, turun, atau datar) sampai ada bukti jelas bahwa tren tersebut telah berbalik (Sertifikasiku, 2024).
- **Sejarah Cenderung Berulang (History Tends to Repeat Itself):** Prinsip ini didasarkan pada psikologi pasar. Pola-pola harga tertentu yang telah muncul di masa lalu dan mencerminkan sentimen kolektif (seperti ketakutan atau keserakahan) cenderung akan muncul kembali (Sertifikasiku, 2024).

Fungsi Analisis Teknikal tidak hanya sebagai alat prediksi, tetapi juga sebagai mekanisme disiplin. Dengan menyediakan sinyal objektif berdasarkan pola dan tren, Analisis Teknikal membantu investor mengurangi dampak bias kognitif, psikologis, dan emosi dalam pengambilan keputusan (Wijaya, 2025).

2.5.2. Teori Support dan Resistance



Gambar 2.5.2.1. Support dan Resistance Tradisional (BrokerForex, 2018)

Support dan resistance merupakan konsep inti dalam analisis teknikal yang membantu trader mengidentifikasi area-area penting di mana pergerakan harga sering kali berhenti atau berbalik (Öztürk, 2024). Support adalah level harga di mana tekanan beli (demand) cukup kuat untuk menghentikan penurunan harga, sementara resistance adalah level harga di mana tekanan jual (supply) cukup kuat untuk menghentikan kenaikan harga (Setiawan & Wijaya, 2024). Secara teoritis, level support dan resistance terbentuk karena dari aktivitas historis buyer dan seller pada level harga tertentu, menciptakan "memory" di pasar yang cenderung bereaksi serupa ketika harga kembali menyentuh level-level tersebut (Akhtar & Raza, 2024). Dalam praktik trading, support dan resistance digunakan untuk: menentukan titik masuk (entry) dan keluar (exit) dengan lebih presisi, menempatkan stop loss di area yang logis berdasarkan struktur pasar, dan mengidentifikasi area target keuntungan berdasarkan zona-zona harga penting (Öztürk, 2024). Penelitian Ardiansyah et al. (2025) menguji kemampuan prediksi indikator teknikal terhadap harga saham perbankan di Indonesia, menemukan bahwa level support dan resistance yang diidentifikasi melalui Fibonacci Retracement memiliki tingkat akurasi yang signifikan dalam memprediksi pembalikan harga. Fenomena "role reversal" juga penting dipahami, di mana ketika level resistance berhasil ditembus

dengan volume besar, level tersebut dapat berubah fungsi menjadi support baru (Setiawan & Wijaya, 2024).

2.5.3. Pivot Points dan Metode Identifikasi Konvensional



Gambar 2.5.3.1. Visualisasi Classical Pivot Points (Truedata, 2025)

Pivot points adalah alat analisis teknikal yang digunakan untuk mengidentifikasi level support dan resistance secara otomatis berdasarkan data harga periode sebelumnya (Trading Strategy Guides, 2024). Metode classical atau floor trader untuk menghitung pivot point menggunakan rumus:

$$PP = \frac{(Harga\ Tertinggi + Harga\ Terendah + Harga\ Penutupan)}{3} \quad (2.5.3.1)$$

dengan level-level support dan resistance dihitung sebagai berikut:

$$R_1 = (2 \times Pivot\ Point) - Harga_{\{Terendah\}} \quad (2.5.3.2)$$

$$S_1 = (2 \times Pivot\ Point) - Harga_{\{Tertinggi\}} \quad (2.5.3.3)$$

$$R_2 = Pivot\ Point + (Harga_{\{Tertinggi\}} - Harga_{\{Terendah\}}) \quad (2.5.3.4)$$

$$S_2 = Pivot\ Point - (Harga_{\{Tertinggi\}} - Harga_{\{Terendah\}}) \quad (2.5.3.5)$$

(Ultra Trader Research, 2025). Keunggulan pivot points dibandingkan dengan metode manual adalah tingkat objektivitas yang lebih tinggi karena menggunakan formula matematis yang jelas dan konsisten (Öztürk, 2024). Dalam praktik, pivot points digunakan sebagai acuan utama untuk perencanaan trading harian, terutama oleh day traders yang memerlukan identifikasi cepat terhadap area-area penting pada setiap hari perdagangan (Trading Strategy Guides, 2024). Variasi lain dari pivot points seperti Fibonacci Pivot Points menggunakan rasio Fibonacci (38.2%, 61.8%) untuk menghitung support dan resistance berdasarkan range harga (High – Low), yang seringkali digunakan dalam pasar forex dan cryptocurrency karena alignment dengan psikologi pasar (Ultra Trader Research, 2025). Namun, pivot points tradisional memiliki keterbatasan signifikan ketika diterapkan pada pasar dengan volatilitas sangat tinggi seperti sektor energi, karena formula ini tidak memberikan representasi zona harga yang fleksibel dan tidak mempertimbangkan kepadatan statistik dari aksi harga historis (Dhakal, 2024).

2.5.4. Keterbatasan Metode Konvensional dalam Identifikasi S/R

Meskipun analisis teknikal konvensional telah lama digunakan oleh trader, metode ini memiliki beberapa keterbatasan fundamental yang mempengaruhi keandalan identifikasi support dan resistance. Pertama, keterbatasan subjektivitas tinggi dalam interpretasi visual grafik, di mana tingkat validitas level S/R sangat bergantung pada pengalaman dan keahlian analyst, sehingga dua analyst berbeda dapat menghasilkan identifikasi yang berbeda untuk data yang sama (Öztürk, 2024). Kedua, keterbatasan pada pasar dengan volatilitas tinggi, di mana pivot points tradisional sering kali menghasilkan level-level yang kurang responsif terhadap perubahan dinamis kondisi pasar (Trading Strategy Guides, 2024). Ketiga, keterbatasan dalam mengidentifikasi zona S/R yang lebih realistis; metode konvensional hanya menghasilkan level harga tunggal, padahal dalam

praktik sebenarnya S/R beroperasi sebagai zona dengan range harga, bukan titik harga eksak (Dhakal, 2024). Keempat, keterbatasan dalam mempertimbangkan kepadatan atau kekuatan statistik dari aksi harga historis, di mana level yang telah diuji berkali-kali oleh pasar seharusnya dianggap lebih kuat dibandingkan dengan level yang hanya disentuh sekali saja (Akhtar & Raza, 2024). Kelima, keterbatasan pada pengaruh skala data historis jangka panjang, di mana harga dari periode tahun pertama dan tahun keenam dalam dataset 6 tahun memiliki skala yang sangat berbeda namun sering kali diberikan bobot yang sama dalam analisis (Wongoutong, 2024). Penelitian Ardiansyah et al. (2025) juga menemukan bahwa tidak semua sinyal yang dihasilkan oleh indikator teknikal tradisional akurat, dengan beberapa sinyal menghasilkan false positive yang dapat menyebabkan kerugian trading.

2.6. Machine Learning untuk Analisis Pasar Modal

Machine learning merupakan cabang dari artificial intelligence yang memungkinkan sistem komputer untuk belajar dan meningkatkan performa tanpa diprogram secara eksplisit untuk setiap skenario spesifik (Almuqati et al., 2023). Dalam konteks analisis pasar modal, machine learning menawarkan keunggulan signifikan dalam memproses dataset besar dengan pola-pola kompleks yang sulit dipahami oleh metode analitik tradisional (Siregar et al., 2024). Penggunaan machine learning di pasar saham telah menunjukkan hasil yang menjanjikan dalam berbagai aplikasi mulai dari prediksi harga saham, identifikasi pola perdagangan, klasifikasi risiko, hingga optimasi portfolio (Sakinah et al., 2024). Machine learning juga mendorong pengambilan keputusan yang lebih objektif dengan meminimalkan pengaruh bias emosional manusia, serta memiliki kemampuan untuk terus belajar dan beradaptasi dengan data baru, memungkinkan strategi investasi yang lebih dinamis dan responsif terhadap perubahan pasar (Yakovyna et al., 2024).

2.6.1. Supervised Learning dan Unsupervised Learning

Machine learning dapat dibedakan menjadi dua kategori utama berdasarkan jenis data yang digunakan: *supervised learning* dan *unsupervised learning* (Almuqati et al., 2023).

Supervised learning adalah metode *machine learning* di mana model dilatih menggunakan data berlabel (labeled data), artinya setiap data input memiliki label output yang benar (Almuqati et al., 2023). Dalam *supervised learning*, algoritma belajar untuk memetakan hubungan antara input dan output melalui proses training, sehingga dapat memprediksi output untuk data input baru yang sebelumnya tidak pernah dilihat.


Tujuan utama *supervised learning* adalah mengidentifikasi fungsi pengambilan keputusan yang menganalisis variabel input untuk menargetkan output spesifik guna memprediksi data baru (Almuqati et al., 2023). Dua subtype utama *supervised learning* adalah klasifikasi untuk mendefinisikan penugasan grup dan regresi untuk memprediksi nilai output kontinu. Aplikasi *supervised learning* dalam pasar modal mencakup prediksi harga saham (regression), klasifikasi apakah saham akan naik atau turun (classification), dan deteksi anomali atau fraud dalam transaksi pasar.

Sebaliknya, *unsupervised learning* adalah metode *machine learning* di mana model belajar dari data tidak berlabel (unlabeled data) tanpa panduan eksplisit tentang jawaban yang benar (Almuqati et al., 2023). Tujuan utama *unsupervised learning* adalah menemukan struktur, pola tersembunyi, dan wawasan yang berguna dari dataset tanpa pengetahuan sebelumnya tentang kategori atau label data.

Sistem dengan *unsupervised learning* beroperasi melalui cara otonom, dan keluarga clustering menggunakan K-means clustering dikombinasikan dengan metode clustering hierarkis bersama dengan metrik jarak dan prosedur estimasi densitas untuk melakukan pencocokan titik pola serupa (Almuqati et al., 2023). Dalam konteks identifikasi support dan resistance, *unsupervised learning* sangat relevan karena peneliti tidak memiliki label sebelumnya tentang di mana level-level S/R "seharusnya"

berada, melainkan membiarkan algoritma menemukan pola pengelompokan aksi harga secara objektif (Öztürk, 2024).

2.6.2. K-Means Clustering



Gambar 2.6.2.1. K-Means Clustering (DQLab, 2022)

K-Means clustering adalah salah satu algoritma machine learning yang paling populer dalam kategori *unsupervised learning* untuk tugas pengelompokan data (Siregar et al., 2024). Algoritma ini bekerja dengan cara membagi dataset menjadi K cluster yang berbeda, di mana setiap data point dikelompokkan ke cluster terdekat berdasarkan jarak Euclidean terhadap centroid (pusat) cluster (Irawan et al., 2025). Proses K-Means terdiri dari beberapa iterasi: pertama, menginisialisasi K centroid secara acak; kedua, mengalokasikan setiap data point ke centroid terdekat; ketiga, menghitung centroid baru berdasarkan rata-rata posisi data point dalam setiap cluster; keempat, mengulangi proses sampai centroid stabil atau tidak berubah lagi (Irawan et al., 2025). Penelitian Irawan et al. (2025) menerapkan algoritma K-Means untuk segmentasi nasabah bank berdasarkan faktor demografi dan finansial, menemukan bahwa validasi menggunakan Within-Cluster Sum of Squares (WCSS) dan Davies-Bouldin Index dapat mengukur kualitas hasil segmentasi dengan efektif. Keunggulan K-Means adalah algoritma ini cukup mudah dipahami dan diimplementasikan, memiliki kompleksitas komputasi yang rendah untuk dataset besar

$$O(n \times k \times i) \quad (2.6.2.1)$$

Di mana n adalah jumlah data point, k adalah jumlah cluster, dan i adalah jumlah iterasi), serta cukup efektif dalam mengidentifikasi cluster yang well-separated (Siregar et al., 2024). Namun, K-Means juga memiliki keterbatasan:

- (1) sangat sensitif terhadap skala fitur dan outlier,
- (2) asumsi bahwa cluster berbentuk spherical (bulat) yang tidak selalu sesuai dengan struktur data nyata,
- (3) memerlukan penentuan parameter K sebelumnya, dan
- (4) hasil clustering dapat berbeda tergantung pada inisialisasi centroid awal (Irawan et al., 2025).

Untuk mengatasi sensitivitas terhadap inisialisasi, sering digunakan K-Means++ yang memilih centroid awal dengan lebih cerdas menggunakan distribusi probabilistik untuk meningkatkan kualitas hasil akhir (Siregar et al., 2024).

2.6.3. Penerapan Clustering dalam Analisis Finansial

Penerapan algoritma clustering dalam analisis finansial telah menunjukkan hasil-hasil yang signifikan dalam berbagai aplikasi praktis. Dalam konteks analisis saham, K-Means clustering telah digunakan untuk mengelompokkan saham berdasarkan kesamaan karakteristik finansial seperti Price Earning Ratio (PER) dan Price to Book Value (PBV), membantu investor mengidentifikasi saham-saham yang murah, sedang, atau mahal dengan profil risiko yang berbeda (Ramadhan & Kusuma, 2025). Penelitian Siregar et al. (2024) menggunakan K-Means untuk klasifikasi harga saham harian di Indonesia Stock Exchange, menghasilkan pengelompokan yang efektif dengan potensi untuk mengungkap pola-pola penting yang berkontribusi pada pengembangan strategi investasi. Penelitian lebih lanjut menunjukkan bahwa pengelompokan berbasis machine learning sangat menjanjikan dalam pemilihan portfolio dengan nilai Sharpe Ratio yang tinggi dan volatilitas rendah (Siregar et al., 2024). Dalam konteks identifikasi support dan resistance, K-Means clustering

diterapkan untuk mengelompokkan titik-titik harga (pivot points) yang memiliki karakteristik serupa, sehingga menghasilkan zona-zona S/R yang lebih representatif dibandingkan dengan metode konvensional (Öztürk, 2024). Penelitian Sakinah et al. (2024) menerapkan time series analysis dan K-Means clustering untuk forecasting harga saham sektor energi, menemukan bahwa clustering issuer berdasarkan kesamaan pergerakan harga saham dapat meningkatkan akurasi prediksi pada level cluster. Penelitian terbaru menunjukkan bahwa kombinasi K-Means dengan teknik preprocessing data yang optimal dapat menghasilkan cluster yang lebih akurat dan valid dengan Silhouette Score yang tinggi, yang mengukur seberapa baik data point cocok dengan cluster-nya dibandingkan dengan cluster lain (Irawan et al., 2025).

2.7. Preprocessing Data dan Featur Engineering

Preprocessing data merupakan tahap krusial dalam pipeline machine learning yang bertujuan untuk mempersiapkan data mentah agar siap digunakan untuk training model (Pinheiro et al., 2025). Tahap preprocessing mencakup beberapa langkah penting seperti pembersihan data (data cleaning), penanganan missing values, removal outlier, normalisasi/standarisasi, dan feature engineering. Kualitas preprocessing data secara langsung mempengaruhi performa model machine learning, di mana data yang buruk akan menghasilkan prediksi yang tidak akurat meskipun menggunakan algoritma terbaik (Wongoutong, 2024). Dalam konteks penelitian ini, preprocessing data menjadi sangat penting karena dataset harga saham 6 tahun memiliki variasi skala yang sangat besar antara harga-harga awal periode dan harga-harga akhir periode, yang dapat mengganggu performa algoritma K-Means jika tidak ditangani dengan baik (Wongoutong, 2024). Penelitian Pinheiro et al. (2025) menekankan bahwa evaluasi dampak metode scaling data yang berbeda terhadap proses training dan metrik performa sangat penting, karena metode scaling yang tepat dapat secara signifikan meningkatkan akurasi model.

2.7.1. Data Harga Historis Saham (Open High Low Close)

Data harga historis saham yang digunakan dalam penelitian ini adalah data OHLC (Open, High, Low, Close) dalam timeframe harian. Open (pembukaan) adalah harga saham pada saat pasar mulai dibuka pada hari perdagangan tersebut, High (tertinggi) adalah harga tertinggi yang dicapai saham selama hari perdagangan, Low (terendah) adalah harga terendah yang dicapai, dan Close (penutupan) adalah harga pada saat pasar ditutup (Sakinah et al., 2024). Selain data OHLC, penelitian ini juga menggunakan Volume yang merupakan jumlah lembar saham yang diperdagangkan dalam satu hari. Data OHLC merupakan input utama untuk deteksi pivot points dan menjadi dasar untuk perhitungan berbagai indikator teknikal (Ultra Trader Research, 2025). Dalam dataset 6 tahun, setiap saham memiliki ribuan data point harian yang mencerminkan dinamika pasar lengkap sepanjang periode observasi. Penelitian Sakinah et al. (2024) menggunakan data OHLC sektor energi untuk forecasting dengan time series analysis dan K-Means clustering, menemukan bahwa data harian memberikan granularitas yang cukup untuk analisis pola pergerakan harga tanpa noise berlebihan yang sering ditemukan pada timeframe yang lebih pendek. Data OHLC dipilih karena informatif dalam menangkap volatilitas dan pergerakan harga intraday yang penting untuk identifikasi support dan resistance (Öztürk, 2024).

2.7.2. Feature Scaling dan Standarisasi

Feature scaling atau standarisasi adalah proses mengubah skala nilai-nilai fitur dalam dataset sehingga memiliki rentang yang sama, biasanya dengan mean (rata-rata) 0 dan *standard deviation* (simpangan baku) 1, atau rentang 0-1 (Pinheiro et al., 2025).

Pentingnya feature scaling menjadi sangat kritis ketika fitur-fitur dalam dataset memiliki unit atau skala yang berbeda secara drastis. Dalam konteks dataset harga saham 6 tahun, harga saham pada tahun 2018 (misalnya Rp 1.000) dan harga pada tahun 2024 (misalnya Rp 4.000)

memiliki skala yang sangat berbeda, sehingga tanpa scaling yang tepat, algoritma machine learning terutama K-Means akan memberikan bobot yang tidak proporsional terhadap data-data yang memiliki nilai absolut lebih besar (Wongoutong, 2024).

Penelitian Wongoutong (2024) yang dipublikasikan di PMC (PubMed Central) menunjukkan bahwa mengabaikan feature scaling pada dataset dengan fitur yang memiliki unit berbeda secara signifikan "memperburuk akurasi, presisi, dan recall" dibandingkan dengan penggunaan data yang telah diskalakan.

Algoritma seperti K-Means, KNN, SVM, dan neural networks sangat sensitif terhadap skala fitur karena mereka mengandalkan perhitungan jarak antar titik data, sehingga feature scaling menjadi langkah mandatory dalam preprocessing (Pinheiro et al., 2025). Penelitian Kim et al. (2025) yang dipublikasikan di ScienceDirect dengan 126 kutipan menemukan bahwa dengan menormalisasi data, nilai-nilai fitur yang berbeda disesuaikan ke skala yang sama, mencegah fitur tertentu mendominasi analisis hanya karena perbedaan magnitude.

2.7.3. Z-Score Standardization


Z-Score standardization, juga dikenal sebagai standarisasi, adalah teknik preprocessing data yang mengubah nilai fitur sehingga memiliki distribusi dengan mean 0 dan standard deviation 1 (Pinheiro et al., 2025). Rumus Z-Score standardization adalah: $z = (x - \mu) / \sigma$

$$z = \frac{(x - \mu)}{\sigma} \quad (2.7.3.1)$$

di mana z adalah nilai standar (Z-score), x adalah nilai awal, μ adalah rata-rata dataset, dan σ adalah standard deviation atau simpangan baku dari dataset.

Proses Z-Score standardization mengubah setiap nilai awal dengan mengurangnya dengan mean, kemudian membaginya dengan standard

deviation, sehingga menghasilkan nilai-nilai yang berpusat di sekitar 0 dengan spread yang konsisten (Wongoutong, 2024).



Gambar 2.7.3.1. Data Sebelum dan Sesudah Z-Score Normalization (Neri Van Otten, 2025)

Keunggulan Z-Score standardization dibandingkan dengan normalisasi Min-Max adalah bahwa Z-Score lebih sesuai untuk data yang berdistribusi normal (Gaussian) dan lebih tahan terhadap outlier dalam batas tertentu, karena tidak membatasi data ke rentang spesifik seperti $[0,1]$ (Pinheiro et al., 2025).

Dalam konteks penelitian ini, Wongoutong (2024) secara spesifik menemukan bahwa Z-Score standardization memberikan performa "superior" untuk dataset dengan fitur yang memiliki unit berbeda, menghasilkan akurasi, presisi, recall, dan F-score yang lebih baik dibandingkan dengan metode normalisasi lainnya. Penelitian ini membandingkan lima metode scaling: Z-score Normalization, Min-Max Normalization, Percentile transformation, Maximum absolute scaling, dan Robust Scaler, dengan hasil bahwa Z-score secara konsisten memberikan hasil terbaik pada cluster analysis (Wongoutong, 2024).

2.7.4. Normalisasi dalam K-Means Clustering



Gambar 2.7.4.1. Dampak Skala pada K-Means With vs Without Normalization

Normalisasi dalam K-Means clustering adalah langkah preprocessing yang bertujuan untuk memastikan bahwa semua fitur memiliki kontribusi yang seimbang dalam perhitungan jarak Euclidean antar data point (Pinheiro et al., 2025). Tanpa normalisasi, fitur dengan skala nilai yang lebih besar akan mendominasi perhitungan jarak, sehingga fitur dengan skala kecil akan diabaikan oleh algoritma (Irawan et al., 2025).

Penelitian Pinheiro et al. (2025) yang dipublikasikan di arXiv menekankan bahwa untuk tugas unsupervised seperti K-Means, normalisasi membantu mencegah bias yang tidak diinginkan dalam indeks validasi eksternal seperti Jaccard, Fowlkes-Mallows, dan Adjusted Rand Index, yang dapat muncul karena variasi dalam jumlah cluster atau ketidakseimbangan dalam distribusi ukuran kelas.

Proses normalisasi untuk K-Means biasanya dilakukan menggunakan Z-Score standardization atau Min-Max scaling sebelum algoritma dijalankan. Setelah normalisasi, semua fitur akan memiliki rata-rata 0 dan standard deviation 1 (untuk Z-Score) atau berada dalam rentang

0-1 (untuk Min-Max), sehingga perhitungan jarak Euclidean akan mempertimbangkan semua fitur secara adil (Wongoutong, 2024).

Penelitian Irawan et al. (2025) menunjukkan bahwa validasi hasil clustering menggunakan Within-Cluster Sum of Squares (WCSS) dan Davies-Bouldin Index memberikan hasil yang lebih baik ketika data telah dinormalisasi terlebih dahulu.

2.8. Backtesting Algoritmik

Backtesting algoritmik adalah proses pengujian strategi trading dengan menggunakan data harga historis untuk melihat bagaimana strategi tersebut berkinerja jika diterapkan pada periode waktu sebelumnya (Letteri et al., 2023). Tujuan utama backtesting adalah untuk memvalidasi efektivitas strategi trading sebelum diterapkan dengan uang sungguhan di pasar real-time, sehingga dapat mengurangi risiko kerugian yang tidak perlu (Mehra et al., 2024).

Backtesting memberikan gambaran kuantitatif tentang performa strategi melalui berbagai metrik seperti total profit/loss, win rate, risk-reward ratio, maximum drawdown, Sharpe ratio, dan lainnya (Fahros et al., 2025).

Proses backtesting mengikuti asumsi bahwa jika strategi bekerja dengan baik di masa lalu, strategi tersebut memiliki peluang yang baik untuk bekerja dengan baik dalam kondisi masa depan, meskipun hal ini tidak menjamin hasil yang sama (Mehra et al., 2024). Dalam konteks penelitian ini, backtesting digunakan untuk mengevaluasi keandalan (robustness) dari zona support dan resistance yang dihasilkan oleh model K-Means clustering, sehingga dapat memberikan validasi empiris tentang efektivitas model pada studi kasus saham sektor energi IDX (Letteri et al., 2023).

2.8.1. Metodologi Backtesting Strategi Trading

Metodologi backtesting strategi trading melibatkan beberapa langkah sistematis untuk memastikan hasil pengujian yang valid dan reliable. Pertama, menentukan strategi spesifik yang akan diuji, termasuk aturan entry, exit, dan risk management yang jelas dan objektif (Mehra et

al., 2024). Kedua, mengumpulkan data historis yang representatif untuk periode testing, biasanya minimal 1-2 tahun data untuk validasi yang kuat (Bathia et al., 2024).

Dalam penelitian ini, menggunakan periode out-of-sample testing untuk memastikan bahwa model tidak overfitting terhadap data training. Ketiga, melakukan simulasi trading secara otomatis atau manual berdasarkan aturan strategi, mencatat setiap transaksi yang terjadi baik yang profitable maupun mengalami loss (Mehra et al., 2024).

Mehra et al. (2024) mengembangkan dan menguji custom algorithmic trading strategy menggunakan technical indicators seperti EMA dan RSI, kemudian melakukan backtesting komprehensif menggunakan library Python VectorBt yang memungkinkan testing multiple scenarios secara efisien.

Keempat, menghitung berbagai metrik performa berdasarkan hasil simulasi trading (Letteri et al., 2023). Kelima, melakukan validasi robustness strategi dengan menguji pada berbagai kondisi pasar atau periode waktu yang berbeda untuk memastikan konsistensi performa (Dhakal, 2024).

Dalam konteks penelitian ini, strategi backtesting diatur dengan memberikan sinyal entry ketika harga menyentuh zona support (buy signal) atau resistance (sell signal) berdasarkan skor zona S/R yang dihasilkan oleh model K-Means, dengan exit berupa target keuntungan di zona lawan atau stop loss ketika harga melewati batas zona (Dhakal, 2024).

2.8.2. Metrik Evaluasi Performa Trading

a) Win Rate


Win rate adalah persentase dari total transaksi yang menghasilkan keuntungan (profitable trades) dibandingkan dengan transaksi yang menghasilkan kerugian (losing trades) (Master Trust Research, 2024). Rumus win rate adalah

$$\text{Win Rate (\%)} = \left(\frac{\text{Jumlah Transaksi Profit}}{\text{Total Transaksi}} \right) \times 100\% \quad (2.8.2.1)$$

Sebagai contoh, jika dari 100 transaksi, 60 menghasilkan profit, maka win rate adalah 60% (LuxAlgo Research Team, 2025).

Win rate yang tinggi menunjukkan bahwa strategi memiliki akurasi yang baik dalam mengidentifikasi arah pergerakan pasar. Namun, win rate saja tidak cukup untuk mengevaluasi keandalan strategi, karena strategi dengan win rate 40% pun bisa menguntungkan jika setiap transaksi yang profit memiliki profit yang besar dan setiap transaksi yang loss memiliki loss yang kecil (LuxAlgo Research Team, 2025).

b) Risk Reward Ratio



Gambar 2.8.2.1. Risk-Reward Ratio 1:1, 1:2, 1:3

Risk Reward Ratio (RRR) adalah perbandingan antara potensi kerugian (risk) dan potensi keuntungan (reward) dalam setiap transaksi (LuxAlgo Research Team, 2025). Rumus RRR adalah: $RRR = (\text{Take Profit} - \text{Entry}) / (\text{Entry} - \text{Stop Loss})$.

$$RRR = \frac{(\text{Take Profit} - \text{Entry})}{(\text{Entry} - \text{Stop Loss})} \quad (2.8.2.2)$$

di mana:

- Entry: Harga saat mulai membeli.
- Take Profit (TP): Target harga untuk mengambil untung.
- Stop Loss (SL): Batas harga untuk menghentikan kerugian.

- RRR: Perbandingan antara besarnya risiko dan besarnya target profit.

Sebagai contoh, jika entry pada harga 1000, stop loss di 950 (risk 50 points), dan take profit di 1100 (reward 100 points), maka RRR adalah 1:2 (LuxAlgo Research Team, 2025).

RRR yang sehat (minimal 1:2) sangat penting karena memungkinkan strategi untuk tetap profitable meskipun win rate rendah. Sebagai ilustrasi, strategi dengan RRR 1:2 hanya perlu win rate 33.33% untuk mencapai breakeven, karena keuntungan dari transaksi yang profit akan mengkompensasi kerugian dari transaksi yang loss (LuxAlgo Research Team, 2025).

Penelitian Sharma dan Patel (2023) dalam Academia.edu menganalisis hubungan antara risk reward ratio dan win rate percentage trading system, menemukan bahwa terdapat hubungan langsung antara keduanya dan secara matematis risk reward ratio optimal dapat diturunkan dalam kaitannya dengan win rate percentage trading system yang dipilih.

c) Akurasi Prediksi Pembalikan Harga

Akurasi prediksi pembalikan harga (price reversal prediction accuracy) adalah metrik yang mengukur tingkat akurasi model dalam memprediksi kapan harga akan berbalik arah, baik dari downtrend ke uptrend (bounce di support) atau dari uptrend ke downtrend (rejection di resistance) (Mehra et al., 2024).

Dalam konteks backtesting strategi support dan resistance, akurasi prediksi pembalikan harga mengukur persentase dari situasi di mana harga menyentuh zona support atau resistance dan kemudian mengalami pembalikan sesuai dengan ekspektasi strategi (Letteri et al., 2023). Rumus akurasi adalah: Akurasi (%) = (Jumlah Prediksi Benar / Total Prediksi) × 100%.

$$Akurasi (\%) = \left(\frac{Jumlah\ Prediksi\ Benar}{Total\ Prediksi} \right) \times 100\% \quad (2.8.2.3)$$

Akurasi yang tinggi menunjukkan bahwa zona-zona support dan resistance yang diidentifikasi oleh model memiliki validitas yang kuat dalam memprediksi perilaku pasar (Dhakal, 2024).

Dalam penelitian Dhakal (2024), model hibrida yang menggabungkan K-Means clustering dengan multi-indicator strategies menunjukkan peningkatan akurasi prediksi pembalikan harga, memberikan validasi bahwa kombinasi metode machine learning dengan analisis teknikal tradisional dapat meningkatkan keandalan prediksi dibandingkan dengan metode tunggal.

2.8.3. Validasi Out-of-Sampe Testing

Validasi out-of-sample testing adalah proses pengujian model pada data yang belum pernah dilihat untuk mengevaluasi generalisasi dan robustness model (Letteri et al., 2023). Dalam praktik machine learning, dataset dibagi menjadi in-sample (training) dan out-of-sample (testing) untuk evaluasi performa (Dhakal, 2024).

Out-of-sample testing penting untuk mendeteksi overfitting, yaitu kondisi ketika model sangat baik pada training data namun buruk pada data baru (Letteri et al., 2023). Penelitian Mehra et al. (2024) melakukan backtesting dengan memisahkan historical data untuk training dan testing serta melakukan paper trading dalam real-time market conditions.


Dalam penelitian ini, dataset 6 tahun dibagi menjadi 4 tahun training dan 2 tahun testing untuk mengevaluasi performa backtesting pada data yang tidak terlihat selama pengembangan model K-Means (Dhakal, 2024). Fahros et al. (2025) melakukan testing pada timeframe H1 dan H4 serta menemukan hasil backtesting yang positif, menunjukkan indikasi realistis performa model pada data real-time di masa depan.

BAB III

METODOLOGI PENELITIAN

3.1. Desain Penelitian

Penelitian ini menggunakan pendekatan kuantitatif yang bertujuan untuk menjelaskan dan menguji efektivitas model hibrida berbasis K-Means Clustering dalam mengidentifikasi zona support dan resistance pada saham sektor energi di Bursa Efek Indonesia (BEI). Pendekatan kuantitatif dipilih karena penelitian ini berfokus pada pengolahan data numerik berupa harga historis saham serta evaluasi kinerja model secara objektif menggunakan metrik statistik. Gambar 3.1.1 mengilustrasikan alur penelitian secara komprehensif, yang akan dijelaskan detail teknisnya pada subpoin berikutnya.



Gambar 3.1.1. Kerangka Penelitian

Penelitian ini menggunakan pendekatan kuantitatif yang terdiri dari tujuh tahapan utama, berikut penjelasannya:

- **Input Data**

Tahap awal penelitian dimulai dengan pengumpulan data historis OHLCV (Open, High, Low, Close, Volume) saham sektor energi

IDX selama enam tahun. Data ini menjadi dasar analisis karena mencerminkan dinamika pergerakan harga dan aktivitas pasar secara menyeluruh. Data OHLCV merupakan format standar yang umum digunakan dalam analisis teknikal untuk mengidentifikasi perilaku harga dan pola pasar studi kasus.

- Splitting Data

Data historis dibagi menjadi dua yaitu, Data in-sample (training) selama 4 tahun Data out-of-sample (testing) selama 2 tahun. Pembagian ini bertujuan untuk menguji kemampuan generalisasi model dan menghindari overfitting melalui proses backtesting algoritmik studi kasus.

- Deteksi Pivot Points

Selanjutnya dilakukan deteksi pivot high dan pivot low menggunakan metode swing dengan parameter order = 2, di mana sebuah pivot ditentukan jika harga lebih tinggi atau lebih rendah dibandingkan dua hari di kiri dan kanan. Pendekatan ini mengacu pada indikator Pivots and Swings yang umum digunakan dalam analisis teknikal untuk mendeteksi titik pembalikan harga jangka pendek studi kasus. Menurut Fidelity Investments, nilai order yang lebih kecil membuat pivot lebih sensitif terhadap perubahan harga, sementara nilai yang lebih besar menghasilkan pivot yang lebih signifikan namun jarang muncul studi kasus.

- Filtering Support dan Resistance

Pivot yang telah terdeteksi kemudian diklasifikasikan berdasarkan harga penutupan terakhir (current price): Pivot low di bawah harga saat ini di inisialisasi menjadi Support, Pivot high di atas harga saat ini inisialisasi menjadi Resistance. Pendekatan ini sejalan dengan definisi support dan resistance dalam analisis teknikal yang menyatakan bahwa support berada di bawah harga saat ini dan resistance berada di atasnya, masing-masing berpotensi menjadi area pembalikan harga.

- Standarisasi Data (Z-Score Normalization)

Nilai level support dan resistance yang telah difilter kemudian dinormalisasi menggunakan Z-score normalization. Tahap ini penting karena algoritma K-Means menggunakan Euclidean distance yang sensitif terhadap skala data. Tanpa normalisasi, level harga dengan nilai lebih besar akan mendominasi proses clustering. Z-score normalization mengubah data ke skala yang seragam dengan mempertimbangkan rata-rata dan standar deviasi, sehingga mempercepat konvergensi dan meningkatkan stabilitas algoritma clustering studi kasus. Praktik ini didukung oleh literatur machine learning yang menekankan pentingnya standarisasi dalam algoritma berbasis jarak (Hastie et al., 2009).

- K-Means Clustering

Pada tahap ini, level-level support dan resistance yang telah distandarisasi dikelompokkan menggunakan K-Means clustering. Tujuan utama clustering adalah mengurangi noise dari terlalu banyak level harga, mengelompokkan level yang berdekatan menjadi zona harga, mengidentifikasi area price action yang signifikan. Setiap cluster menghasilkan satu zona support atau resistance yang memiliki batas minimum, maksimum, centroid, dan kekuatan (strength) berdasarkan jumlah sentuhan harga (touch count).

- Scoring Zona Support dan Resistance

Zona hasil clustering selanjutnya diberi skor kuantitatif untuk menentukan tingkat kepentingannya. Skor dihitung berdasarkan dua faktor utama yaitu kedekatan zona terhadap harga saat ini (proximity), kekuatan zona (jumlah sentuhan harga). Zona yang lebih dekat dengan harga dan memiliki lebih banyak sentuhan akan memperoleh skor lebih tinggi, sehingga dianggap lebih relevan dan kuat sebagai area support atau resistance.

- Dataset dan Training

Hasil scoring menghasilkan dataset zona support dan resistance yang telah terurut berdasarkan tingkat kepentingannya. Dataset ini kemudian digunakan dalam proses training dan backtesting algoritmik untuk mengevaluasi konsistensi dan efektivitas model dalam kondisi historis yang berbeda.


- **Evaluasi dan Output**

Tahap akhir adalah evaluasi performa model, yang dilakukan dengan mengamati akurasi zona terhadap pergerakan harga historis, dan konsistensi zona pada data out-of-sample. Hasil evaluasi kemudian dianalisis dan disajikan dalam bentuk kesimpulan dan laporan penelitian. Output akhir penelitian ini berupa zona support dan resistance yang bersifat objektif, adaptif, dan dapat direplikasi, sehingga mengurangi subjektivitas yang sering muncul pada metode manual/visual.

3.2. Data Penelitian

Data yang digunakan dalam penelitian ini berupa data historis harga saham harian (daily timeframe) emiten sektor energi yang tercatat di Bursa Efek Indonesia (BEI). Data historis tersebut mencakup harga Open, High, Low, Close, dan Volume (OHLCV) untuk setiap hari perdagangan selama periode enam tahun, sehingga mampu merepresentasikan dinamika pergerakan harga yang lengkap beserta volatilitas yang terjadi pada sektor energi.

3.2.1. Sumber dan Jenis Data



Gambar 3.2.1.1. Alur Pengambilan Data

Data harga historis saham sektor energi diperoleh dari sumber data pasar modal yang kredibel yaitu Yahoo Finance dengan satuan waktu harian (daily).

Pemilihan BEI dan sektor energi didasarkan pada karakteristik volatilitas yang tinggi dan sensitivitas terhadap faktor makroekonomi, sehingga cocok untuk pengujian model identifikasi support dan resistance berbasis machine learning.

Penelitian ini menggunakan data sekunder berupa deret waktu (time series) harga saham, yang terdiri atas komponen OHLCV: Open, High, Low, Close, dan Volume untuk setiap emiten sektor energi yang menjadi objek penelitian.

3.2.2. Sampel Data

Sampel data dalam penelitian ini adalah saham-saham sektor energi (minyak, gas, dan batubara) yang tercatat dan aktif diperdagangkan di BEI selama periode observasi enam tahun terakhir.

Pemilihan sampel emiten dilakukan secara purposive dengan kriteria memiliki data historis harian yang lengkap selama enam tahun, likuiditas perdagangan yang memadai, serta merepresentasikan subsektor utama energi di Indonesia.

Open	High	Low	Close	Volume
BUMI.JK	BUMI.JK	BUMI.JK	BUMI.JK	BUMI.JK
200.00	208.00	196.00	200.00	184584700
202.00	204.00	199.00	200.00	134887400
197.00	197.00	188.00	188.00	313094100
190.00	192.00	188.00	190.00	127967600
191.00	193.00	177.00	178.00	403244100
180.00	183.00	178.00	179.00	162345700
181.00	190.00	181.00	182.00	316954100
183.00	184.00	176.00	177.00	197461700
177.00	181.00	176.00	177.00	105658800
178.00	179.00	174.00	174.00	75732000
175.00	175.00	170.00	170.00	161644200
170.00	174.00	170.00	173.00	178806600
170.00	173.00	168.00	172.00	100567900
172.00	177.00	172.00	172.00	159507300
172.00	173.00	165.00	167.00	101725200
166.00	167.00	162.00	164.00	114676000
165.00	171.00	164.00	169.00	145131500
169.00	171.00	167.00	167.00	70492500
167.00	169.00	165.00	165.00	79813600
165.00	169.00	164.00	165.00	76428200

Gambar 3.2.2.1. Sampel Data

Gambar 3.2.2.1 menunjukkan contoh tampilan sampel data historis saham harian emiten sektor energi di BEI, dalam hal ini saham dengan ticker BUMI.JK. Setiap baris merepresentasikan satu hari perdagangan dengan lima kolom utama, yaitu harga pembukaan (Open), harga tertinggi (High), harga terendah (Low), harga penutupan (Close), dan volume transaksi (Volume) yang seluruhnya berskala harian. Struktur seperti ini menggambarkan bagaimana data OHLCV riil yang diambil dari Bursa Efek Indonesia disusun sebelum diolah lebih lanjut.

3.3. Prosedur Penelitian

Prosedur penelitian ini diawali dengan pengumpulan data harga historis saham sektor energi IDX (OHLCV) timeframe harian selama 6 tahun, dilanjutkan dengan pra-pemrosesan data, deteksi pivot high dan pivot low, filtering pivot menjadi kandidat level support dan resistance berdasarkan posisi terhadap harga penutupan saat ini, standardisasi Z-score, pengelompokan level-level tersebut menggunakan algoritma K-Means clustering untuk membentuk zona harga,

perhitungan skor zona berbasis kedekatan dan kekuatan historis, dan diakhiri dengan pembagian data menjadi set training dan testing untuk kemudian dievaluasi menggunakan algorithmic backtesting guna mengukur efektivitas zona support dan resistance yang dihasilkan.


3.3.1. Data Splitting

Pada tahap data splitting, data historis yang telah diproses dibagi menjadi dua bagian, yaitu data training dan data testing, untuk memastikan proses evaluasi model dilakukan secara out-of-sample dan menghindari overfitting. Pembagian data dilakukan berdasarkan urutan waktu karena data harga saham bersifat time series sehingga tidak dilakukan pengacakan (shuffling).

Proporsi pembagian data dalam penelitian ini adalah 67% untuk data training dan 33% untuk data testing:

- Data training (67%) digunakan untuk menjalankan seluruh pipeline model hibrida, mulai dari deteksi pivot, filtering kontekstual, standardisasi Z-score, penerapan K-Means clustering, pembentukan zona harga, hingga perhitungan skor zona support dan resistance.
- Data testing (33%) digunakan sebagai periode out-of-sample untuk melakukan algorithmic backtesting, yaitu menguji seberapa efektif zona support dan resistance yang dihasilkan pada data yang belum pernah “dilihat” model pada saat proses pembentukan zona.

3.3.2. Deteksi Pivot Point




Gambar 3.3.2.1. Alur Deteksi Pivot Point

Tahap deteksi pivot point digunakan untuk mengidentifikasi titik pembalikan lokal pada deret harga yang nantinya menjadi kandidat level support dan resistance. Gambar 3.3.2.1 menunjukkan bahwa proses dimulai dari pengambilan data training, penetapan parameter orde $n = 2$, dan perhitungan jumlah bar data. Setiap bar ke- i kemudian dievaluasi secara berurutan dengan membandingkan harga high dan low terhadap dua bar sebelumnya dan dua bar sesudahnya; titik ke- i dinyatakan sebagai pivot high jika high-nya lebih besar dari high $i-1$, $i-2$, $i+1$, dan $i+2$, sedangkan dinyatakan sebagai pivot low jika low-nya lebih kecil dari low $i-1$, $i-2$, $i+1$, dan $i+2$.

Setiap indeks yang lolos kriteria disimpan ke dalam daftar data pivot untuk diproses pada tahap filtering berikutnya, sementara indeks lain dilewati dan iterasi dilanjutkan ke $i+1$ sampai seluruh data training habis. Dengan alur ini, deteksi pivot point berjalan secara otomatis dan konsisten mengikuti definisi pivot orde 2, sehingga menggantikan proses penentuan titik balik harga yang biasanya dilakukan secara visual dan subjektif di grafik harga.

3.3.3. Filtering




Gambar 3.3.3.1. Alur Filtering

Tahap filtering digunakan untuk mengklasifikasikan setiap pivot yang telah terdeteksi menjadi kandidat zona support atau resistance berdasarkan posisi relatifnya terhadap harga saat ini. Flowchart pada Gambar 3.3.3.1 memperlihatkan bahwa proses diawali dengan pengambilan nilai current price dari harga penutupan (close) bar terakhir, kemudian dihitung jumlah data pivot dan algoritma membaca pivot ke-I satu per satu. Jika indeks i belum mencapai akhir data, sistem membandingkan nilai pivot dengan current price apabila pivot lebih kecil dari current price, maka pivot tersebut diberi label sebagai support, sebaliknya jika pivot lebih besar dari current price, pivot diklasifikasikan sebagai resistance.

Setiap pivot yang sudah diberi label support atau resistance kemudian disimpan ke dalam struktur data hasil filter (filter result), hingga seluruh data di filtering.

3.3.4. Standarisasi Data




Gambar 3.3.4.1. Alur Standarisasi Data

Flowchart pada Gambar 3.3.4.1 menggambarkan proses standarisasi data level support dan resistance hasil filtering menggunakan metode Z-Score Normalization. Tahap ini diawali dengan menghitung jumlah data filter result (n), kemudian algoritma melakukan iterasi pertama untuk menghitung mean μ setiap nilai level pada data filter result ke-i dijumlahkan, lalu setelah indeks Ke-i mencapai n, total tersebut dibagi dengan nilai n sehingga diperoleh rata-rata μ . Setelah mean diperoleh, lalu mencari standar deviasi, data filter result kembali dibaca dari awal, tiap nilai dihitung selisihnya terhadap μ , dikuadratkan menjadi $(i - \mu)^2$, kemudian hasil dari itu disimpan sebagai σ .

Kemudian proses standarisasi, data filter result ke-i dibaca lagi satu per satu, lalu setiap nilai dikonversi menjadi skor baku dengan rumus $\frac{(i - \mu)}{\sigma}$. Nilai hasil transformasi tersebut disimpan sebagai data baru $Z(i)$ dan iterasi dilanjutkan hingga seluruh data mencapai indeks n (total data), sehingga seluruh level harga kini berada pada skala standar dengan rata-rata nol dan

deviasi baku satu. Dengan demikian, keluaran tahap ini adalah deret level support dan resistance yang sudah terstandarisasi, siap digunakan sebagai input K-Means sehingga pengelompokan tidak lagi bias terhadap perbedaan skala nominal harga antar level.

3.3.5. K-Means Clustering




Gambar 3.3.5.1. Alur K-Means Clustering

Tahap K-Means clustering digunakan untuk mengelompokkan level harga yang sudah distandarisasi (data z) ke dalam beberapa cluster yang merepresentasikan konsentrasi harga tertentu. Flowchart pada Gambar 3.3.5.1 memperlihatkan bahwa proses dimulai dengan menentukan jumlah cluster k serta inisialisasi centroid awal $c1 = z(1)$ dan $c2 = z(2)$ untuk kasus $k=2$. Selanjutnya, dihitung jumlah data z sebesar n, lalu algoritma membaca setiap data z ke-i dan melakukan tahap assignment setiap titik dibandingkan jaraknya terhadap masing-masing centroid, kemudian dimasukkan ke cluster dengan jarak terkecil sampai seluruh data z selesai diproses.

Setelah assignment, algoritma masuk ke tahap update centroid. Setiap cluster dihitung jumlah anggotanya (y) dan nilai rata-rata titik di dalam cluster tersebut, lalu dihasilkan centroid baru $c_{new} = \frac{\text{nilai cluster}}{y}$. Proses assignment dan update centroid ini diulang iteratif sampai komposisi cluster stabil atau perubahan centroid sudah sangat kecil. Pada akhir tahap, dari setiap cluster diperoleh nilai minimum, maksimum, dan centroid c_{new} yang kemudian disimpan sebagai data zona; nilai min–max akan menjadi batas zona harga, sedangkan centroid mewakili titik tengah statistik zona tersebut yang digunakan pada tahap konversi zona dan scoring selanjutnya.

3.3.6. Zone Scoring



Gambar 3.3.6.1. Alur Scoring Zona

Tahap zone scoring digunakan untuk memberikan nilai kuantitatif pada setiap zona support dan resistance yang dihasilkan dari proses clustering berdasarkan kedekatan dengan nilai current price serta touched (berapa kali zona tersebut tersentuh). Flowchart pada Gambar 3.3.6.1 menunjukkan bahwa proses dimulai dengan mengambil data zona,

menentukan batas zona sebagai nilai min dari setiap cluster, lalu menghitung jumlah data zona n . Selanjutnya sistem melakukan iterasi untuk setiap zona ke- i , dihitung jarak antara batas zona dan current price, kemudian jarak tersebut dinormalisasi dengan membaginya terhadap current price sehingga diperoleh nilai normalisasi sebagai ukuran jarak relatif zona terhadap harga berjalan.

3.4. Evaluasi Model

Evaluasi model dilakukan untuk menilai sejauh mana algoritma hibrida enam tahap mampu menghasilkan zona support dan resistance yang benar-benar berguna dalam pengambilan keputusan trading. Proses evaluasi tidak hanya berhenti pada kualitas teknis clustering, tetapi dilanjutkan dengan pengujian empiris melalui backtesting algoritmik pada data historis out-of-sample, sehingga performa model dapat diukur secara kuantitatif dalam konteks kondisi pasar nyata pada saham sektor energi BEI.

3.4.1. Backtesting Algorithmic

Backtesting algoritmik digunakan sebagai kerangka untuk menguji performa zona support dan resistance yang dihasilkan model ketika diterapkan sebagai dasar keputusan entry dan exit di pasar. Seluruh aturan trading didefinisikan secara sistematis: kapan masuk posisi, kapan keluar, serta bagaimana penempatan target profit dan stop loss, sehingga hasil backtest dapat direplikasi dan tidak bergantung pada intuisi subyektif peneliti.

Skenario backtesting yang digunakan adalah Sinyal buy muncul ketika harga menyentuh atau memasuki zona support dengan skor tertinggi, dengan asumsi zona tersebut berpotensi menahan penurunan harga dan memicu pembalikan naik. Kemudian sinyal sell muncul ketika harga menyentuh zona resistance ber-skor tinggi yang diperkirakan menjadi area penahanan kenaikan harga.

Exit posisi dilakukan dengan dua mekanisme yaitu Take profit ketika harga mencapai zona lawan berikutnya (support untuk posisi jual, resistance untuk posisi beli). Kemudian stop loss ketika harga menembus batas zona (Max untuk support, Min untuk resistance) sebagai indikasi bahwa zona gagal menahan pergerakan harga.

Backtesting dijalankan pada beberapa saham sektor energi dan pada berbagai periode waktu untuk melihat konsistensi kinerja model. Hasil backtesting kemudian direkap dalam bentuk statistik dan tabel performa sehingga dapat dibandingkan dengan pendekatan konvensional atau baseline sederhana.

3.4.2. Metrik Evaluasi Performa

Untuk menilai kualitas model secara kuantitatif, penelitian ini menggunakan beberapa metrik performa utama yang lazim dalam evaluasi strategi trading algoritmik. Metrik-metrik tersebut tidak hanya mengukur tingkat keuntungan, tetapi juga aspek risiko dan akurasi sinyal yang dihasilkan zona support dan resistance.

Metrik yang digunakan antara lain:

- Win rate

Win rate didefinisikan sebagai persentase jumlah transaksi yang menghasilkan profit dibandingkan total transaksi pada periode pengujian. Metrik ini menunjukkan seberapa sering zona SR yang dihasilkan model mampu memprediksi pembalikan harga dengan benar ketika harga menyentuh zona tersebut.

- Risk-Reward Ratio

Risk-reward ratio mengukur perbandingan rata-rata keuntungan per transaksi terhadap rata-rata kerugian per transaksi. Nilai risk-reward ratio yang lebih besar dari satu menunjukkan bahwa ketika model benar, keuntungan yang diperoleh secara rata-rata lebih besar daripada kerugian ketika model salah, sehingga strategi tetap menarik meskipun win rate tidak sangat tinggi.

- Akurasi Prediksi Pembalikan Harga

Akurasi ini menghitung proporsi kasus di mana harga benar-benar berbalik arah setelah menyentuh zona support atau resistance dibandingkan seluruh sentuhan zona yang terjadi. Metrik ini lebih fokus pada kualitas zona sebagai “area reaksi harga” daripada pada hasil finansial akhir, sehingga membantu menilai apakah K-Means dan mekanisme scoring berhasil menemukan zona harga yang memang signifikan secara price action.

DAFTAR PUSTAKA

- Akhtar, N., & Raza, A. (2024). Machine Learning Dynamic Support and Resistance by AlgoAlpha.
- Almuqati, K., et al. (2023). Artificial Intelligence in Financial Analysis.
- Ardiansyah, R., et al. (2025). Pengujian Indikator Teknikal pada Harga Saham Perbankan di Indonesia.
- Asma Awan, S., et al. (2023). The Macroeconomic Determinants of Stock Price Volatility in Pakistan: An Empirical Investigation.
- Bathia, R., et al. (2024). Advanced Backtesting Strategy in Financial Market.
- Dhakal, S. (2024). An Algorithmic Trading Approach: Merging Machine Learning With Multi-Indicator Strategies for Optimal Performance.
- Fahros, M., et al. (2025). Evaluasi Performa Backtesting Trading Saham Sektor Energi di BEI.
- Ghanem, Y. (2024). Behavioral Bias in Technical Analysis: Evidence from Emerging Markets.
- Hasanah, U., & Syarif, F. (2023). Volatility, FPI, and Macroeconomic Impact on Energy Sharia Stocks.
- Irawan, F., et al. (2025). Validation Techniques for K-Means Clustering in Financial Segmentation.
- Katifa, S., et al. (2025). Regulasi dan Mekanisme Pasar Modal di Indonesia.
- Kim, D., et al. (2025). Effects of Data Normalization in Machine Learning for Financial Analysis.
- Kusmini, S., & Wibowo, A. (2025). Market Uncertainty and Asymmetric Information in Indonesian Energy Sector 2021-2024.
- Letteri, I., et al. (2023). Backtesting Trading Strategies: Application on Historical Market Data.
- Luis, A., & Elisabete, V. (2023). Technical Analysis, Fundamental Analysis, and Ichimoku Dynamics: A Bibliometric Analysis.
- LuxAlgo Research Team. (2025). Risk Reward Ratio and Win Rate in Algorithmic Trading.
- Master Trust Research Team. (2024). Measuring the Win Rate in Trading Systems.
- Mehra, P., et al. (2024). Real-Time Paper Trading Backtesting Strategies.
- Octavia, S., et al. (2022). Pengaruh Nilai Tukar dan Suku Bunga terhadap Harga Saham Sektor Energi.
- Öztürk, C. (2024). Market Analysis with K-Means Clustering Algorithm: Identifying Support and Resistance Levels.
- Pasaribu, P., & Wibowo, A. (2025). Implementasi FCA dalam Saham BEI dan Dampak Volatilitas.

- Pinheiro, F., et al. (2025). Data Scaling Impact in Unsupervised Learning: Financial Market Applications.
- Ramadhan, T., & Kusuma, R. (2025). Segmentasi Saham IDX Berdasarkan Kriteria Fundamental dan Teknikal.
- Sakinah, A., et al. (2024). Kapitalisasi dan Volatilitas Sektor Energi BEI.
- Sarjan, S., et al. (2025). Kapitalisasi Pasar dan Regulasi Bursa Efek Indonesia.
- Sertifikasiku. (2024). Konsep Dasar Analisis Teknikal dan Supporting Evidence.
- Setiawan, B., & Wijaya, O. (2024). Dasar-Dasar Support dan Resistance dalam Analisis Teknikal.
- Siregar, T., et al. (2024). Machine Learning for Financial Clustering in Indonesia Stock Exchange.
- Sharma, P., & Patel, V. (2023). Risk-Reward Mathematical Relations in Trading Systems.
- Trading Strategy Guides. (2024). Pivot Points and Objective Calculation in Technical Analysis.
- Tri Wahyudi, F., et al. (2025). Impact of Global Oil Price Shocks on Energy Stocks: Short-Term and Long-Term Analysis.
- TDS Editorial. (2021). Fundamental Review of Support-Resistance Drawing Techniques.
- Tyas, F. K. (2025). Analisis Fluktuasi Harga Saham Sektor Energi di Bursa Efek Indonesia.
- Ultra Trader Research. (2025). Classical Pivot Calculation and Alternative Formulas.
- Wijaya, O. (2025). Trends and History Repetition in Technical Analysis.
- Wongoutong, C. (2024). Impact of Feature Scaling on K-Means Clustering Performance for Features with Different Units.
- Yakovyna, T., et al. (2024). Adaptive Machine Learning for Stock Predictive Modelling.
- Ztrk, C. (2024). Market Analysis with K-Means Clustering Algorithm Identifying Support and Resistance Levels.
- Ahir, H., Bloom, N., & Furceri, D. (2020). The World Uncertainty Index. *Finance & Development*, 57(1), 38–41.
- Souffargi, N. (2024). Impact of political uncertainty on stock market returns. *Cogent Economics & Finance*, 12(1), 2324525.
- Prihandono, I. (2023). Regulatory capture in energy sector: Evidence from Indonesia's coal-fired power plant industry. *International Journal of Emerging Markets*, 18(6), 1400–1420.

Saputra, A. D. (2023). Geopolitical risk & Indonesian stock market response. *Equity Governance Journal*, 6(2), 93–105.