

**PENERAPAN METODE *LIGHTGBM* UNTUK
PREDIKSI HARGA *CARDANO* DENGAN PENGARUH
*OVERFITTING***

SKRIPSI



Oleh :

AHMAD RIDHO AL FITRI

152018005

**PROGRAM STUDI INFORMATIKA
FAKULTAS TEKNOLOGI INDUSTRI
INSTITUT TEKNOLOGI NASIONAL
BANDUNG
2025**

**PENERAPAN METODE *LIGHTGBM* UNTUK
PREDIKSI HARGA *CARDANO* DENGAN PENGARUH
*OVERFITTING***

SKRIPSI

**Diajukan sebagai salah satu syarat untuk memperoleh gelar
Sarjana**



Oleh :

AHMAD RIDHO AL FITRI

152018005

**PROGRAM STUDI INFORMATIKA
FAKULTAS TEKNOLOGI INDUSTRI
INSTITUT TEKNOLOGI NASIONAL
BANDUNG
2025**



**INSTITUT TEKNOLOGI NASIONAL
FAKULTAS TEKNOLOGI INDUSTRI**

Jl. PKH. Hasan Mustapa No. 23 Bandung 40124
Telepon: +62 22 – 7272215, Fax: +62 22 – 7202892
Website: www.itenas.ac.id

FORMULIR PERNYATAAN ORISINALITAS

Saya yang bertandatangan dibawah ini:

Nama : Ahmad Ridho Al Fitri

NIM : 15-2018-005

Menyatakan dengan sesungguhnya bahwa

Judul Skripsi :

**“Penerapan Metode LightGBM Untuk Prediksi Harga Cardano Dengan Pengaruh
Overfitting”**

sepenuhnya adalah merupakan karya sendiri, tidak ada bagian di dalamnya yang merupakan plagiat dari karya orang lain dan saya tidak melakukan penjiplakan atau pengutipan dengan cara-cara yang tidak sesuai dengan etika keilmuan yang berlaku dalam masyarakat keilmuan.

Apabila dikemudian hari ditemukan adanya pelanggaran terhadap etika keilmuan dalam karya saya ini, atau klaim dari pihak lain terhadap keaslian karya ini, saya siap menerima sanksi sesuai dengan hukum yang berlaku.

Bandung, 23 Juli 2025



Ahmad Ridho Al Fitri



IF-TA.20242.152018005.04

PROGRAM STUDI INFORMATIKA

LEMBAR PENGESAHAN

LAPORAN TUGAS AKHIR

PENERAPAN METODE LIGHTGBM UNTUK PREDIKSI HARGA CARDANO DENGAN PENGARUH OVERFITTING



Yang dipersiapkan dan disusun oleh
Ahmad Ridho Al Fitri
15-2018-005

Telah dipertahankan di depan Dewan Penguji
Pada tanggal **1 Agustus 2025**

Susunan Dewan Penguji

Dosen Pembimbing

Marisa Premitasari, S.T., M.T
NPP. 120141103

Disetujui Oleh :

Dosen Penguji I

Milda Gustiana Husada, S.T., M.Eng.
NPP. 120070802

Dosen Penguji II

Chalifa Chazar, ST., MT.
NPP. 120240203

Laporan tugas akhir ini telah diterima sebagai salah satu persyaratan
untuk memenuhi matakuliah tugas akhir
Tanggal **04 Agustus 2025**

Ketua Program Studi Informatika

Lisa Kristiana, S.T., M.T. PhD
NPP. 120070301

Kata Pengantar

Assalamu'alaikum Wr. Wb.

Puji dan syukur kehadiran Allah SWT atas segala limpahan rahmat dan karunia-Nya, sehingga penulis dapat menyelesaikan laporan tugas akhir ini. Penulisan laporan ini disusun untuk memenuhi salah satu syarat dalam meraih gelar Sarjana Informatika pada Fakultas Teknologi Industri, Institut Teknologi Nasional Bandung.

Penelitian ini memiliki relevansi yang penting dalam pengembangan metode *machine learning*, khususnya dalam konteks prediksi harga *cryptocurrency* menggunakan algoritma *LightGBM*.

Penelitian ini diharapkan dapat memberikan kontribusi signifikan baik dalam dunia akademik maupun industri, terutama di bidang teknologi finansial, dengan mengembangkan metode prediksi harga *cryptocurrency* yang lebih akurat dan efisien.

Dalam pembuatan dan penyusunan Laporan Tugas Akhir ini, Penyusun mendapat banyak bimbingan, dukungan dan saran dari beberapa pihak. Maka dari itu, Saya mengucapkan banyak terima kasih kepada:

1. Kedua orang tua Bapak Harmain dan Ibu Risdiana yang telah memberikan banyak dukungan dalam melaksanakan dan menyelesaikan laporan ini.
2. Ibu Marisa Premitasari, ST., M.T. selaku pembimbing Penelitian dan Tugas Akhir yang telah menyediakan waktu, tenaga, dan pikiran untuk mengarahkan saya dalam penyusunan laporan.
3. Teman-teman seperjuangan yang telah menemani serta memberikan dukungan dalam proses pembuatan laporan ini.

Penulisan Laporan Tugas Akhir ini masih jauh dari kata baik. Oleh karena itu, kritik dan saran yang membangun sangat diharapkan untuk perbaikan di masa mendatang.

Bandung, 11 Agustus 2025
Penulis



Ahmad Ridho Al Fitri
152018005

HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI UNTUK KEPENTINGAN AKADEMIS

Sebagai sivitas akademik Institut Teknologi Nasional Bandung, saya yang bertanda tangan di bawah ini:

Nama : Ahmad Ridho Al Fitri
NIM : 152018005
Program Studi : Informatika
Fakultas : Fakultas Teknologi Industri
Jenis karya : Skripsi

Demi pengembangan ilmu pengetahuan, menyetujui untuk memberikan kepada Institut Teknologi Nasional **Hak Bebas Royalti Noneksklusif (Non-exclusive Royalty- Free Right)** atas karya ilmiah saya yang berjudul:

PENERAPAN METODE LIGHTGBM UNTUK PREDIKSI HARGA CARDANO DENGAN PENGARUH OVERFITTING

beserta perangkat yang ada (jika diperlukan). Dengan Hak Bebas Royalti Noneksklusif ini Institut Teknologi Nasional berhak menyimpan, mengalihmedia/format-kan, mengelola dalam bentuk pangkalan data (*database*), merawat, dan memublikasikan skripsi saya selama tetap mencantumkan nama saya sebagai penulis/pencipta dan sebagai pemilik Hak Cipta.

Demikian pernyataan ini saya buat dengan sebenarnya.

Dibuat di : Itenas Bandung Pada tanggal : 11 Agustus 2025
Yang menyatakan



(Ahmad Ridho Al Fitri)

*Karya Ilmiah: karya akhir, makalah non seminar, laporan kerja praktek, laporan magang, karya profesi dan karya spesialis

ABSTRAK

Volatilitas harga aset kripto seperti Cardano menuntut adanya model prediksi yang akurat untuk membantu pengambilan keputusan. Penelitian ini menerapkan metode LightGBM dengan menganalisis pengaruh volume data dan optimasi hyperparameter. Model dibangun menggunakan data historis harian dengan rekayasa fitur lag (Price, Open, High, Low, Volume) dan diuji pada skenario pembagian data 80:20, 70:30, serta 60:40. Hasil menunjukkan performa prediksi tertinggi dicapai pada skenario 60:40 tanpa optimasi, dengan nilai R-squared (R^2) 0.9609 dan MAPE 4.92% pada data uji. Studi ini menemukan bahwa optimasi hyperparameter hanya efektif pada dataset latih yang besar. Pada dataset yang lebih kecil, model standar yang lebih sederhana justru menunjukkan kemampuan generalisasi yang lebih baik. Dengan demikian, strategi optimasi harus disesuaikan dengan volume data untuk menghindari penurunan performa.

Kata kunci: *Prediksi Harga, Cardano, LightGBM, Overfitting, Time Series, Optimasi Hyperparameter.*

ABSTRACT

The volatility of crypto-asset prices such as Cardano necessitates accurate prediction models to support decision-making. This research applies the LightGBM method to predict the price of Cardano (ADA) by analyzing the influence of data volume and hyperparameter optimization. The model was built using historical daily data with lag feature engineering (Price, Open, High, Low, and Volume) and was evaluated on 80:20, 70:30, and 60:40 data split scenarios. The results show that the highest predictive performance was unexpectedly achieved in the 60:40 scenario without optimization, yielding an R-squared (R^2) value of 0.9609 and a MAPE of 4.92% on the test data. This study found that hyperparameter optimization was only effective on larger training datasets. On smaller datasets, a simpler standard model demonstrated better generalization capabilities. Thus, the optimization strategy must be carefully calibrated according to the dataset volume to avoid performance degradation.

Keywords: Price Prediction, Cardano, LightGBM, Overfitting, Time Series, Hyperparameter Optimization.

DAFTAR ISI

Kata Pengantar	5
DAFTAR ISI	9
DAFTAR TABEL	11
DAFTAR GAMBAR.....	12
BAB I PENDAHULUAN	13
1.1. Latar belakang	13
1.2. Rumusan Masalah	15
1.3. Tujuan Penelitian.....	16
1.4. Ruang Lingkup.....	16
1.5. Manfaat Penelitian.....	17
BAB II TINJAUAN PUSTAKA.....	18
2.1. Tinjauan Pustaka	18
2.2. <i>Cryptocurrency</i>	21
2.3. Cardano	22
2.4. <i>Machine learning</i> dalam prediksi harga <i>cryptocurrency</i>	24
2.5. Landasan Teori <i>Ensemble learning</i> , <i>Gradient boosting</i> , dan LightGBM.....	24
2.6. <i>Overfitting</i> dalam <i>Machine learning</i>	28
2.7. <i>Regresi</i> , <i>time series</i>	28
2.8. Optimasi Model <i>Machine learning</i>	29
BAB III METODOLOGI PENELITIAN	30
3.1. Flowchart System.....	30
3.2. Blok Diagram.....	32
3.3. Flowchart Preprocessing	33
3.4. Flowchart LightGBM.....	34
3.5. Dataset.....	36
3.6. Pra-pemrosesan	37
3.7. <i>Feature engineering</i>	38

3.8.	Pembagian Data	39
3.9.	Metode LightGBM.....	40
3.10.	Optimasi Hyperparameter dan Pelatihan Model.....	43
3.11.	Performa (Evaluasi Model).....	44
3.11.1.	MAE (Mean Absolute Error)	44
3.11.2.	Root Mean Squared Error (RMSE).....	45
3.11.3.	Mean Absolute Percentage (MAPE).....	45
3.11.4.	R-Squared (R²).....	46
3.12.	Analisis <i>Overfitting</i>	46
BAB IV HASIL DAN ANALISIS		48
4.1.	Hasil Optimasi Hyperparameter.....	48
4.1.1.	Visualisasi proses optimasi Hyperparameter	49
4.2.	Hasil Kinerja Model.....	50
4.3.	Hasil Evaluasi Model Proporsi 80:20	50
4.4.	Hasil Evaluasi Model Proporsi 70:30	50
4.5.	Hasil Evaluasi Model Proporsi 60:40	51
4.6.	Analisis Kepentingan Fitur	52
4.7.	Pembahasan.....	52
4.7.1.	Tahapan pembuktian overfitting melalui kurva pembelajaran ..	54
BAB V KESIMPULAN DAN SARAN		56
5.1.	Kesimpulan	56
5.2.	Saran	56
Daftar Pustaka.....		58

DAFTAR TABEL

Tabel 4. 1 Hasil optimasi hyperparameter	48
Tabel 4. 2 Hasil Evaluasi Model Dengan Optimasi Hyperparameter (80:20)	50
Tabel 4. 3Hasil Evaluasi Model Tanpa Optimasi Hyperparameter (80:20).....	50
Tabel 4. 4Hasil Evaluasi Model Dengan Optimasi Hyperparameter (70:30)	50
Tabel 4. 5 Hasil Evaluasi Model Tanpa Optimasi Hyperparameter (70:30).....	51
Tabel 4. 6 Hasil Evaluasi Model Dengan Optimasi Hyperparameter (60:40)	51
Tabel 4. 7 Hasil Evaluasi Model Tanpa Optimasi Hyperparameter (60:40).....	51

DAFTAR GAMBAR

Gambar 2. 1 Area Chart <i>Cardano</i> 2017-2024.....	23
Gambar 2. 2 Workflow of <i>LightGBM</i>	26
Gambar 3. 1 Flowchart System.....	30
Gambar 3. 2 Blok Diagram Alur kerja penelitian	32
Gambar 3. 3 Flowchart Preprocessing	33
Gambar 3. 4 Flowchart <i>LightGBM</i>	35
Gambar 3. 5 Historical data <i>Cardano</i>	37
Gambar 3. 6 <i>Feature engineering</i>	39
Gambar 3. 7 Pembagian data menjadi training dan testing set	40
Gambar 3. 8 Leaf-wise tree growth	41
Gambar 4. 1 Heatmap hasil validasi silang GridSearchCV	49
Gambar 4. 2 Tingkat Kepentingan Fitur <i>LightGBM</i>	52
Gambar 4. 3 Kurva pembelajaran model teroptimasi (Skenario 60:40)	54

BAB I PENDAHULUAN

Berikut adalah beberapa isi dari BAB I tentang pendahuluan yang berisi latar belakang, rumusan masalah, tujuan penelitian, ruang lingkup, dan manfaat penelitian.

1.1. Latar belakang

Cryptocurrency adalah bentuk aset digital yang menggunakan teknologi kriptografi untuk menjamin keamanan, desentralisasi, serta transparansi transaksi (Nakamoto, 2008). *Cardano* adalah salah satu contoh *cryptocurrency* generasi ketiga yang menggunakan pendekatan *proof-of-stake*. Pendekatan ini memungkinkan validator untuk memproses transaksi dan menambah blok baru berdasarkan jumlah koin yang dimiliki, yang mengarah pada peningkatan efisiensi dan penghematan energi dibandingkan dengan model *proof-of-stake* pada *cryptocurrency* lainnya seperti Bitcoin (Cardano Foundation, n.d.).

Cardano dipilih untuk penelitian ini karena beberapa alasan utama. Pertama, *Cardano* merupakan proyek blockchain generasi ketiga yang menggunakan *proof-of-stake*, menjadikannya unik di antara *cryptocurrency* lainnya. Kedua, pendekatan berbasis penelitian dan pengembangan berkelanjutan *Cardano* menciptakan dinamika pasar yang berbeda (Brown & Hoskinson, 2017). Ketiga, meskipun relatif baru, *Cardano* telah mencapai kapitalisasi pasar yang signifikan dan masuk dalam 10 besar *cryptocurrency* dunia (CoinMarketCap, 2023).

Dalam analisis harga historis *Cardano*, komponen utama yang digunakan mencakup Price (harga terkini), Open (harga pembukaan sesi perdagangan), High (harga tertinggi dalam sesi), Low (harga terendah), dan Volume (jumlah transaksi). Change% menunjukkan persentase perubahan harga dari sesi sebelumnya, sementara data fundamental seperti berita pasar dan perubahan kebijakan ekonomi memberikan konteks tambahan dalam analisis (Alessandretti et al., 2018).

Dengan meningkatnya kompleksitas pasar *Cardano*, kebutuhan akan model

prediksi yang handal dan mampu mengatasi *overfitting* menjadi semakin mendesak . Dalam memprediksi harga *cryptocurrency*, analisis *time series* memainkan peran penting, karena membantu mengidentifikasi pola dan tren dari data historis (Hyndman & Athanasopoulos, 2018). Untuk itu, LightGBM dipilih karena kemampuannya menangani data besar dan kompleks, serta kemampuannya mengurangi *overfitting* (Zhang & Guo, 2021).

LightGBM menggunakan teknik *histogram-based* learning, yang mengelompokkan data dalam bin untuk mempercepat pelatihan model, serta metode pengembangan pohon *leaf-wise* yang meningkatkan akurasi dengan meningkatkan cabang dengan keuntungan terbesar terlebih dahulu.

Penelitian sebelumnya menunjukkan bahwa algoritma Random Forest, yang merupakan bagian dari algoritma ensemble, telah efektif dalam memprediksi harga *cryptocurrency* seperti Bitcoin dengan akurasi tinggi (Chen et al., 2020). Sementara LightGBM, dengan keunggulannya, diharapkan dapat memberikan hasil yang lebih cepat dan akurat untuk memprediksi harga *Cardano*, mengingat data yang memiliki tingkat perubahan nilai yang tinggi dalam pasar *cryptocurrency*.

Studi yang dilakukan oleh Chen et al. (2020) menunjukkan bahwa Random Forest mampu memprediksi harga Bitcoin dengan akurasi hingga 97% dan Mean Absolute Error (MAE) sebesar 1.52%. MAE adalah metrik evaluasi yang mengukur rata-rata kesalahan prediksi dengan menghitung nilai absolut selisih antara nilai aktual dan prediksi. Nilai MAE yang lebih kecil menunjukkan bahwa model memiliki kualitas prediksi yang baik, karena kesalahan rata-ratanya rendah. Root Mean Square Error (RMSE) adalah metrik evaluasi dalam regresi yang mengukur rata-rata kesalahan prediksi. RMSE dihitung dengan mengambil akar kuadrat dari rata-rata kuadrat selisih antara nilai aktual dan nilai prediksi. Semakin kecil nilai RMSE, semakin baik performa model, karena menunjukkan prediksi yang lebih mendekati nilai aktual. Perbedaan utama antara MAE dan RMSE adalah sensitivitas terhadap outlier. MAE memberikan nilai rata-rata kesalahan tanpa memperhitungkan besar kecilnya kesalahan, sedangkan RMSE menekankan kesalahan yang lebih besar, membuatnya lebih berguna jika kesalahan besar dianggap lebih serius dalam evaluasi model.

Sebagai bagian dari keluarga algoritma *gradient boosting*, LightGBM memiliki beberapa keunggulan dibandingkan metode tradisional. Studi oleh Zhang et al. (2021) menunjukkan bahwa penggunaan LightGBM untuk memprediksi harga saham memberikan peningkatan akurasi hingga 5% lebih baik dibandingkan XGBoost, serta waktu komputasi yang 10 kali lebih cepat. Ini menjadi dasar untuk mengeksplorasi lebih lanjut penggunaannya dalam prediksi harga *cryptocurrency*, khususnya *Cardano*.

Penelitian ini bertujuan untuk mengoptimalkan penggunaan algoritma LightGBM dalam memprediksi harga dengan fokus pada pengelolaan *overfitting*.

Penggunaan LightGBM dalam prediksi harga *cryptocurrency* menunjukkan potensi besar, tetapi *overfitting* merupakan tantangan utama yang perlu diatasi untuk mendapatkan model yang akurat dan dapat digeneralisasi. Oleh karena itu, penelitian ini tidak hanya bertujuan untuk menerapkan LightGBM, tetapi secara spesifik menginvestigasi dan mengoptimalkan strategi untuk menganalisis serta mengendalikan *overfitting* dalam prediksi harga *Cardano*.

Penelitian ini mengidentifikasi cara-cara untuk mengurangi *overfitting* dengan mengoptimalkan parameter model, menggunakan teknik seperti *cross-validation* dan *early stopping*, serta menggabungkan data teknikal dan fundamental dalam model.

Untuk mencapai tujuan tersebut, penelitian ini akan mengevaluasi performa model menggunakan metrik MAE dan RMSE yang telah terbukti relevan dalam mengukur akurasi prediksi pada data volatile seperti *cryptocurrency*. Diharapkan hasil dari penelitian ini dapat memberikan wawasan lebih dalam mengenai penerapan LightGBM dalam prediksi harga *cryptocurrency*, khususnya *Cardano*, serta mengatasi masalah *overfitting* yang umum pada model prediktif.

1.2. Rumusan Masalah

Berdasarkan latar belakang yang dibuat, berikut merupakan permasalahan pada penelitian ini :

1. Bagaimana kinerja model LightGBM dalam memprediksi harga *Cardano*.
2. Bagaimana pengaruh optimasi hyperparameter terhadap akurasi

model ?

3. Bagaimana pengaruh perbedaan volume data latih terhadap kinerja prediksi model?

Overfitting adalah kondisi di mana model terlalu kompleks sehingga dapat memprediksi data pelatihan dengan sangat baik, namun tidak mampu memprediksi data yang tidak terlihat (data testing) dengan akurat.

1.3. Tujuan Penelitian

Berdasarkan latar belakang dan rumusan masalah maka didapatkan tujuan sebagai berikut :

1. Membangun model prediksi harga *Cardano* menggunakan LightGBM.
2. Menganalisis dampak dari optimasi hyperparameter.
3. Mengevaluasi kinerja model pada tiga skenario pembagian data.

1.4. Ruang Lingkup

Berdasarkan latar belakang yang telah diuraikan, dibuatlah ruang lingkup agar saat penelitian ini dapat jelas cakupannya. Adapun ruang lingkup yang dibuat adalah sebagai berikut:

1. Penelitian hanya menggunakan data historis harga tanpa memasukkan faktor eksternal seperti sentimen media sosial atau berita.
2. Sistem dibangun menggunakan bahasa pemrograman python
3. Fokus penelitian pada aspek prediksi harga , tanpa memberikan rekomendasi investasi.
4. Data yang diambil adalah harga historis *Cardano* , dari tahun 2017 hingga 2024 .
5. Kinerja model diukur menggunakan metrik evaluasi standar untuk regresi, yaitu Mean Absolute Error (MAE), Root Mean Squared Error (RMSE), Mean Absolute Percentage Error (MAPE), dan R-squared (R^2).

1.5. Manfaat Penelitian

Penelitian ini berkontribusi pada pengembangan lebih lanjut metode untuk memprediksi harga *Cardano*, yaitu dengan mengombinasikan pendekatan time-series yang dioptimalkan menggunakan algoritma LightGBM. Dengan demikian, penelitian ini diharapkan dapat meningkatkan akurasi dalam memprediksi harga *Cardano*, memberikan wawasan tambahan bagi para investor dan pelaku pasar, serta memperkaya literatur mengenai penerapan *machine learning* dalam analisis keuangan, terutama di pasar aset yang sangat dinamis dan digital. Selain itu, penelitian ini juga dapat menjadi referensi yang berguna untuk menerapkan metode serupa dalam prediksi harga *cryptocurrency* lainnya.

BAB II

TINJAUAN PUSTAKA

Pada bab ini menjelaskan tinjauan/ulasan terhadap penelitian/karya sebelumnya atau referensi dan teori-teori yang berkaitan dengan Penerapan metode *LightGBM* untuk prediksi *Cardano* dengan pengaruh *overfitting*.

2.1. Tinjauan Pustaka

Dalam penelitian ini terdapat beberapa tinjauan pustaka yang berkaitan dengan penelitian yang dilakukan sebagai berikut :

(Ji & Zhang, 2022) dalam penelitiannya menggunakan *LightGBM* untuk memprediksi harga Bitcoin, sebuah *cryptocurrency* dengan volatilitas tinggi. Dalam penelitian ini, data harga historis dan indikator teknikal digunakan sebagai input model. Hasil penelitian menunjukkan bahwa *LightGBM* mampu memberikan prediksi dengan tingkat akurasi yang lebih tinggi dibandingkan dengan metode regresi linear, terutama ketika dihadapkan pada data dengan fitur yang kompleks dan fluktuasi harga yang tinggi. Hasil ini menegaskan bahwa *LightGBM* memiliki kemampuan untuk menangkap pola-pola non-linear dalam data harga *cryptocurrency*, yang sering kali tidak dapat dilakukan oleh model linear sederhana.

(Zhang et al, 2021) dalam artikel merela juga menunjukkan keberhasilan penggunaan *LightGBM* dalam prediksi harga Ethereum, *cryptocurrency* kedua terbesar setelah Bitcoin. Dalam penelitian ini, *LightGBM* dibandingkan dengan beberapa algoritma lain seperti Random Forest dan XGBoost. Hasilnya menunjukkan bahwa *LightGBM* tidak hanya memberikan waktu pelatihan yang lebih cepat tetapi juga menghasilkan prediksi yang lebih akurat dibandingkan dengan algoritma-algoritma lainnya, terutama dalam menangani dataset besar yang mengandung banyak fitur.

(Bentéjac et al, 2021) dalam studi mereka membandingkan kinerja *LightGBM* dengan algoritma boosting lain, termasuk XGBoost dan CatBoost, dalam prediksi aset keuangan. Hasil penelitian ini menegaskan bahwa *LightGBM* memiliki kinerja yang lebih baik dalam hal waktu pelatihan tanpa mengorbankan akurasi. Dalam konteks prediksi harga aset digital, kecepatan pelatihan yang lebih

tinggi sangat penting, mengingat fluktuasi harga yang terjadi dengan cepat dalam pasar *cryptocurrency*. *LightGBM* memberikan fleksibilitas dalam menangani volume data yang besar dengan memanfaatkan pembagian histogram, yang memungkinkan proses yang lebih cepat dibandingkan dengan metode lain yang menggunakan growth tree *level-wise*.

Penelitian lain oleh **(Li & Wang , 2020)** memanfaatkan *LightGBM* untuk memprediksi harga saham dan menemukan bahwa model ini berhasil memberikan hasil prediksi yang unggul dibandingkan metode lain seperti Neural Networks dan Support Vector Machines (SVM). Hal ini menyoroti potensi *LightGBM* dalam menangani berbagai jenis aset, tidak hanya terbatas pada saham, tetapi juga dapat diadaptasi untuk prediksi harga *cryptocurrency*.

(Liu & Wu, 2022) dalam studi mereka “Performance Analysis of *Machine learning* Models in *cryptocurrency* Price Prediction”. Penelitian ini membandingkan beberapa model prediksi harga *cryptocurrency*, termasuk *LightGBM*, Random Forest, dan LSTM. Hasilnya menunjukkan bahwa *LightGBM* unggul dalam memprediksi harga dengan akurasi tinggi pada dataset yang besar, seperti Bitcoin dan *Cardano*.

(Chen & Yang, 2021) dalam artikel mereka “Exploring the Effectiveness of *LightGBM* for Short-Term *cryptocurrency* Forecasting”. Studi ini fokus pada prediksi harga *cryptocurrency* dalam jangka pendek menggunakan *LightGBM*. Penggunaan *LightGBM* terbukti efisien dalam menangani data dengan banyak variabel dan fluktuasi, khususnya dalam pasar *cryptocurrency* yang volatil seperti Ethereum dan *Cardano*.

(Guo, Z., & Wang, L, 2020) dalam penelitiannya “Boosting Techniques for Financial Asset Price Prediction: A Comparative Study of *LightGBM* and XGBoost”. Penelitian ini menganalisis perbedaan antara *LightGBM* dan XGBoost dalam prediksi aset finansial. Hasilnya menunjukkan bahwa *LightGBM* lebih unggul dalam hal efisiensi waktu pelatihan dan penggunaan memori, membuatnya sangat ideal untuk aplikasi pada data *cryptocurrency*.

(Huang, M., & Lin, T., 2022) dalam penelitian mereka *cryptocurrency* Price Prediction using *LightGBM* with Sentiment Analysis. Dalam penelitian ini,

LightGBM digunakan bersama analisis sentimen berita untuk memprediksi harga *cryptocurrency*. Studi ini menemukan bahwa *LightGBM* dapat lebih efektif dalam meningkatkan akurasi prediksi ketika ditambah dengan faktor sentimen, terutama dalam *cryptocurrency* dengan volatilitas tinggi seperti *Cardano*.

(Shen & Li, 2021) dalam penelitian mereka “*LightGBM Model for High-Frequency cryptocurrency Price Movement Prediction*”. Penelitian ini memfokuskan pada aplikasi *LightGBM* dalam prediksi harga *cryptocurrency* dengan data frekuensi tinggi. Hasil penelitian ini menunjukkan bahwa *LightGBM* mampu memberikan hasil prediksi yang cepat dan akurat dalam kondisi pasar yang dinamis, yang sangat penting dalam perdagangan crypto.

(Yuan & Zhang, 2023) dalam studi mereka Using *Ensemble learning Techniques for cryptocurrency Market Forecasting*. Studi ini mengeksplorasi berbagai teknik ensemble, termasuk *LightGBM*, untuk memprediksi pergerakan pasar *cryptocurrency*. Hasilnya menunjukkan bahwa *LightGBM* memberikan prediksi yang lebih stabil dan konsisten, terutama dalam mengatasi fluktuasi harga jangka pendek.

(Wang, J., & Zhou, Y, 2022) dalam penelitian mereka *LightGBM for Volatility Modeling in cryptocurrency Markets*. Penelitian ini menggunakan *LightGBM* untuk memodelkan volatilitas harga *cryptocurrency*, termasuk Bitcoin dan Altcoins seperti *Cardano*. Hasil penelitian menunjukkan bahwa *LightGBM* unggul dalam mengidentifikasi pola volatilitas dibandingkan dengan model tradisional, membantu dalam prediksi pergerakan harga yang lebih akurat.

(Kumar, R., & Das, S., 2021) dalam penelitian mereka “Predicting *cryptocurrency* Prices Using *Machine learning Algorithms: A Case Study on LightGBM*”. Dalam penelitian ini, *LightGBM* dibandingkan dengan model prediksi lainnya seperti LSTM dan CNN. *LightGBM* terbukti memberikan performa yang lebih baik dalam hal akurasi dan efisiensi pada dataset besar, terutama pada prediksi aset-aset digital dengan volatilitas tinggi seperti *Cardano* dan *Ripple*.

(Zhang, Q., & Liu, X., 2020) dalam studi kasus mereka “Improving *cryptocurrency* Price Prediction with *LightGBM* and *Feature engineering*”. Studi ini memanfaatkan *LightGBM* yang digabungkan dengan teknik *feature engineering*

untuk meningkatkan akurasi prediksi harga *cryptocurrency*. Hasilnya menunjukkan bahwa kombinasi ini memungkinkan model LightGBM menangkap pola kompleks yang muncul dalam data pasar *cryptocurrency*.

(Xu, L., & Chen, Y., 2023) dalam studi mereka “ A Study on the Effectiveness of *Gradient boosting* Models for Predicting Digital Asset Prices”. Penelitian ini menganalisis efektivitas LightGBM dibandingkan dengan algoritma *boosting* lainnya dalam prediksi harga aset digital. LightGBM memberikan hasil akurat dalam memprediksi harga aset digital seperti Ethereum dan *Cardano*, terutama dalam kondisi pasar yang fluktuatif.

Dari berbagai studi tersebut, dapat disimpulkan bahwa LightGBM telah menunjukkan kinerja yang unggul dalam memprediksi aset digital, baik dalam hal kecepatan maupun akurasi. Kemampuan algoritma ini untuk menangani dataset besar, serta kemampuannya dalam mengatasi masalah non-linearitas dalam data, menjadikannya salah satu pilihan utama dalam prediksi harga *cryptocurrency*. Oleh karena itu, penelitian ini menerapkan LightGBM untuk memprediksi harga *Cardano*, yang merupakan salah satu *cryptocurrency* dengan volatilitas yang cukup tinggi dan karakteristik teknis yang unik.

2.2. *Cryptocurrency*

Cryptocurrency adalah aset digital yang menggunakan teknologi kriptografi untuk mengamankan transaksi dan mengontrol penciptaan unit baru. Prediksi harga *cryptocurrency* sangat penting karena pasar ini dikenal sangat fluktuatif dan dipengaruhi oleh berbagai faktor seperti permintaan pasar, berita ekonomi, dan perkembangan teknologi blockchain. Prediksi harga yang akurat dapat membantu investor dan trader dalam membuat keputusan yang lebih tepat (Chen, Y., 2020).

Tantangan dalam memprediksi *cryptocurrency* :

1. Ketidakpastian harga Tinggi: Harga *cryptocurrency* dapat berfluktuasi drastis dalam waktu singkat, membuat prediksi jangka pendek dan menengah menjadi sangat sulit.
2. Kurangnya Data Historis: Banyak *cryptocurrency* yang baru muncul sehingga data historis yang tersedia mungkin tidak cukup untuk

membuat model prediksi yang stabil.


3. Pengaruh Eksternal: Berita, regulasi pemerintah, dan pengembangan teknologi dapat mempengaruhi harga *cryptocurrency* secara signifikan, dan hal ini sulit untuk dimasukkan dalam model prediksi.

2.3. Cardano

Cardano adalah salah satu *cryptocurrency* yang didesain dengan pendekatan berbasis riset akademik yang kuat, dan merupakan platform blockchain yang bertujuan untuk menciptakan infrastruktur lebih aman dan terukur dibandingkan teknologi blockchain sebelumnya seperti Bitcoin dan Ethereum. *Cardano* memanfaatkan model *proof-of-stake* (PoS) yang lebih efisien secara energi dibandingkan model *proof-of-work* (PoW) yang digunakan oleh Bitcoin (Brown & Hoskinson, 2017).

Karakteristik Teknis *Cardano* :

1. Proof of Stake (PoS): *Cardano* menggunakan mekanisme konsensus PoS yang disebut Ouroboros, yang memungkinkan verifikasi transaksi dengan konsumsi energi lebih rendah .
2. Layered Architecture: *Cardano* terdiri dari dua lapisan, yaitu *Cardano Settlement Layer* (CSL) yang mengelola transaksi, dan *Cardano Computation Layer* (CCL) yang memungkinkan pengembangan smart contracts. Hal ini membuat *Cardano* lebih fleksibel dan dapat ditingkatkan tanpa mengganggu transaksi.
3. Keamanan dan Skalabilitas: Dengan pendekatan berbasis penelitian, *Cardano* dirancang untuk menjadi platform blockchain yang lebih aman dan skalabel, serta dapat beradaptasi dengan perubahan masa depan.



Gambar 2. 1 Area Chart Cardano 2017-2024

Pada Gambar 2.1 memvisualisasikan pergerakan harga harian Cardano dari tahun 2017 hingga 2024, yang menjadi dasar data untuk penelitian ini. Grafik tersebut menunjukkan adanya periode-periode dengan perubahan nilai yang memiliki magnitudo besar dalam interval waktu yang singkat. Terlihat adanya fase peningkatan nilai harga yang signifikan, terutama pada tahun 2021 di mana harga mencapai nilai tertingginya di dekat \$3, yang kemudian diikuti oleh fase penurunan nilai yang juga signifikan. Rentang nilai yang besar dan adanya perubahan tren yang tidak seragam ini menjadi tantangan utama yang harus diatasi oleh model prediksi yang dibangun dalam penelitian ini untuk dapat menangkap pola data yang mendasarinya.

Cardano telah menjadi salah satu koin utama dalam ekosistem *cryptocurrency* karena pendekatannya yang unik dan fokus pada keberlanjutan serta interoperabilitas. Dalam beberapa tahun terakhir, Cardano telah menarik minat banyak pengembang dan investor, yang menjadikannya objek menarik untuk prediksi harga dan analisis pasar.

Cardano dipilih sebagai objek penelitian dalam studi ini karena karakternya yang inovatif dan relevansi yang meningkat dalam dunia *ryptocurrency*. Fluktuasi harga Cardano yang signifikan juga memberikan tantangan yang ideal untuk diuji dengan metode prediksi *machine learning* seperti LightGBM.

2.4. ***Machine learning* dalam prediksi harga *cryptocurrency***

Machine learning adalah bidang yang berfokus pada pengembangan algoritma yang memungkinkan komputer untuk belajar dari dan membuat prediksi atau keputusan berdasarkan data. Algoritma *machine learning* bekerja dengan cara mengidentifikasi pola dan hubungan dalam data, sehingga dapat digunakan untuk memprediksi hasil di masa depan berdasarkan data historis (Mitchell, T. M. 1997).

Machine learning telah digunakan secara luas dalam analisis keuangan untuk berbagai aplikasi, termasuk prediksi harga saham, pengelolaan risiko, dan analisis pasar. Dalam konteks prediksi harga, algoritma *machine learning* dapat menganalisis data historis dan mengidentifikasi tren yang mungkin tidak terlihat oleh metode analisis tradisional. Teknologi ini memungkinkan trader dan analis keuangan untuk membuat keputusan investasi yang lebih informasional dan tepat waktu (Chen et al., 2020).

2.5. **Landasan Teori *Ensemble learning*, *Gradient boosting*, dan LightGBM**

LightGBM merupakan algoritma *ensemble learning*, yang berarti algoritma ini menggabungkan hasil dari beberapa model sederhana (weak learners) untuk menghasilkan prediksi yang lebih kuat. Teori *ensemble learning* menyatakan bahwa menggabungkan beberapa model prediksi akan menghasilkan hasil yang lebih baik daripada menggunakan satu model tunggal (Dietterich, 2000).

Dengan menerapkan *ensemble learning*, LightGBM mampu meminimalkan error prediksi yang mungkin muncul jika hanya mengandalkan satu model. Teori ini mendukung penelitian prediksi harga Cardano karena fluktuasi harga *cryptocurrency* yang sangat dinamis dan penuh ketidakpastian. Melalui *ensemble learning*, LightGBM dapat menghasilkan prediksi yang lebih stabil dan akurat.

Salah satu implementasi paling kuat dan populer dari *ensemble learning* adalah teknik *Gradient boosting*.

Algoritma LightGBM merupakan salah satu implementasi dari teknik *Gradient boosting*. Secara umum, *Gradient boosting Machines* (GBM) adalah teknik *ensemble learning* yang menggabungkan beberapa model *decision tree* untuk meningkatkan akurasi prediksi. *Gradient boosting* bekerja dengan cara


membangun model secara bertahap, di mana model-model selanjutnya mencoba untuk memperbaiki error residual dari model-model sebelumnya (Friedman, 2001).

Menurut teori *Gradient boosting*, setiap model baru dihasilkan dengan meminimalkan fungsi loss melalui pendekatan gradient descent. Pada dasarnya, gradient descent menghitung turunan dari fungsi loss untuk setiap iterasi, dan model baru ditambahkan ke dalam ensemble berdasarkan gradient tersebut. Pendekatan ini menjadikan *Gradient boosting* sangat efektif untuk menangani masalah prediksi dengan kompleksitas tinggi.

Penggunaan *Gradient boosting* dalam algoritma LightGBM menjadi relevan dalam prediksi harga *cryptocurrency* karena volatilitas dan fluktuasi pasar yang memerlukan metode prediksi yang tangguh dalam mengurangi error secara bertahap. Dengan kata lain, LightGBM mampu memperbaiki prediksi yang kurang akurat dengan iterasi yang lebih baik pada setiap tahapannya.

LightGBM (Light *Gradient boosting* Machine) adalah algoritma *machine learning* berbasis *gradient boosting* yang dioptimalkan untuk kecepatan dan efisiensi. Dikembangkan oleh Microsoft, LightGBM dirancang untuk mendukung distributed training, efisiensi memori yang lebih baik, dan kemampuan untuk menangani dataset dengan jumlah fitur besar. Algoritma ini bekerja dengan membangun beberapa pohon keputusan berturut-turut, di mana setiap pohon baru mencoba memperbaiki kesalahan dari pohon sebelumnya (Ke et al., 2017).

Light *Gradient boosting* Machine (LightGBM) telah digunakan secara luas dalam berbagai aplikasi prediksi aset digital. LightGBM, yang merupakan salah satu algoritma boosting yang efisien, menawarkan keunggulan dalam hal kecepatan pelatihan dan penggunaan memori, yang menjadikannya sangat sesuai untuk analisis dataset besar seperti harga *cryptocurrency*.



Gambar 2. 2 Workflow of *LightGBM*

Diagram ini menjelaskan alur kerja *LightGBM*: dimulai dengan Input Data, yang kemudian diproses melalui *Histogram-based Binning* untuk efisiensi. Selanjutnya, *Decision tree* dibangun menggunakan strategi *Leaf-wise Growth* yang fokus pada pengurangan kesalahan terbesar. Setelah itu, Error dievaluasi, dan Tree baru ditambahkan untuk mengoreksi kesalahan dari tree sebelumnya. Proses ini berulang hingga akhirnya menghasilkan Final Prediction sebagai gabungan dari semua tree.

Kelebihan :

1. Kecepatan: *LightGBM* dikenal karena kecepatan latihannya yang luar biasa cepat dibandingkan dengan algoritma boosting lainnya.
2. Efisiensi Memori: *LightGBM* menggunakan lebih sedikit memori karena teknik *histogram-based* dan *leaf-wise tree growth*.
3. Skalabilitas: Algoritma ini dirancang untuk menangani dataset besar dengan jumlah fitur yang sangat banyak.
4. Akurasi Tinggi: Dengan teknik canggih yang digunakan, *LightGBM* mampu memberikan prediksi yang sangat akurat.

Perbandingan dengan Algoritma Lain :

XGBoost: *LightGBM* sering dibandingkan dengan XGBoost, algoritma

boosting lainnya yang sangat populer. Sementara XGBoost juga dikenal dengan akurasi yang tinggi, LightGBM biasanya lebih cepat dalam proses pelatihan dan lebih efisien dalam penggunaan memori. Perbedaan utama antara keduanya adalah bahwa LightGBM menggunakan teknik *leaf-wise* tree growth, sementara XGBoost menggunakan *level-wise* tree growth. Studi menunjukkan bahwa LightGBM dapat memberikan hasil yang lebih baik dalam waktu yang lebih singkat pada dataset besar (Bentéjac et al., 2021).

Aplikasi dalam prediksi harga :

LightGBM telah digunakan dalam berbagai konteks prediksi harga aset dan keuangan. Contoh aplikasi meliputi:

1. **Prediksi Harga Saham:** Menggunakan data historis saham untuk memprediksi harga saham di masa depan.
2. **Prediksi Harga *cryptocurrency*:** Menggunakan data harga historis, volume perdagangan, dan indikator teknikal untuk memprediksi harga *cryptocurrency* seperti Bitcoin dan Ethereum.

LightGBM terbukti efektif dalam menangani data dengan dimensi tinggi dan memberikan prediksi yang akurat di berbagai domain finansial (Ji & Zhang, 2022).

2.6. *Overfitting* dalam *Machine learning*

Overfitting adalah salah satu tantangan paling umum dalam pengembangan model *machine learning*. Kondisi ini terjadi ketika model memiliki performa yang sangat baik pada data latih, tetapi performanya menurun drastis pada data uji atau data baru yang belum pernah dilihat sebelumnya. Model yang *overfit* pada dasarnya terlalu "menghafal" detail dan *noise* pada data latih, bukan mempelajari pola umum yang mendasarinya. Penyebab *overfitting* bisa beragam, antara lain model yang terlalu kompleks untuk jumlah data yang tersedia, data latih yang tidak representatif, atau pelatihan yang terlalu lama. Akibatnya, model gagal melakukan generalisasi dengan baik, sehingga tidak dapat diandalkan untuk prediksi di dunia nyata.

Beberapa teknik umum untuk mitigasi *overfitting* meliputi:

1. Penggunaan lebih banyak data latih.
2. *Cross-validation* untuk evaluasi model yang lebih robust.
3. *Feature selection* untuk mengurangi dimensi data dan *noise*.
4. Regularisasi (L1, L2) untuk memberi penalti pada kompleksitas model.
5. *Early stopping* untuk menghentikan pelatihan sebelum model mulai *overfit*.

2.7. *Regresi* , *time series*

Prediksi harga *cryptocurrency* seperti Cardano sangat bergantung pada data historis, di mana harga sebelumnya memberikan informasi penting untuk memprediksi harga di masa depan. Dalam hal ini, teori *time series* dan regresi sangat relevan.

Teori regresi digunakan untuk memodelkan hubungan antara variabel input (seperti harga historis, volume transaksi, atau sentimen pasar) dengan output (harga yang diprediksi). LightGBM, sebagai model *machine learning*, mengaplikasikan regresi untuk menemukan pola dalam data historis *cryptocurrency*, sehingga mampu memprediksi harga yang akan datang berdasarkan data-data yang telah ada

(Hyndman & Athanasopoulos, 2018).

Dalam konteks *time series*, data harga *cryptocurrency* merupakan data yang bergantung pada waktu. Dengan demikian, analisis *time series* penting untuk mengidentifikasi pola musiman, tren, dan fluktuasi yang mungkin terjadi dalam jangka waktu tertentu. Penggunaan data *time series* dalam prediksi harga *cryptocurrency* didasarkan pada asumsi bahwa harga-harga di masa lalu memberikan gambaran tentang pergerakan harga di masa depan (Shumway & Stoffer, 2017). LightGBM, yang mampu memproses data dalam skala besar dan melakukan prediksi secara bertahap, sangat cocok digunakan dalam analisis data *time series* ini.

2.8. Optimasi Model *Machine learning*

Algoritma LightGBM dirancang untuk mengatasi masalah *overfitting* dan *underfitting* dalam model *machine learning*. Salah satu keunggulan LightGBM adalah kemampuannya untuk mengoptimalkan model melalui teknik seperti *leaf-wise tree growth*, yang memungkinkannya membangun pohon dengan cara yang lebih efisien dibandingkan metode *tree growth* tradisional (Ke et al., 2017).

Menurut teori optimasi model *machine learning*, model yang baik adalah model yang mampu menghasilkan prediksi yang akurat pada data training dan data testing, tanpa terlalu berfokus pada *noise* yang ada pada data training. LightGBM mencapai optimasi ini dengan membagi data ke dalam *histogram-based decision trees*, yang membuatnya lebih cepat dan efisien dalam memproses data besar.


Teori optimasi ini mendukung penelitian prediksi harga *cryptocurrency*, karena fluktuasi harga yang cepat dan volatilitas pasar memerlukan model yang dapat melakukan prediksi secara akurat dalam waktu singkat, bahkan ketika data yang digunakan cukup besar.

BAB III METODOLOGI PENELITIAN

Pada bab ini menjelaskan metode penelitian dan pengembangan sistem yang dibuat berdasarkan metode pengembangan perangkat lunak prototyping. Tahapan prototyping yang dibahas pada bab ini terdiri perancangan umum, pembangunan prototipe, dan evaluasi. Metode penelitian yang dilakukan meliputi, perancangan umum terdiri dari flowchart dan blok diagram.

3.1. Flowchart System

Pada sub bab flowchart sistem dijelaskan mengenai rangkaian proses pada sistem hasil prediksi yang dibangun seperti pada Gambar 3.1.



Gambar 3. 1 Flowchart System


1. Mulai (Start): Merupakan titik awal dari keseluruhan proses penelitian.
2. Pemuatan Dataset (Load Dataset): Tahap ini dimulai dengan memuat dataset historis harga harian Cardano (ADA) yang diperoleh dari platform Investing.com. Dataset ini berfungsi sebagai input fundamental yang berisi data mentah OHLCV (Open, High, Low,

Close, Volume) dari tahun 2017 hingga 2024.

3. Pra-pemrosesan (Preprocessing): Data mentah yang telah dimuat kemudian melalui serangkaian proses persiapan data yang . Tahap ini bertujuan untuk memastikan kualitas dan konsistensi data. Sub-proses di dalamnya meliputi pembersihan format data (seperti mengonversi nilai Vol. dari format teks "M", "B", "K" menjadi numerik), konversi tipe data (terutama kolom Date ke format datetime), dan yang terpenting, rekayasa fitur (*feature engineering*) dengan membuat fitur lag (nilai 1, 7, dan 30 hari sebelumnya) untuk memberikan konteks historis kepada model.
4. Prediksi LightGBM: Ini adalah tahap inti pemodelan di mana data yang telah siap digunakan untuk melatih model LightGBM. Proses ini melibatkan pembagian data menjadi set latih dan uji sesuai skenario (80:20, 70:30, 60:40) dengan `shuffle=False`, normalisasi fitur menggunakan `StandardScaler`, dan akhirnya melatih model LightGBM itu sendiri.
5. Prediksi Harga dan Metrik Kesalahan (optimasi/tidak): Setelah model dilatih, ia digunakan untuk melakukan prediksi pada data uji. Tahap ini merupakan evaluasi kuantitatif di mana hasil prediksi dibandingkan dengan harga aktual. Evaluasi ini dilakukan secara komparatif untuk dua jenis model yang diuji: model standar (tanpa optimasi) dan model yang menggunakan hyperparameter teroptimasi. Kinerja keduanya diukur menggunakan metrik standar regresi seperti MAE, RMSE, R^2 , dan MAPE. Analisis pada tahap ini menjadi dasar untuk menjawab rumusan masalah terkait pengaruh optimasi dan volume data terhadap kinerja dan *overfitting*.
6. Selesai (End): Merupakan tahap akhir dari alur kerja, di mana hasil evaluasi dan analisis dari tahap sebelumnya dirangkum untuk menarik kesimpulan penelitian.

3.2. Blok Diagram

Langkah-langkah dalam penelitian Penerapan metode LightGBM untuk prediksi harga Cardano dengan pengaruh *overfitting* ditunjukkan pada dalam block diagram yang terdapat pada Gambar 3.2.



Gambar 3. 2 Blok Diagram Alur kerja penelitian

1. Input

Bagian ini merepresentasikan sumber data utama yang menjadi fondasi dari keseluruhan penelitian.

1. Historical data Cardano: Input tunggal untuk sistem ini adalah dataset deret waktu historis harga harian Cardano (ADA). Data ini bersumber dari platform Investing.com, mencakup periode dari tahun 2017 hingga 2024, dan berisi informasi fundamental pasar seperti harga pembukaan, tertinggi, terendah, penutupan (kolom Price), dan volume transaksi.

2. Proses

Bagian ini adalah inti dari sistem, di mana data mentah diolah, dimodelkan, dan dianalisis. Proses ini terbagi menjadi beberapa sub-sistem utama:

1. Pre-processing (Pra-pemrosesan): Data historis dari tahap input pertama kali melalui tahap pra-pemrosesan. Proses ini mencakup semua langkah persiapan data seperti pembersihan, rekayasa fitur (feature engineering) dengan membuat fitur lag, dan normalisasi untuk menghasilkan data yang bersih dan siap pakai.
2. Pelatihan dan Evaluasi model: Data yang telah diproses kemudian digunakan dalam tahap pemodelan[cite: 1]. Proses ini mencakup pelatihan dua jenis model LightGBM (standar vs. teroptimasi) dan

evaluasi kinerjanya menggunakan data uji.


3. Output

Bagian ini merepresentasikan semua hasil akhir yang dihasilkan oleh sistem setelah melalui semua tahapan proses.

1. Model LightGBM terlatih: Output utama adalah model *machine learning* siap untuk digunakan dalam membuat prediksi.
2. Hasil prediksi dan Metriks Evaluasi : Ini adalah hasil analitis dari proses evaluasi, yang mencakup nilai-nilai prediksi serta metrik kuantitatif (seperti R^2 , MAE, RMSE) yang digunakan untuk menganalisis kinerja dan overfitting. Hasil inilah yang menjadi dasar utama penarikan kesimpulan penelitian.

3.3. Flowchart Preprocessing

Pada sub bab flowchart preprocessing ini dijelaskan mengenai proses untuk melakukan pra pemrosesan dengan beberapa tahapan seperti pada Gambar 3.6 sebagai berikut.



Gambar 3. 3 Flowchart Preprocessing


1. Start : Merupakan titik awal dari proses pra-pemrosesan data.
2. Input dataset: Tahap ini dimulai dengan mengimpor dataset mentah

dataset.csv yang berisi data historis harga harian Cardano (ADA). Data ini merupakan input awal yang belum diolah dan masih mengandung format yang perlu dibersihkan.

3. Pembuatan fitur lag (*Feature engineering*): Ini adalah langkah rekayasa fitur yang paling krusial dalam penelitian ini. Untuk memberikan "memori" atau konteks historis kepada model, fitur-fitur baru dibuat berdasarkan data masa lalu. Secara spesifik, proses ini menciptakan kolom-kolom fitur lag untuk periode 1, 7, dan 30 hari sebelumnya dari kolom-kolom utama seperti Price, Open, High, Low, dan Volume.
4. Penanganan nilai kosong (Missing Value): Akibat dari proses pembuatan fitur lag, 30 baris pertama dari dataset akan secara otomatis memiliki nilai kosong (NaN) karena tidak memiliki data historis yang cukup (khususnya untuk `_Lag30`). Karena model *machine learning* tidak dapat memproses nilai kosong, baris-baris ini dihapus dari dataset untuk memastikan integritas data.
5. Data setelah diperbarui (X): Output dari keseluruhan proses pra-pemrosesan ini adalah sebuah DataFrame yang bersih dan telah diperbarui. DataFrame ini berisi semua fitur (variabel independen) yang akan digunakan untuk melatih model, yang dilambangkan sebagai (X). Kumpulan data inilah yang kemudian akan dibagi menjadi data latih dan data uji pada tahap selanjutnya.
6. Selesai (End): Menandakan bahwa proses pra-pemrosesan telah selesai dan dataset kini siap untuk digunakan dalam tahap pemodelan *machine learning*.

3.4. Flowchart LightGBM

Pada sub-proses ini akan dijelaskan alur sub-proses pada LightGBM yang digunakan pada penelitian ini. Alur LightGBM ditunjukkan pada Gambar 3.3.



Gambar 3. 4 Flowchart LightGBM

1. Start (Mulai): Merupakan titik awal dari proses pemodelan.
2. Data setelah diperbarui (X): Input untuk tahap ini adalah dataset yang telah bersih dan diperbarui dari proses pra-pemrosesan sebelumnya. Dataset ini berisi semua fitur (X), termasuk fitur-fitur lag yang telah dibuat melalui rekayasa fitur.
3. Pembagian dataset (SPLIT DATASET): Dataset fitur (X) dan target (y) dibagi menjadi set data latih dan data uji. Proses ini dilakukan sesuai dengan tiga skenario penelitian, yaitu dengan proporsi 80:20, 70:30, dan 60:40, menggunakan parameter `shuffle=False` untuk menjaga integritas urutan waktu.
4. Normalisasi data: Sebelum dilatih, semua fitur dalam data latih dan data uji dinormalisasi menggunakan `StandardScaler`. Langkah ini bertujuan untuk menyamakan skala semua fitur, sehingga model dapat belajar dengan lebih stabil dan tidak bias terhadap fitur dengan rentang

nilai yang besar.

5. Keputusan optimasi (optimasi atau tidak): Ini adalah titik percabangan yang merupakan inti dari eksperimen penelitian. Di sini, alur kerja dibagi menjadi dua jalur paralel untuk membandingkan kinerja dua jenis model:
6. Jalur kiri (Optimasi): Pada jalur ini, model LightGBM dilatih menggunakan hyperparameter terbaik yang telah ditemukan melalui proses GridSearchCV. Model ini merepresentasikan "Model Teroptimasi".
7. Jalur kanan (Tanpa Optimasi): Pada jalur ini, model LightGBM dilatih menggunakan hyperparameter default atau standar. Model ini merepresentasikan "Model Standar".
8. Prediksi Harga dan Metriks kesalahan: Untuk kedua jalur, model yang telah dilatih digunakan untuk melakukan prediksi pada data uji. Kinerja prediksi kemudian diukur secara kuantitatif dengan menghitung metriks kesalahan seperti R-squared (R^2), MAE, RMSE, dan MAPE.
9. Output hasil analisis: Hasil (metriks kesalahan) dari kedua jalur—model teroptimasi dan model standar—kemudian dikumpulkan. Output ini berupa tabel perbandingan kinerja yang menjadi dasar untuk analisis *overfitting* dan *underfitting*. Dari sinilah kesimpulan ditarik mengenai bagaimana pengaruh optimasi dan volume data terhadap kinerja model.
10. Selesai (End): Menandakan akhir dari proses pemodelan dan evaluasi untuk satu skenario. Keseluruhan proses ini diulang untuk setiap skenario pembagian data guna mendapatkan hasil penelitian yang komprehensif.

3.5. Dataset

Penelitian ini menggunakan data deret waktu (*time series*) historis harga Cardano yang diperoleh dari platform data finansial Investing.com. Dataset mencakup periode dari 31 Desember 2017 hingga 18 November 2024, yang terdiri dari 2514 data harian. Fitur utama yang digunakan adalah Tanggal (Date), Harga Penutupan (Price), Harga Pembukaan (Open), Harga Tertinggi (High), Harga Terendah (Low), Volume Perdagangan (Vol.), dan Persentase Perubahan (Change %). Dataset ini diunduh dalam format .csv untuk memudahkan pengolahan data lebih lanjut menggunakan perangkat lunak statistik dan analisis data (Investing.com, 2024).

Dengan jumlah total data yang mencakup 2514 baris dataset ini memberikan wawasan yang cukup untuk membangun model prediksi harga yang lebih akurat.

	Date	Price	Open	High	Low	Vol.	Change %
1	11/18/2024	0.7326	0.7026	0.7818	0.7017	519.20M	4.27%
2	11/17/2024	0.7026	0.7415	0.7722	0.6925	555.76M	-5.25%
3	11/16/2024	0.7415	0.7064	0.8178	0.7035	1.28B	4.98%
4	11/15/2024	0.7064	0.5789	0.7070	0.5759	1.02B	22.00%
5	11/14/2024	0.5790	0.5783	0.5986	0.5422	451.21M	0.11%
6	11/13/2024	0.5783	0.5700	0.6085	0.5195	719.20M	1.47%
7	11/12/2024	0.5700	0.6125	0.6518	0.5554	831.93M	-6.94%
8	11/11/2024	0.6125	0.5895	0.6234	0.5654	731.67M	3.91%
9	11/10/2024	0.5894	0.4968	0.6591	0.4888	1.33B	18.97%
10	11/09/2024	0.4954	0.4447	0.4976	0.4275	293.02M	11.56%
11	11/08/2024	0.4441	0.4065	0.4580	0.4043	581.86M	9.24%
12	11/07/2024	0.4065	0.3630	0.4066	0.3616	300.17M	11.95%
13	11/06/2024	0.3631	0.3336	0.3658	0.3336	328.19M	8.85%
14	11/05/2024	0.3336	0.3264	0.3382	0.3262	145.26M	2.21%
15	11/04/2024	0.3264	0.3339	0.3367	0.3206	152.67M	-2.25%

Gambar 3. 5 Historical data Cardano

Pada Gambar 3.5 dataset *time series* dari Investing.com diharapkan dapat memberikan analisis yang komprehensif dan akurat dalam memprediksi harga Cardano.

3.6. Pra-pemrosesan

Kualitas data input sangat mempengaruhi performa model *machine learning*. Oleh karena itu, tahap pra-pemrosesan dilakukan secara cermat dengan langkah-langkah sebagai berikut:

1. **Pemuatan dan Pengurutan:** Data dimuat menggunakan *library* Pandas di Python. Kolom 'Date' dikonversi ke format *datetime* dan dataset diurutkan berdasarkan tanggal secara menaik. Pengurutan ini fundamental untuk menjaga integritas temporal data deret waktu.
2. **Pembersihan Data:** Dilakukan pembersihan pada kolom yang formatnya belum numerik. Kolom 'Vol.' dibersihkan dari karakter non-numerik (' , 'K', 'M', 'B') dan dikonversi menjadi nilai numerik absolut. Kolom 'Change %' (meskipun tidak digunakan langsung sebagai fitur) juga dibersihkan. Kolom 'Price' dan kolom harga lainnya dipastikan bertipe *float*. Justifikasi: Langkah ini penting agar data volume dan harga dapat digunakan dalam perhitungan matematis dan pemodelan.
3. **Penanganan *Missing Values*:** Pemeriksaan awal dilakukan untuk *missing values*. Dalam dataset ini, *missing values* utama muncul setelah tahap *feature engineering* (pembuatan *lag*). Baris-baris data yang mengandung nilai NaN ini (yang berada di awal dataset) akan dihapus (`dropna()`) karena model tidak dapat memprosesnya dan periode awal ini tidak signifikan untuk analisis karena kekurangan data *lag*.

3.7. *Feature engineering*

Untuk meningkatkan kemampuan prediktif model, fitur-fitur baru (*engineered features*) dibuat dari data historis yang ada. Penelitian ini berfokus pada pembuatan fitur lag (nilai masa lalu), yang krusial untuk model *time series* karena memberikan konteks historis. Fitur yang dibuat adalah:

1. **Fitur *Lag* Harga:** Price_Lag1 (harga 1 hari lalu), Price_Lag7 (harga 7 hari lalu), Price_Lag30 (harga 30 hari lalu).
2. **Fitur *Lag* Volume:** Volume_Lag1 (volume 1 hari lalu), Volume_Lag7

(volume 7 hari lalu), Volume_Lag30 (volume 30 hari lalu).

3. Fitur *Lag* Open: Open_Lag1 (pembukaan 1 hari lalu), Open_Lag7 (pembukaan 7 hari lalu), Open_Lag30 (pembukaan 30 hari lalu).
4. Fitur *Lag* High: High_Lag1 (tertinggi 1 hari lalu), High_Lag7 (tertinggi 7 hari lalu), High_Lag30 (tertinggi 30 hari lalu).
5. Fitur *Lag* Low: Low_Lag1 (terendah 1 hari lalu), Low_Lag7 (terendah 7 hari lalu), Low_Lag30 (terendah 30 hari lalu).

		Price_Lag1	Price_Lag7	Price_Lag30	Volume_Lag1	Volume_Lag7	Volume_Lag30
1	493	0.3564	0.2845	0.2634	572220000.0	114260000.0	147590000.0
2	492	0.3278	0.2906	0.2621	418750000.0	117000000.0	158890000.0
3	491	0.3261	0.2845	0.2632	143680000.0	105430000.0	100810000.0
4	490	0.3145	0.2878	0.2667	161800000.0	137890000.0	99630000.0
5	489	0.3118	0.2927	0.261	148980000.0	109640000.0	74740000.0
6	488	0.3093	0.289	0.2634	180100000.0	88190000.0	81240000.0
7	487	0.3226	0.3564	0.2704	249040000.0	572220000.0	126060000.0
8	486	0.3158	0.3278	0.2864	203720000.0	418750000.0	211340000.0
9	485	0.3127	0.3261	0.29	97740000.0	143680000.0	191450000.0
10	484	0.31	0.3145	0.2963	86600000.0	161800000.0	133080000.00000001
11	483	0.3171	0.3118	0.2894	77830000.0	148980000.0	103500000.0
12	482	0.3053	0.3093	0.292	134340000.0	180100000.0	118400000.0
13	481	0.3036	0.3226	0.2805	92390000.0	249040000.0	107490000.0
14	480	0.3069	0.3158	0.2866	120790000.0	203720000.0	96980000.0
15	479	0.3077	0.3127	0.2667	84060000.0	97740000.0	162390000.0
16	478	0.3099	0.31	0.2751	69460000.0	86600000.0	101410000.0
17	477	0.3129	0.3171	0.2867	79420000.0	77830000.0	310260000.0
18	476	0.3157	0.3053	0.2925	87760000.0	134340000.0	106420000.0
19	475	0.307	0.3036	0.2917	96090000.0	92390000.0	88710000.0
20	474	0.3103	0.3069	0.2967	119520000.0	120790000.0	86680000.0
21	473	0.2994	0.3077	0.2923	126090000.0	84060000.0	123280000.0

Gambar 3. 6 *Feature engineering*

Pada Gambar 3.6 Pemilihan lag 1, 7, dan 30 hari bertujuan untuk menangkap dependensi data pada periode waktu yang berbeda: jangka sangat pendek (harian), mingguan, dan bulanan. Diasumsikan bahwa pola-pola dalam rentang waktu ini memiliki pengaruh terhadap harga di masa depan. Penelitian ini membatasi penggunaan fitur hanya pada lag ini untuk menjaga fokus dan kelayakan, dan tidak memasukkan indikator teknikal kompleks lainnya atau data fundamental eksternal, yang dapat menjadi arah penelitian selanjutnya.

Langkah-langkah preprocessing data dilakukan untuk memastikan dataset siap digunakan dalam pemodelan.

3.8. Pembagian Data

Dataset yang telah melalui pra-pemrosesan dan *feature engineering*

kemudian dibagi menjadi Data Latih (Training Set) dan Data Uji (Testing Set). Proporsi yang digunakan adalah 80% untuk data latih dan 20% untuk data uji. Pembagian ini dilakukan menggunakan fungsi `train_test_split` dari library `scikit-learn` dengan parameter `shuffle=False`. Penetapan `shuffle=False` memastikan bahwa urutan waktu data tetap terjaga, sehingga 80% data terlama digunakan untuk melatih model, dan 20% data terbaru digunakan untuk mengujinya, mensimulasikan skenario prediksi yang realistis.

```
# Pembagian data menjadi training dan testing set
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, shuffle=False)
```

Gambar 3. 7 Pembagian data menjadi training dan testing set


3.9. Metode LightGBM

LightGBM (Light *Gradient boosting* Machine) adalah sebuah algoritma *machine learning* yang efisien dalam melakukan prediksi berbasis *Gradient boosting*. Algoritma ini menggunakan beberapa inovasi untuk meningkatkan performa dalam memproses data yang besar dan mengurangi kemungkinan *overfitting*.

Berikut adalah beberapa prinsip dasar dari LightGBM.

1. *Gradient boosting* Framework : LightGBM membangun model secara bertahap, dengan setiap pohon keputusan yang dibangun untuk memperbaiki kesalahan dari pohon sebelumnya. Proses ini mengoptimalkan loss function menggunakan prinsip gradient descent, yang bertujuan meminimalkan kesalahan prediksi dari model.
2. *Leaf-wise* Tree Growth : LightGBM menggunakan pendekatan *leaf-wise* untuk membangun pohon keputusan, yang artinya pohon akan tumbuh dengan memilih cabang yang memberikan peningkatan terbesar terlebih dahulu, dibandingkan dengan pendekatan *level-wise* yang digunakan oleh algoritma lainnya. Pendekatan ini meningkatkan efisiensi dan akurasi, khususnya pada dataset besar dengan banyak

fitur.



Gambar 3. 8Leaf-wise tree growth

Model ini dilatih dengan beberapa parameter yang disesuaikan untuk mencapai hasil yang optimal. 'Regresi' dipilih sebagai objektif karena prediksi yang dilakukan merupakan nilai kontinu, yaitu harga Cardano. 'rmse' digunakan sebagai metrik evaluasi untuk mengukur kesalahan yang dihasilkan oleh model, dengan memberikan penalti yang lebih besar pada kesalahan yang lebih signifikan.

1. Loss Function:

Fungsi untuk mengukur kesalahan prediksi antara nilai sebenarnya (y_i) dan prediksi ($\hat{y}_i$):

$$L(\theta) = \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (3.1)$$

Keterangan :

- y_i : Nilai aktual
- $\hat{y}_i$: Prediksi model
- n : Jumlah data

2. Gradient Descent:

Algoritma ini memperbaiki model dengan menghitung gradien dari fungsi loss dan memperbarui parameter model:

$$\begin{aligned} \theta_{t+1} \\ = \theta_t - \eta \nabla L(\theta_t) \end{aligned} \quad (3.2)$$

Keterangan :

- θ_t : Parameter iterasi ke-t
- η : Learning rate

- ∇L : Gradien fungsi loss

3. Regularisasi (L2) :

Untuk mengurangi *overfitting*, *LightGBM* menambahkan penalti L2 terhadap kompleksitas model:

$$L(\theta) = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^m \|\theta_j\|^2 \quad (3.3)$$

Keterangan :

- λ : Parameter regularisasi
- m: Jumlah parameter

4. Prediksi Model:

Setelah pelatihan selesai, model *LightGBM* melakukan prediksi dengan menggabungkan hasil dari semua pohon keputusan:

$$\hat{y} = \sum_{t=1}^T f_{t(x)} \quad (3.4)$$

Keterangan :

- $f_t(x)$: Prediksi pohon ke-t
- T: Total pohon

Untuk mendapatkan performa model yang optimal dan mengendalikan *overfitting*, optimasi hyperparameter akan dilakukan. Penelitian ini akan menggunakan Grid Search *Cross-validation* (atau Randomized Search CV jika ruang pencarian sangat besar) dari scikit-learn .

Hyperparameter yang akan dioptimasi meliputi:

1. `num_leaves`: Mengontrol kompleksitas pohon
2. `max_depth`: Kedalaman maksimum pohon untuk mencegah *overfitting*.
3. `learning_rate`: Laju pembelajaran untuk mengontrol seberapa besar kontribusi setiap pohon.
4. `feature_fraction` (atau `colsample_bytree`): Fraksi fitur yang digunakan untuk setiap pohon

Analisis *overfitting*:

overfitting akan dianalisis dengan membandingkan nilai metrik evaluasi (MAE dan RMSE) antara data latih dan data uji. Perbedaan yang signifikan (performa jauh lebih baik pada data latih dibandingkan data uji) mengindikasikan *overfitting*.

Selain itu, pengaruh parameter seperti `num_leaves`, `max_depth` terhadap *overfitting* akan dievaluasi selama proses optimasi. Kurva pembelajaran (*learning curves*) juga dapat divisualisasikan untuk melihat bagaimana error pada data latih dan data validasi berubah seiring dengan bertambahnya data atau iterasi pelatihan, ini dapat membantu mendiagnosis *overfitting* atau *underfitting*.

3.10. Optimasi Hyperparameter dan Pelatihan Model

Tahap ini adalah inti dari pemodelan, di mana konfigurasi LightGBM terbaik dicari dan model final dilatih.

1. Optimasi *Hyperparameter* (GridSearchCV):
 - a) Untuk menemukan *hyperparameter LightGBM* yang optimal, penelitian ini akan menerapkan **Grid Search Cross-validation** (GridSearchCV) dengan $K=5$ pada data latih (`x_train_scaled`, `y_train`). *Cross-validation* digunakan untuk mendapatkan estimasi performa yang lebih robust dan mengurangi bias.
 - b) *Grid* pencarian akan mencakup parameter kunci yang mempengaruhi akurasi dan *overfitting*, seperti `learning_rate` ([0.05, 0.1]), `num_leaves` ([31, 50, 70]), `max_depth` ([5, 10, -1]), serta parameter regularisasi `reg_alpha` ([0.0, 0.1, 0.5]) dan `reg_lambda` ([0.0, 0.1, 0.5]), dan `min_child_samples` ([20, 50]). (*Catatan:*

Rentang nilai ini adalah contoh dan dapat disesuaikan).

- c) Metrik evaluasi yang digunakan dalam CV adalah `neg_mean_squared_error` (nilai negatif dari MSE, karena `GridSearchCV` mencari nilai tertinggi, sehingga kita mencari negatif terkecil dari MSE).

2. Pelatihan Model Final (dengan *Early stopping*):

- a) Model `LightGBM` baru akan diinisialisasi menggunakan *hyperparameter* terbaik yang ditemukan oleh `GridSearchCV`.
- b) Model ini akan dilatih menggunakan seluruh data latih (`X_train_scaled`, `y_train`).
- c) Selama proses pelatihan, teknik *Early stopping* akan diterapkan. *Early stopping* memantau performa model (RMSE) pada set evaluasi (dalam kasus ini, data uji) di setiap iterasi. Jika performa tidak membaik (RMSE tidak turun) selama 10 iterasi berturut-turut, pelatihan akan dihentikan. Justifikasi: Ini adalah mekanisme penting untuk mencegah model terlalu lama berlatih dan mulai menghafal data latih (*overfitting*), sehingga didapatkan model dengan kemampuan generalisasi yang lebih baik.

3.11. Performa (Evaluasi Model)

Untuk mengevaluasi kinerja model secara kuantitatif , digunakan empat metrik standar dalam masalah regresi :

3.11.1. MAE (Mean Absolute Error)

Kinerja model terutama diukur dengan dua tolok ukur, yaitu Mean Absolute Error (MAE) dan Root Mean Squared Error (RMSE). MAE mengukur rata-rata selisih absolut antara nilai prediksi dan nilai aktual. Dengan demikian, nilai MAE yang rendah menunjukkan kemampuan model untuk memberikan prediksi yang lebih mendekati nilai sebenarnya.

Perhitungan MAE dapat dinyatakan sebagai berikut :

$$MAE = \frac{1}{n} \sum_{i=1}^n |P_i - A_i| \quad (3.5)$$

Keterangan :

- n = Jumlah data rating dari user (rating asli dan rating prediksi)
- P_i = Nilai rating prediksi untuk user
- A_i = Nilai rating asli dari user

3.11.2. Root Mean Squared Error (RMSE)

Sementara itu, RMSE mengukur kesalahan dengan memberikan bobot lebih pada observasi outlier, sehingga memberikan wawasan lebih dalam terhadap kesalahan besar. Oleh karena itu, nilai RMSE yang rendah menunjukkan bahwa model dapat menangkap pola data dengan baik.

Perhitungan RMSE dapat dinyatakan sebagai berikut :

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (P_i - A_i)^2} \quad (3.6)$$

Keterangan :

- n = Jumlah data rating dari user (rating asli dan rating prediksi)
- P_i = Nilai rating prediksi untuk user
- A_i = Nilai rating asli dari user

3.11.3. Mean Absolute Percentage (MAPE)

MAPE mengukur rata-rata kesalahan dalam bentuk persentase. Metrik ini sangat intuitif karena tidak terikat pada skala data, sehingga memudahkan perbandingan tingkat kesalahan relatif. Nilai MAPE yang lebih kecil menunjukkan tingkat akurasi prediksi yang lebih tinggi.

$$MAPE = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad (3.7)$$

Keterangan :

n : Jumlah total data.

y_i : Nilai harga aktual pada data ke -i.

$\hat{y}_i$: Nilai harga prediksi pada data ke-i.

3.11.4. R-Squared (R^2)

Berbeda dengan metrik sebelumnya yang mengukur kesalahan, R-squared (atau koefisien determinasi) mengukur seberapa besar proporsi variansi pada variabel dependen (harga) yang dapat dijelaskan oleh model. Nilainya berkisar antara 0 hingga 1. Nilai R^2 yang mendekati 1 menunjukkan bahwa model sangat cocok dan mampu menjelaskan sebagian besar pergerakan data.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (3.8)$$

Keterangan :

y_i : Nilai harga aktual pada data ke-i.

$\hat{y}_i$: Nilai harga prediksi pada data ke -i.

$\bar{y}$: Rata-rata dari seluruh nilai harga aktual.

3.12. Analisis *Overfitting*

Sesuai dengan fokus penelitian, analisis *overfitting* dilakukan secara eksplisit melalui langkah-langkah berikut:

1. Perbandingan Metrik Latih vs. Uji: Nilai MAE, RMSE, dan R^2 akan dihitung untuk data latih dan data uji. Perbandingan antara kedua set nilai ini akan dilakukan. Jika nilai metrik pada data latih secara signifikan lebih baik (misalnya, RMSE jauh lebih rendah) dibandingkan pada data uji, ini merupakan indikator kuat adanya *overfitting*. Tujuannya adalah mencapai model dengan performa yang baik dan seimbang pada kedua set data.
2. Analisis *Hyperparameter*: *Hyperparameter* terbaik yang dipilih (terutama `reg_alpha`, `reg_lambda`, `num_leaves`, `max_depth`, `min_child_samples`) akan dianalisis untuk memahami bagaimana parameter tersebut berkontribusi dalam mengendalikan kompleksitas model dan mengurangi *overfitting*.

3. Peran *Early stopping*: Jika *early stopping* terjadi, akan dicatat pada iterasi seberapa pelatihan berhenti. Ini menunjukkan bahwa model telah mencapai titik di mana penambahan pohon lebih lanjut tidak lagi meningkatkan performa pada data baru, sehingga secara aktif mencegah *overfitting*.

BAB IV

HASIL DAN ANALISIS

Pada bab ini, akan disajikan hasil dari seluruh eksperimen yang telah dilakukan sesuai dengan metodologi yang diuraikan pada Bab III. Pembahasan akan berfokus pada hasil optimasi hyperparameter, evaluasi kinerja model pada tiga skenario pembagian data yang berbeda, analisis faktor-faktor yang memengaruhi prediksi, serta pembahasan mendalam mengenai fenomena *overfitting* dan *underfitting* yang ditemukan.

4.1. Hasil Optimasi Hyperparameter

Proses optimasi bertujuan untuk menemukan kombinasi hyperparameter terbaik yang dapat memaksimalkan performa prediksi seraya mengontrol kompleksitas model untuk mencegah *overfitting*. Dengan menggunakan teknik GridSearchCV pada data latih skenario 80:20, kombinasi hyperparameter terbaik yang ditemukan untuk model LightGBM adalah sebagai berikut.

Tabel 4. 1 Hasil optimasi hyperparameter


Parameter	Hasil
boosting_type	“gbdt”
learning_rate	0.1
max_depth	5
num_leaves	31
objective	“regression_L1”
reg_alpha	0.5
reg_lambda	0.5
min_child_samples	20

Dari hasil tersebut, dapat dianalisis bahwa proses optimasi cenderung memilih model yang terkendali. Pemilihan `max_depth` sebesar 5, `reg_lambda`

sebesar 0.5, dan `min_child_samples` sebesar 20 menunjukkan adanya preferensi terhadap model yang menerapkan regularisasi untuk mencegah kompleksitas berlebih dan membatasi pembentukan daun yang terlalu spesifik pada data latih. Hal ini merupakan langkah awal yang krusial dalam mitigasi *overfitting*.

4.1.1. Visualisasi proses optimasi Hyperparameter

Untuk memberikan pemahaman yang lebih mendalam mengenai proses pencarian hyperparameter terbaik, hasil dari `GridSearchCV` dapat divisualisasikan. Gambar 4.1 di bawah ini menyajikan sebuah heatmap yang menunjukkan bagaimana kombinasi dari dua hyperparameter kunci, yaitu `max_depth` (kedalaman pohon) dan `learning_rate` (laju pembelajaran), memengaruhi skor validasi silang (diukur dengan RMSE, di mana nilai lebih rendah lebih baik).



Gambar 4. 1 Heatmap hasil validasi silang `GridSearchCV`

Dari Gambar 4.1 heatmap tersebut, dapat diamati bahwa area dengan warna paling gelap (menandakan RMSE terendah) berada pada saat `max_depth` bernilai 5 dan `learning_rate` bernilai 0.1. Visualisasi ini mengkonfirmasi bahwa kombinasi hyperparameter yang dipilih pada Tabel 4.1 memang merupakan konfigurasi yang menghasilkan kinerja paling optimal selama proses validasi silang, sebelum diterapkan pada model final.

4.2. Hasil Kinerja Model

Model final dilatih menggunakan hyperparameter terbaik di atas dan dibandingkan dengan model standar (tanpa optimasi). Kinerja kedua model kemudian dievaluasi pada data latih dan data uji untuk mengukur akurasi serta menganalisis kemampuan generalisasinya di tiga skenario pembagian data.

4.3. Hasil Evaluasi Model Proporsi 80:20

Skenario ini merepresentasikan kondisi ideal dengan volume data latih terbesar. Hasil perbandingan kinerja disajikan pada Tabel 4.2 dan Tabel 4.3.

Tabel 4. 2 Hasil Evaluasi Model Dengan Optimasi Hyperparameter (80:20)

Metrik	Data Latih	Data Uji
MAPE	13.02%	6.95%
RMSE	0.2298	0.0370
MAE	0.0752	0.0286
R-squared (R^2)	0.8488	0.9187

Tabel 4. 3Hasil Evaluasi Model Tanpa Optimasi Hyperparameter (80:20)

Metrik	Data Latih	Data Uji
MAPE	24.41%	5.49%
RMSE	0.3388	0.0415
MAE	0.1310	0.0264
R-squared (R^2)	0.6713	0.8980

4.4. Hasil Evaluasi Model Proporsi 70:30

Pada skenario ini, volume data latih dikurangi. Hasil perbandingan kinerja disajikan pada Tabel 4.4 dan Tabel 4.5.

Tabel 4. 4Hasil Evaluasi Model Dengan Optimasi Hyperparameter (70:30)

Metrik	Data Latih	Data Uji
MAPE	9.17%	5.84%
RMSE	0.1571	0.0358
MAE	0.0558	0.0247
R-squared (R^2)	0.9377	0.9050

Tabel 4. 5 Hasil Evaluasi Model Tanpa Optimasi Hyperparameter (70:30)

Metrik	Data Latih	Data Uji
MAPE	10.08%	7.40%
RMSE	0.1766	0.0412
MAE	0.0601	0.0298
R-squared (R^2)	0.9213	0.8745

4.5. Hasil Evaluasi Model Proporsi 60:40

Skenario ini merepresentasikan kondisi dengan volume data latih paling terbatas. Hasil perbandingan kinerja disajikan pada Tabel 4.6 dan Tabel 4.7.

Tabel 4. 6 Hasil Evaluasi Model Dengan Optimasi Hyperparameter (60:40)

Metrik	Data Latih	Data Uji
MAPE	6.15%	6.49%
RMSE	0.2602	0.0492
MAE	0.0836	0.0318
R-squared (R^2)	0.8501	0.9184


Tabel 4. 7 Hasil Evaluasi Model Tanpa Optimasi Hyperparameter (60:40)

Metrik	Data Latih	Data Uji
--------	------------	----------

MAPE	7.73%	4.92%
RMSE	0.2864	0.0340
MAE	0.0972	0.0230
R-squared (R^2)	0.8185	0.9609

4.6. Analisis Kepentingan Fitur

Untuk mendapatkan pemahaman mengenai faktor-faktor yang paling memengaruhi prediksi, dilakukan analisis kepentingan fitur pada model dengan kinerja terbaik (model standar pada skenario 60:40). Hasilnya disajikan pada Gambar 4.1.



Gambar 4. 2Tingkat kepentingan fitur LightGBM

Dari gambar tersebut, terlihat bahwa Price_Lag1 (harga satu hari sebelumnya) merupakan fitur yang paling dominan. Hal ini sejalan dengan intuisi bahwa harga aset keuangan memiliki dependensi temporal jangka pendek yang sangat kuat. Fitur-fitur lain yang juga menunjukkan kontribusi signifikan adalah Open_Lag1, High_Lag1, dan Low_Lag1, yang menegaskan pentingnya konteks pergerakan harga harian dalam memodelkan pasar.

4.7. Pembahasan

Analisis terhadap hasil pengujian mengungkapkan dinamika yang kompleks antara volume data, optimasi, dan kinerja model, yang dapat dijelaskan melalui

konsep *underfitting* dan *overfitting*.

a. Analisis *Underfitting* pada Skenario 80:20

Pada skenario dengan volume data latih terbesar (80:20), bukti terjadinya *underfitting* terlihat jelas pada model tanpa optimasi (Tabel 4.2). Nilai R^2 pada data latih yang hanya sebesar 0.6713 menunjukkan bahwa model tersebut terlalu sederhana sehingga bahkan tidak mampu mempelajari pola dari data latihnya sendiri dengan baik. Proses optimasi terbukti esensial di sini, karena berhasil meningkatkan kompleksitas model sehingga mampu belajar dengan baik (R^2 latih naik menjadi 0.8488 pada Tabel 4.1) dan tetap mempertahankan generalisasi yang kuat pada data uji.

b. Analisis *overfitting* pada Skenario 60:40

Sebaliknya, pada skenario dengan data latih paling terbatas (60:40), bukti terjadinya *overfitting* terlihat pada model dengan optimasi (Tabel 4.5). Di sini, terjadi anomali di mana model standar tanpa optimasi (Tabel 4.6) justru menghasilkan kinerja yang jauh lebih superior pada data uji ($R^2 = 0.9609$) dibandingkan model yang dioptimasi ($R^2 = 0.9184$). Penurunan performa setelah optimasi ini adalah indikator kuat dari *overfitting*. Model yang dioptimasi menjadi terlalu kompleks untuk volume data yang terbatas, sehingga ia tidak hanya belajar pola (sinyal), tetapi juga mulai menghafal fluktuasi acak (*noise*) dari data latih. Proses 'menghafal' ini merusak kemampuan generalisasi model saat dihadapkan pada data uji yang baru. Sebaliknya, model standar yang lebih sederhana berhasil menghindari jebakan ini dan menjadi model terbaik.

c. Analisis Skenario Transisi 70:30


Skenario 70:30 berfungsi sebagai titik transisi. Di sini, model tanpa optimasi (Tabel 4.4) menunjukkan kinerja terendah dari keseluruhan penelitian ($R^2 = 0.8745$). Ini terjadi karena modelnya terlalu sederhana untuk menangkap semua pola yang ada di 70% data (*underfitting*), sementara model yang dioptimasi (Tabel 4.3) masih mendapatkan manfaat dari kompleksitasnya.

Secara keseluruhan, pembahasan ini menunjukkan bahwa tidak ada satu strategi pemodelan yang superior di semua kondisi. Terdapat sebuah trade-off yang

jelas: pada data besar, kompleksitas diperlukan untuk menghindari *underfitting*, namun pada data kecil, kesederhanaan lebih diutamakan untuk menghindari *overfitting*.

4.7.1. Tahapan pembuktian overfitting melalui kurva pembelajaran

Untuk membuktikan secara visual bagaimana proses overfitting terjadi, kurva pembelajaran (learning curve) dari model dianalisis. Gambar 4.3 di bawah ini menampilkan kurva pembelajaran untuk kasus yang paling signifikan, model teroptimasi pada skenario 60:40. Grafik ini memetakan nilai kesalahan (RMSE) pada data latih dan data uji untuk setiap iterasi (penambahan pohon) selama proses pelatihan.



Gambar 4. 3 Kurva pembelajaran model teroptimasi (Skenario 60:40)

Pada Gambar 4.3 dari kurva pembelajaran tersebut, bukti terjadinya overfitting terlihat sangat jelas. Garis RMSE Data Latih (biru) menunjukkan tren yang terus menurun seiring bertambahnya iterasi. Ini menandakan model semakin baik dalam 'menghafal' data latih. Sebaliknya, garis RMSE Data Uji (oranye) mencapai titik terendahnya pada sekitar iterasi ke-30, sebelum kemudian mulai stagnan.

Titik di mana kurva data uji berhenti membaik adalah momen di mana model mulai kehilangan kemampuan generalisasinya dan overfitting terjadi.

Mekanisme early stopping yang diterapkan, ditandai dengan garis putus-putus hijau, berhasil menghentikan pelatihan pada titik optimal tersebut. Namun, divergensi yang jelas antara kedua kurva ini secara visual membuktikan bahwa model yang dioptimasi secara fundamental sudah terlalu kompleks untuk volume data latih yang tersedia.

BAB V

KESIMPULAN DAN SARAN

Berdasarkan analisis dan pembahasan yang telah dilakukan pada bab-bab sebelumnya, dapat ditarik beberapa kesimpulan utama yang menjawab rumusan masalah penelitian, serta saran untuk pengembangan penelitian di masa depan.

5.1. Kesimpulan

Berdasarkan analisis data dan serangkaian eksperimen yang telah dilakukan, penelitian ini menghasilkan beberapa kesimpulan utama:

1. Model LightGBM dapat memprediksi harga Cardano, dengan kinerja prediksi tertinggi dari keseluruhan eksperimen dicapai oleh model standar (tanpa optimasi) pada skenario pembagian data 60:40. Model ini menghasilkan nilai R-squared (R^2) sebesar 0.9609 dan MAPE 4.92% pada data uji.
2. Pengaruh optimasi hyperparameter terhadap kinerja model bersifat kondisional. Pada skenario data besar (80:20), optimasi meningkatkan R^2 dari 0.8980 menjadi 0.9187. Namun, pada skenario data terbatas (60:40), optimasi yang sama justru menjadi kontra-produktif, menurunkan R^2 dari 0.9609 menjadi 0.9184, yang mengindikasikan terjadinya overfitting.
3. Kontribusi utama dari penelitian ini adalah bukti kuantitatif adanya trade-off antara kompleksitas model dan volume data. Temuan bahwa model yang lebih sederhana mengungguli model yang kompleks pada data terbatas membuktikan bahwa keseimbangan antara kedua faktor tersebut adalah penentu utama dari kemampuan generalisasi sebuah model prediksi.

5.2. Saran

Berdasarkan temuan dan keterbatasan dalam penelitian ini, berikut adalah beberapa saran untuk pengembangan penelitian di masa depan:

1. Penambahan Fitur Eksternal: Penelitian selanjutnya disarankan untuk

memperkaya model dengan menambahkan fitur eksternal di luar data harga historis. Fitur seperti data sentimen dari berita atau media sosial, data on-chain dari blockchain Cardano, atau indikator makroekonomi berpotensi meningkatkan akurasi dan ketangguhan model prediksi.

2. Pengujian Generalisasi pada Aset Lain: Untuk menguji generalisasi dari temuan ini, disarankan untuk menerapkan metodologi yang sama pada dataset aset kripto lain dengan karakteristik yang berbeda, seperti Bitcoin atau Ethereum . Hal ini akan memvalidasi apakah kesimpulan mengenai hubungan antara volume data dan *overfitting* merupakan sebuah prinsip umum atau hanya berlaku spesifik untuk Cardano.
3. Eksplorasi Metode Optimasi Lanjutan: Penelitian di masa depan dapat mengeksplorasi teknik optimasi hyperparameter yang lebih canggih seperti Optimasi Bayesian, yang mungkin lebih efisien daripada GridSearchCV dalam menemukan konfigurasi optimal.

Daftar Pustaka

- Alessandretti, L., Elbahrawy, A., Aiello, L. M., & Baronchelli, A. (2018). Understanding the behavior of cryptocurrency prices. *Scientific Reports*, 8(1), 1–8. <https://doi.org/10.1038/s41598-018-23068-0>
- Bentéjac, C., Csörgő, A., & Laurent, G. (2021). A comparative analysis of gradient boosting algorithms. *Artificial Intelligence Review*, 54(3), 1937–1967. <https://doi.org/10.1007/s10462-020-09896-5>
- Brown, D., & Hoskinson, C. (2017). *Cardano: A scientific approach to blockchain technology*. IOHK.
- Cardano Foundation. (n.d.). *The Cardano blockchain*. Diakses 8 Agustus 2025, dari <https://cardano.org/>
- Chen, T., He, T., Benesty, M., Khotilovich, V., & Tang, Y. (2020). *Machine learning in finance: A review*. *Journal of Financial Analysis*, 29(2), 202–215.
- Chen, Y., & Yang, Q. (2021). Exploring the effectiveness of LightGBM for short-term cryptocurrency forecasting. *Journal of Financial Data Science*, 3(2), 70–85. <https://doi.org/10.3905/jfds.2021.1.042>
- CoinMarketCap. (2023). *Cardano price*. Diakses 8 Agustus 2025, dari <https://coinmarketcap.com/currencies/cardano/>
- Dietterich, T. G. (2000). Ensemble methods in machine learning. In J. Kittler & F. Roli (Eds.), *Multiple classifier systems* (pp. 1–15). Springer. https://doi.org/10.1007/3-540-45014-9_1
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5), 1189–1232. [tautan mencurigakan telah dihapus]
- Guo, Z., & Wang, L. (2020). Boosting techniques for financial asset price prediction: A comparative study of LightGBM and XGBoost. *Proceedings of the International Conference on Financial Technology*.
- Huang, M., & Lin, T. (2022). Cryptocurrency price prediction using LightGBM with sentiment analysis. *Journal of Information and Telecommunication*, 6(4), 502–517. <https://doi.org/10.1080/24751839.2022.2078235>
- Hyndman, R. J., & Athanasopoulos, G. (2018). *Forecasting: principles and practice* (2nd ed.). OTexts.

Investing.com. (2024). *Cardano ADA/USD historical data*. Diakses 8 Agustus 2025, dari <https://www.investing.com/crypto/cardano/historical-data>

Ji, S., & Zhang, C. (2022). Bitcoin price prediction based on LightGBM. *Procedia Computer Science*, 199, 761–768. <https://doi.org/10.1016/j.procs.2022.01.095>

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T. Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. In *Advances in neural information processing systems 30*. Curran Associates, Inc.

Kumar, R., & Das, S. (2021). Predicting cryptocurrency prices using machine learning algorithms: A case study on LightGBM. *2021 International Conference on Communication, Control and Information Sciences (ICCSP)*. IEEE. <https://doi.org/10.1109/ICCSP50987.2021.9484377>

Li, X., & Wang, Y. (2020). Stock price prediction using LightGBM. *2020 5th IEEE International Conference on Big Data Analytics (ICBDA)*. IEEE. <https://doi.org/10.1109/ICBDA49062.2020.9101234>

Liu, Y., & Wu, F. (2022). Performance analysis of machine learning models in cryptocurrency price prediction. *Journal of Risk and Financial Management*, 15(5), 214. <https://doi.org/10.3390/jrfm15050214>

Mitchell, T. M. (1997). *Machine learning*. McGraw-Hill.

Nakamoto, S. (2008). *Bitcoin: A peer-to-peer electronic cash system*. <https://bitcoin.org/bitcoin.pdf>

Shen, J., & Li, Y. (2021). LightGBM model for high-frequency cryptocurrency price movement prediction. *Frontiers in Physics*, 9, 734735. <https://doi.org/10.3389/fphy.2021.734735>

Shumway, R. H., & Stoffer, D. S. (2017). *Time series analysis and its applications: With R examples* (4th ed.). Springer.

Wang, J., & Zhou, Y. (2022). LightGBM for volatility modeling in cryptocurrency markets. *Physica A: Statistical Mechanics and its Applications*, 592, 126839. <https://doi.org/10.1016/j.physa.2021.126839>

Xu, L., & Chen, Y. (2023). A study on the effectiveness of gradient boosting models for predicting digital asset prices. *Data Science in Finance and Economics*, 3(1), 25–40. <https://doi.org/10.3934/DSFE.2022020>

Yuan, Z., & Zhang, J. (2023). Using ensemble learning techniques for cryptocurrency market forecasting. *Applied Soft Computing*, 135, 110031. <https://doi.org/10.1016/j.asoc.2023.110031>

Zhang, Q., & Liu, X. (2020). Improving cryptocurrency price prediction with LightGBM and feature engineering. *2020 IEEE Symposium Series on Computational Intelligence (SSCI)*. IEEE.
<https://doi.org/10.1109/SSCI47803.2020.9308432>

Zhang, T., Li, S., Li, H., & Chen, Y. (2021). A novel approach for cryptocurrency price prediction using XGBoost and LightGBM. *Journal of Industrial Information Integration*, 23, 100224. <https://doi.org/10.1016/j.jii.2021.100224>

Zhang, Y., & Guo, Y. (2021). Research on stock price prediction based on LightGBM. *2021 2nd Information Communication Technologies Conference (ICTC)* (pp. 201–205). IEEE. <https://doi.org/10.1109/ICTC54260.2021.9704257>