

Identifikasi Support dan Resistance pada Saham Sektor Energi IDX Menggunakan Metode K-Means Clustering dan Backtesting

Marisa Premitasari¹, Ardi Fajar Maulana¹

¹ Program Studi Informatika, Institut Teknologi Nasional, Bandung, Indonesia
Email: marisa-premitasari@gmail.com, ardifjr27@gmail.com,

Abstrak— Sektor energi di Bursa Efek Indonesia (BEI) memiliki tingkat volatilitas yang tinggi karena sangat dipengaruhi oleh gejala harga komoditas global dan ketidakpastian kebijakan domestik. Analisis teknikal konvensional dalam menentukan level *support* dan *resistance* dinilai subjektif antar analis. Penelitian ini bertujuan mengoptimalkan penentuan area zona *support* dan *resistance* saham sektor energi menggunakan pendekatan K-Means Clustering. Pengujian performa dilakukan secara komparatif menggunakan skenario nilai K=2 hingga K=10 melalui metode *backtesting* terhadap data *out of sample* historis harian periode 27 Desember 2023 sampai 26 Desember 2025 pada 26 emiten sektor energi. Hasil penelitian menunjukkan bahwa variasi jumlah klaster (K) memengaruhi performa model dalam mengidentifikasi zona *Support* dan *Resistance*. Semakin besar nilai K, kemampuan model dalam mendeteksi sinyal cenderung menurun yang ditunjukkan oleh penurunan nilai *Recall* hingga 18,88% pada skenario K=10. Berdasarkan hasil evaluasi menggunakan *Confusion Matrix*, model dengan konfigurasi K=2 memberikan performa terbaik dengan rata-rata *F1-Score* sebesar 67,24%, *Precision* sebesar 86,01%, *Recall* sebesar 57,33%, dan *Accuracy* sebesar 72,86%.

Kata kunci— K-Means Clustering, Support Resistance, Backtesting, IDX.

I. PENDAHULUAN

Sektor energi di Bursa Efek Indonesia (BEI) yang didominasi komoditas minyak, gas, dan batu bara memiliki karakteristik pergerakan harga yang sangat fluktuatif. Pola pergerakan harga pada sektor ini sangat sensitif terhadap perubahan harga komoditas dunia, regulasi pemerintah, serta sentimen pasar global [1]. Selain faktor ekonomi makro, gejala pada pasar keuangan di negara berkembang sering kali diperparah oleh dinamika politik domestik dan ketidakpastian arah kebijakan negara [2]. Fenomena tersebut terlihat jelas pada pergerakan Indeks Harga Saham Gabungan (IHSG) saat merespons pengumuman pasangan calon presiden dan wakil presiden Indonesia yang memicu reaksi pelemahan akibat meningkatnya sikap kehati-hatian investor [3]. Ditambah dengan bergulirnya proses transisi energi nasional, ketidakpastian terhadap kinerja masa depan emiten energi semakin memperkuat risiko investasi [4]. Tingginya risiko fluktuasi harga ini menuntut penggunaan metode analisis yang presisi, di mana salah satu acuan utamanya adalah penentuan area pembalikan arah pergerakan saham [5].

Dalam analisis teknikal, penentuan titik balik harga tersebut bergantung pada dua konsep dasar, yaitu *support* dan *resistance*. *Support* didefinisikan sebagai area harga di mana

tekanan beli cukup kuat menahan penurunan, sedangkan *resistance* merupakan area di mana tekanan jual lebih tinggi sehingga membatasi tren kenaikan harga [6]. Kedua level ini menjadi acuan bagi investor untuk menentukan momentum beli atau jual hingga membatasi risiko kerugian [7]. Zona *support resistance* sangat vital, mayoritas analisis masih menentukan level *support resistance* secara konvensional atau menarik garis lurus manual pada titik tertinggi atau terendah secara visual [8]. Pendekatan tradisional ini dinilai sangat subjektif karena analis yang berbeda dapat menghasilkan level harga yang berbeda pada grafik saham yang sama [9] seperti pada Figure 1.



Fig. 1. Perbedaan Analisis Terhadap Penentuan Zona Support dan Resistance

Figure 1 menunjukkan adanya perbedaan hasil analisis dimana Analisis A menentukan zona support pada area 350 - 360 dan

zona resistance pada area 480 - 490, sedangkan Analisis B menentukan zona support pada area 370 - 390 dan zona resistance pada area 570 - 590. Kelemahan aspek subjektivitas pada penarikan garis manual ini kemudian mendorong urgensi pemanfaatan komputasi cerdas untuk menghasilkan perhitungan yang lebih objektif [10]. Untuk mengatasi keterbatasan tersebut, pendekatan berbasis *machine learning* terus berkembang, salah satunya melalui penerapan algoritma *K-Means Clustering* untuk mengelompokkan data harga historis [11],[12]. Performa algoritma berbasis jarak seperti *K-Means* ini terbukti meningkat ketepatannya secara signifikan setelah melalui proses standarisasi data menggunakan *Z-score* [13],[14]. Namun, kelemahan utama dari penelitian [11] dari *K-Means* standar adalah *output*-nya yang hanya berupa titik koordinat tunggal, padahal pada realitasnya harga saham selalu memantul di dalam suatu rentang area. Oleh karena itu, penelitian ini bertujuan untuk pembentukan zona *Support* dan *Resistance* dengan memanfaatkan nilai standar deviasi internal setiap klaster untuk menentukan batas rentang zona. Selanjutnya, model yang dihasilkan dievaluasi menggunakan data pengujian (*out of sample*) untuk menentukan konfigurasi jumlah klaster terbaik berdasarkan metrik *Confusion Matrix*. Guna mempertegas posisi kebaruan (*novelty*) riset ini dibandingkan dengan penelitian terdahulu pada Tabel 1 berikut.

TABLE I
PERBANDINGAN PENELITIAN TERKAIT DAN PENELITIAN INI

Peneliti & Tahun	Metode	Hasil Penelitian / Kontribusi
Öztürk (2024)	<i>K-Means Clustering</i> tanpa <i>preprocessing</i> .	Otomatisasi S/R berhasil, namun hasilnya berupa titik kaku dan rentan <i>noise</i> harga.
Wongoutong (2024)	<i>K-Means</i> dioptimasi penskalaan <i>Z-Score</i> .	Membuktikan <i>Z-Score</i> meningkatkan akurasi klasterisasi pada metodologi umum.
Letteri et al. (2023)	Simulasi <i>Backtesting</i> berbasis data historis bursa saham.	Berhasil menguji keandalan strategi transaksi konvensional secara objektif.
Penelitian ini (2026)	Integrasi <i>Pivot Points</i> , <i>Z-Score</i> , <i>K-Means</i> , Formulasi <i>Dynamic Width</i> (σ_{internal}), dan <i>Algorithmic Backtesting</i> .	Menghasilkan zona <i>Support</i> dan <i>Resistance</i> bebas <i>noise</i> yang teruji via <i>Confusion Matrix</i> pada 26 emiten energi.

II. METODE PENELITIAN

Penelitian ini menggunakan pendekatan *Hybrid Machine Learning Pipeline* atau penggabungan beberapa algoritma *Machine Learning* yang berbeda. Alur sistem dibangun untuk memproses data mentah pergerakan harga saham harian hingga menghasilkan pengujian performa area psikologis pasar modal secara objektif.

A. Desain Sistem

Arsitektur model yang diusulkan dalam penelitian ini dirancang menggunakan kerangka kerja *Hybrid Machine Learning Pipeline* yang mencakup tujuh tahapan pemrosesan berurutan. Secara prinsip, desain sistem ini mengintegrasikan metode pembersihan data dan pengelompokan otomatis (*unsupervised clustering*) [15]. Alur ini dibentuk supaya sistem tidak hanya mampu mengelompokkan data masa lalu, melainkan juga dapat mengenali saat diuji pada kondisi pasar saham yang bergerak dinamis. Logika urutan arsitektur sistem tersebut disajikan secara runtut pada Figure 2 berikut:




Fig. 2. Blok Diagram Desain Sistem

Proses dimulai dari tahap akuisisi data dan penyaringan awal untuk memastikan kecukupan data dari emiten Sektor Energi IDX yang digunakan. Selanjutnya, data pergerakan harga harian tersebut diekstraksi menjadi titik-titik *Pivot High* dan *Pivot Low* serta melalui proses penyaringan untuk menghilangkan fluktuasi harga yang bersifat minor. Agar skala nominal harga saham antar emiten yang berbeda signifikan dapat dibandingkan secara adil, dilakukan penskalaan fitur menggunakan standarisasi *Z-Score* sebelum data masuk ke tahap klasterisasi *K-Means*. Kemudian hasil titik pusat (*centroid*) dari iterasi *K-Means* kemudian dikonversi menjadi area rentang atas-bawah melalui formulasi batas ruang spasial dinamis (σ_{internal}). Rangkaian proses ini diakhiri dengan pengujian *backtesting* algoritmik pada data *out of sample* untuk mengevaluasi akurasi model menggunakan metrik *Confusion Matrix*.

B. Sumber Data

Data yang digunakan dalam penelitian ini merupakan data harga saham harian yang terdiri atas harga pembukaan (*Open*), harga tertinggi (*High*), harga terendah (*Low*), dan harga penutupan (*Close*). Rentang waktu pengambilan data historis dari 26 Desember 2019 hingga 26 Desember 2025 guna menangkap berbagai dinamika volatilitas harga pasar modal. Dari total 41 emiten pada Sektor Energi IDX, dilakukan penyaringan sampel, sistem menghitung jumlah baris data perdagangan harian yang tersedia. Emiten yang memiliki celah kosong (*missing values*) akibat suspensi perdagangan jangka panjang oleh otoritas bursa akan langsung dieleminasi [16] untuk memastikan emiten tetap aktif beroperasi dan diperdagangkan hingga akhir periode penelitian demi menjaga kelangsungan deteksi titik pivot, diperoleh 26 emiten valid yang memenuhi syarat untuk diproses lebih lanjut seperti pada Figure 3.




Fig. 3. Pemilihan Sumber Data

Basis data dari 26 emiten ini dibagi menjadi dua bagian. Data rentang tahun 26 Desember 2019 hingga 26 Desember 2023 dialokasikan sebagai data *in-sample* untuk mendeteksi pola historis dan melatih model *K-Means Clustering*. Sementara itu, data rentang tahun 27 Desember 2023 hingga 26 Desember 2025 dialokasikan sebagai *out of sample* yang digunakan khusus untuk menguji model melalui simulasi *backtesting*.

C. Ekstraksi Pola Dan Standarisasi Z-Score

Proses pemrosesan awal data (*data preprocessing*) pada penelitian ini dibagi menjadi dua tahapan utama, yaitu menggunakan metode *Pivot Points* dan penyamaan skala nilai melalui transformasi *Z-Score*.

Data pergerakan harga saham harian bersifat kontinu dan memiliki tingkat acak yang sangat tinggi (*market noise*). Guna mengurangi *noise* tersebut, data tren kontinu harus diekstraksi menjadi titik-titik pembalikan harga yang merepresentasikan area psikologis pasar. Penentuan titik *Pivot High* (titik harga tertinggi) dan *Pivot Low* (titik harga terendah) dilakukan dengan menerapkan metode pengecekan harga berukuran N hari (di mana dalam penelitian ini $N = 1$).

Secara matematis, sebuah titik harga rendah pada hari ke- t (L_t) akan dinyatakan sebagai *Pivot Low* (PL) jika nilai harga terendah tersebut lebih rendah dibandingkan dengan harga terendah pada n hari sebelum dan n hari sesudahnya. Logika kondisional ini dirumuskan sebagai berikut:

$$PL = L_t \text{ Jika } L_t < L_{t-i} \text{ dan } L_t < L_{t+i} \quad (1)$$

Sebaliknya, sebuah titik harga tinggi pada hari ke- t (H_t) akan dinyatakan sebagai *Pivot High* (PH) jika nilai tertinggi tersebut melebihi harga tertinggi pada n hari sebelum dan n hari sesudahnya, yang dirumuskan melalui kondisi:

$$PH = H_t \text{ Jika } H_t > H_{t-i} \text{ dan } H_t > H_{t+i} \quad (2)$$

Melalui proses penyaringan ini, perubahan harga yang kecil atau *noise* akan dihilangkan sehingga hanya titik-titik balik yang benar-benar menunjukkan perubahan tren atau pembalikan arah yang dipertahankan. Meskipun demikian, data yang dihasilkan masih memiliki perbedaan rentang harga antar emiten, sehingga perlu dilakukan penyamaan skala sebelum proses klusterisasi [17]. Hal ini karena setiap emiten pada Sektor Energi IDX memiliki kisaran harga yang berbeda, mulai dari puluhan hingga ribuan rupiah per lembar saham. Jika data tersebut langsung digunakan pada algoritma *K-Means*, perbedaan skala harga dapat memengaruhi hasil pengelompokan agar tidak bias terhadap data angka besar [18]. Oleh karena itu, dilakukan standarisasi menggunakan metode *Z-Score* agar seluruh data berada pada skala yang sama tanpa mengubah pola pergerakan harganya. Nilai standarisasi dihitung dari setiap harga asli (x) menggunakan rumus berikut.

$$Z = \frac{x - \mu}{\sigma} \quad (3)$$

Di mana μ menunjukkan nilai rata-rata data harga, sedangkan σ merupakan nilai standar deviasi dari data harga emiten. Setelah melalui proses standarisasi *Z-Score*, seluruh data dari 26 emiten memiliki skala yang sama sehingga dapat dibandingkan secara lebih adil pada proses klusterisasi untuk mengidentifikasi kelompok area psikologis pasar. Alur proses identifikasi *Pivot Points* dan standarisasi *Z-Score* pada tahap pengolahan data ditunjukkan secara ringkas pada Figure 4 berikut.




Fig. 4. Flowchart Deteksi Pivot Point dan Standarisasi Data

D. Pembentukan Zona

Setelah seluruh data titik balik harga berada pada skala yang sama melalui proses standarisasi *Z-Score*, tahap berikutnya adalah melakukan pengelompokan menggunakan algoritma *K-Means Clustering*. Algoritma ini bertujuan mengelompokkan data *Pivot Points* ke dalam beberapa kelompok K berdasarkan kemiripan karakteristiknya sehingga dapat membentuk area psikologis harga. Prosesnya diawali dengan menentukan sejumlah titik pusat kelompok (*centroid*), kemudian setiap data akan ditempatkan pada kelompok yang memiliki jarak paling dekat dengan *centroid* tersebut. Kedekatan antara data

dan *centroid* dihitung menggunakan metode *Euclidean Distance* dengan persamaan berikut.

$$d(x, c) = \sqrt{\sum_{i=1}^n (x_i - c_i)^2} \quad (4)$$

Pada persamaan tersebut, $d(x, c)$ menunjukkan jarak antara titik data x dan titik pusat kelompok (*centroid*) c . Setiap data akan dimasukkan ke dalam kelompok yang memiliki jarak paling dekat. Setelah seluruh data dikelompokkan, posisi *centroid* diperbarui berdasarkan nilai rata-rata data pada masing-masing kelompok. Proses ini dilakukan secara berulang hingga tidak ada lagi perubahan pada pembagian kelompok maupun posisi *centroid*, sehingga hasil klasterisasi menjadi stabil.

Karena algoritma *K-Means* memerlukan jumlah kelompok (K) yang ditentukan di awal, dilakukan pengujian beberapa nilai K , yaitu dari 2 hingga 10. Rentang tersebut dipilih karena $K = 2$ merupakan jumlah kelompok minimum untuk membentuk dua area, sedangkan batas maksimal $K = 10$ dipilih untuk menghindari pembentukan kelompok yang terlalu banyak (*over segmentation*). Jumlah kelompok yang terlalu besar dapat menyebabkan data terpecah menjadi kelompok-kelompok kecil sehingga pola utama pada data menjadi kurang terlihat dan hasil pengelompokan menjadi kurang representatif [19]. Setiap nilai K kemudian diuji melalui proses *backtesting*, dan nilai yang menghasilkan angka terbaik berdasarkan *Confusion Matrix* dipilih sebagai jumlah kelompok yang optimal. Setelah proses klasterisasi selesai, setiap *centroid* masih berupa satu titik pusat sehingga belum dapat menggambarkan suatu zona harga. Oleh karena itu, diperlukan penentuan batas bawah (*Min*) dan batas atas (*Max*) agar setiap *centroid* dapat direpresentasikan sebagai sebuah rentang zona psikologis harga menggunakan formulasi spasial dinamis:

$$Zona_{Max} = c + (w \cdot \sigma_{internal}) \quad (5)$$

$$Zona_{Min} = c - (w \cdot \sigma_{internal}) \quad (6)$$

Pada persamaan tersebut, c merupakan titik pusat (*centroid*) hasil klasterisasi, sedangkan w merupakan bobot yang digunakan untuk mengatur lebar rentang zona. Dengan menggunakan kedua parameter tersebut, sudah terbentuk sebuah zona *Support* dan *Resistance*, bukan lagi hanya berupa satu titik, tetapi berubah menjadi sebuah rentang zona psikologis harga. Zona ini kemudian digunakan sebagai acuan untuk mengidentifikasi potensi pembalikan arah harga saham. Untuk mengetahui efektivitas zona yang telah terbentuk, dilakukan proses *backtesting* menggunakan data pergerakan harga saham. Pengujian ini bertujuan untuk mengukur tingkat akurasi zona. Alur proses klasterisasi, pengujian variasi jumlah klaster, hingga pembentukan rentang zona ditunjukkan pada Figure 5 berikut.




Fig. 5. Flowchart Pembentukan Zona Support dan Resistance

E. Simulasi Pengujian

Pengujian model dilakukan untuk mengevaluasi kemampuan zona *Support* dan *Resistance* yang telah dihasilkan dalam mengenali pola pada data baru [20]. Oleh karena itu, digunakan data pengujian (*out of sample*) 27 Desember 2023 hingga 26 Desember 2025 yang tidak terlibat dalam proses pembentukan model, sehingga hasil evaluasi dapat menggambarkan kemampuan model dalam melakukan generalisasi terhadap data yang belum pernah dianalisis sebelumnya.

Pada tahap ini, sistem memproses data harga secara berurutan dan membandingkan posisi harga terhadap rentang zona yang telah dibentuk. Jika harga berada di dalam rentang zona *Support* atau *Resistance*, sistem akan menghasilkan sinyal prediksi. Selanjutnya, hasil prediksi tersebut dibandingkan dengan pergerakan harga, apakah prediksi yang diberikan sesuai dengan kondisi sebenarnya. Apabila harga bergerak sesuai dengan arah yang diprediksi, hasil tersebut dinyatakan sebagai prediksi yang benar. Sebaliknya, apabila harga bergerak di luar prediksi, hasil tersebut dinyatakan sebagai prediksi yang tidak sesuai.

Agar pengujian dilakukan secara konsisten pada 26 emiten Sektor Energi, digunakan beberapa skenario pengujian sebagaimana ditunjukkan pada Tabel 2.

TABLE II
SKENARIO PENGUJIAN

Komponen	Parameter
Dataset Pengujian	Data <i>out-of-sample</i> periode 27 Desember 2023 hingga 26 Desember 2025
Variasi Klaster	$K=2$ sampai $K=10$
Aturan Pengujian	Evaluasi berdasarkan rentang zona <i>Support</i> dan <i>Resistance</i>
Metrik Evaluasi	<i>Accuracy</i> , <i>Precision</i> , <i>Recall</i> , dan <i>F1-Score</i>

Hasil pengujian kemudian dievaluasi menggunakan *Confusion Matrix* yang terdiri atas empat kategori, yaitu *True Positive* (TP), *False Positive* (FP), *False Negative* (FN), dan

True Negative (TN). Pada penelitian ini, *True Positive* menunjukkan kondisi ketika zona *Support* atau *Resistance* berhasil memberikan prediksi yang sesuai dengan pergerakan harga. *False Positive* menunjukkan kondisi pergerakan harga tidak sesuai dengan prediksi tersebut. *False Negative* terjadi ketika terdapat pergerakan harga yang sesuai dengan karakteristik zona, namun tidak berhasil dikenali oleh model. Sementara itu, *True Negative* menunjukkan kondisi ketika model tidak memberikan prediksi dan kondisi tersebut memang tidak membentuk sinyal yang sesuai dengan kriteria zona.

Berdasarkan nilai pada *Confusion Matrix* tersebut, performa model diukur menggunakan metrik *Accuracy*, *Precision*, *Recall*, dan *F1-Score*. Metrik *Accuracy* digunakan untuk mengukur persentase prediksi yang berhasil diklasifikasikan dengan benar terhadap seluruh data pengujian,

Nilai dari keempat metrik tersebut digunakan untuk membandingkan performa model pada setiap variasi jumlah kluster K.

III. HASIL DAN PEMBAHASAN

Penelitian ini menerapkan gabungan algoritma *Machine Learning* untuk mengidentifikasi zona *Support* dan *Resistance* pada 26 emiten Sektor Energi IDX. Proses dimulai dengan identifikasi *Pivot Points* sebagai titik balik harga, dilanjutkan dengan standarisasi menggunakan metode *Z-Score* agar seluruh data memiliki skala yang sama sebelum dilakukan klusterisasi. Hasil klusterisasi kemudian dikembangkan menjadi rentang zona harga dan dievaluasi menggunakan data pengujian periode 27 Desember 2023 hingga 26 Desember 2025 untuk mengukur performa model berdasarkan metrik *Accuracy*, *Precision*, *Recall*, dan *F1-Score*.

A. Analisis Data dan Hasil Standarisasi

Proses analisis diawali dengan penyaringan emiten Sektor Energi yang terdaftar di Bursa Efek Indonesia (BEI). Penyaringan dilakukan untuk memastikan setiap emiten memiliki jumlah data *Pivot Points* yang cukup pada seluruh variasi jumlah kluster ($K=2$ hingga $K=10$). Emiten yang memenuhi kriteria tersebut digunakan sebagai data penelitian sehingga proses klusterisasi dapat dilakukan secara konsisten pada setiap variasi nilai K.

Data pergerakan harga saham dari setiap emiten kemudian diproses menggunakan metode *Pivot Points* dengan ukuran jendela waktu 1 hari untuk mengidentifikasi titik-titik pembalikan harga. Proses ini bertujuan mengurangi pengaruh perubahan harga yang bersifat sementara atau *noise* sehingga hanya titik balik yang merepresentasikan data asli yang dipertahankan. Hasil identifikasi *Pivot Points* ditampilkan pada Figure 6.




Fig. 6. Hasil dari Deteksi Pivot Points

Berdasarkan Figure 6 tersebut, sistem berhasil mengidentifikasi titik harga tertinggi (*Pivot High*) dan titik terendah (*Pivot Low*) sebagai dasar pembentukan zona *Support* dan *Resistance* pada tahap selanjutnya.

Hasil identifikasi *Pivot Points* menunjukkan bahwa setiap emiten memiliki rentang harga yang berbeda, mulai dari puluhan hingga ribuan rupiah per lembar saham. Oleh karena itu, dilakukan standarisasi menggunakan metode *Z-Score* agar seluruh data berada pada skala yang sama sebelum proses klusterisasi. Hasil standarisasi ditampilkan pada Figure 7.




Fig. 7. Perbandingan Data Sebelum dan Setelah Standarisasi

Berdasarkan Figure 7 seluruh data berhasil ditransformasikan ke dalam skala yang seragam dengan nilai rata-rata (*mean*) 0. Kondisi ini membuat setiap emiten memiliki skala yang setara sehingga proses klusterisasi menggunakan algoritma *K-Means* dapat dilakukan secara lebih objektif.

B. Implementasi Klusterisasi K-Means

Proses klusterisasi dilakukan dengan menguji variasi jumlah kluster (K) dari 2 hingga 10 menggunakan algoritma *K-Means* pada data *Pivot Points*. Setiap variasi nilai K menghasilkan pola pengelompokan yang berbeda sehingga dapat digunakan untuk melihat pengaruh jumlah kluster terhadap hasil yang diperoleh. Visualisasi hasil klusterisasi untuk setiap nilai K disajikan secara berurutan dibawah ini.




Fig. 8. Hasil Pengelompokan Data dengan Jumlah Kluster 2




Fig. 9. Hasil Pengelompokan Data dengan Jumlah Kluster 3




Fig. 13. Hasil Pengelompokan Data dengan Jumlah Kluster 7




Fig. 10. Hasil Pengelompokan Data dengan Jumlah Kluster 4




Fig. 14. Hasil Pengelompokan Data dengan Jumlah Kluster 8




Fig. 11. Hasil Pengelompokan Data dengan Jumlah Kluster 5




Fig. 15. Hasil Pengelompokan Data dengan Jumlah Kluster 9




Fig. 12. Hasil Pengelompokan Data dengan Jumlah Kluster 6




Fig. 16. Hasil Pengelompokan Data dengan Jumlah Kluster 10

Setiap titik *Pivot Points* berhasil dikelompokkan ke dalam kluster sesuai dengan hasil proses *K-Means*. Perbedaan kluster ditunjukkan dengan warna yang berbeda sehingga memudahkan dalam melihat sebaran data pada setiap kelompok. Selain itu, terlihat bahwa semakin besar nilai *K* yang digunakan, semakin banyak kluster yang terbentuk. Akibatnya, pembagian data menjadi lebih rinci karena setiap kluster mencakup jumlah titik data yang lebih sedikit dibandingkan variasi nilai *K* yang lebih rendah.

Hasil proses *K-Means* menghasilkan titik pusat (*centroid*) pada setiap kluster yang merepresentasikan pusat sebaran data *Pivot Points*. Berdasarkan visualisasi, posisi *centroid* berada di sekitar area yang memiliki konsentrasi data lebih tinggi pada masing-masing kelompok.

Hasil klasterisasi menunjukkan bahwa proses standarisasi *Z-Score* data dari seluruh emiten dikelompokkan pada skala yang sama meskipun memiliki rentang harga yang berbeda. Setiap variasi nilai *K* menghasilkan sejumlah *centroid* yang mewakili pusat dari masing-masing kluster. Nilai *centroid* tersebut kemudian digunakan sebagai dasar untuk menentukan batas bawah (*Min*) dan batas atas (*Max*), sehingga setiap kluster dapat direpresentasikan sebagai zona *Support* dan *Resistance* pada tahap pemetaan berikutnya.

C. Pemetaan Zona Rentang Dinamis

Nilai *centroid* yang diperoleh dari proses *K-Means* pada Figure 17 ditandai dengan tanda x pada masing-masing kelompok.




Fig. 17. Nilai Titik Centroid Pada Setiap Kluster

Selanjutnya digunakan untuk membentuk rentang zona *Support* dan *Resistance*. Setiap *centroid* dikembangkan menjadi batas bawah (*Min*) dan batas atas (*Max*) menggunakan standar deviasi internal dari masing-masing kluster. Hasil perhitungan tersebut kemudian dikonversi kembali ke skala harga asli sehingga rentang zona dapat direpresentasikan dalam satuan rupiah. Proses pembentukan batas zona ditampilkan pada Figure 18.




Fig. 18. Zona yang Terbentuk di Area Titik Centroid

Berdasarkan Figure 18, batas bawah (*Min*) dan batas atas (*Max*) terbentuk di sekitar posisi *centroid*, sehingga setiap kluster tidak lagi direpresentasikan sebagai satu titik, tetapi sebagai sebuah rentang zona. Lebar rentang yang dihasilkan menyesuaikan dengan penyebaran data pada masing-masing kluster, sehingga setiap zona memiliki batas yang berbeda. Rentang zona inilah yang selanjutnya digunakan sebagai acuan pada proses pengujian model.

Rentang zona yang telah diperoleh kemudian ditampilkan pada grafik pergerakan harga saham untuk memperlihatkan posisi zona *Support* dan *Resistance* terhadap data harga aktual. Hasil visualisasi tersebut disajikan pada Figure 19.




Fig. 19. Zona Support dan Resistance yang Sudah Terbentuk

Berdasarkan Figure 19, pergerakan harga saham ditampilkan dalam bentuk garis, sedangkan zona *Support* dan *Resistance* divisualisasikan sebagai area berwarna hasil perhitungan batas bawah (*Min*) dan batas atas (*Max*). Area berwarna hijau menunjukkan zona *Support*, sedangkan area berwarna merah menunjukkan zona *Resistance*. Visualisasi ini memperlihatkan bahwa rentang zona yang terbentuk mengikuti sebaran pergerakan harga historis sehingga dapat digunakan sebagai acuan pada proses pengujian model.

Pada konfigurasi *K=2*, data *Pivot Points* terbagi menjadi dua kluster yang menggambarkan zona *Support* dan *Resistance*. Karena jumlah kluster yang digunakan relatif sedikit, rentang zona yang dihasilkan cenderung lebih lebar sehingga mencakup lebih banyak titik *Pivot Points*. Hasil ini menunjukkan bahwa pembentukan zona telah mengikuti sebaran data historis pada masing-masing kluster. Rentang zona yang diperoleh selanjutnya digunakan sebagai dasar pada proses pengujian model untuk mengevaluasi performanya.

D. Evaluasi Performa Model

Evaluasi model dilakukan untuk mengukur kemampuan zona *Support* dan *Resistance* yang telah terbentuk dalam mengidentifikasi pergerakan harga pada data pengujian (*out-of-sample*). Pengujian dilakukan menggunakan data periode 27 Desember 2023 hingga 26 Desember 2025, kemudian hasil prediksi dibandingkan dengan pergerakan harga aktual. Performa model diukur menggunakan *Confusion Matrix* yang terdiri atas metrik *Accuracy*, *Precision*, *Recall*, dan *F1-Score* kemudian hasil *Confusion Matrix* pada masing-masing nilai K dianalisis untuk melihat pengaruh jumlah kluster terhadap performa model.




Fig. 20. Confusion Matrix K2

Berdasarkan Figure 20, hasil pengujian pada konfigurasi K=2 menghasilkan nilai *True Positive* (TP) sebesar (4315), *True Negative* (TN) sebesar (4583), *False Positive* (FP) sebesar (528), dan *False Negative* (FN) sebesar (2783). Berdasarkan nilai tersebut, model memperoleh *Accuracy* sebesar 72,86%, *Precision* sebesar 86,01%, *Recall* sebesar 57,33%, dan *F1-Score* sebesar 67,24%.




Fig. 21. Confusion Matrix K3

Berdasarkan Figure 21, hasil pengujian pada konfigurasi K=3 menghasilkan nilai *True Positive* (TP) sebesar (3497), *True Negative* (TN) sebesar (5093), *False Positive* (FP) sebesar (481), dan *False Negative* (FN) sebesar (3144). Berdasarkan nilai tersebut, model memperoleh *Accuracy* sebesar 70,32%, *Precision* sebesar 84,26%, *Recall* sebesar 48,35%, dan *F1-Score* sebesar 58,76%.




Fig. 22. Confusion Matrix K4

Berdasarkan Figure 22, hasil pengujian pada konfigurasi K=4 menghasilkan nilai *True Positive* (TP) sebesar (2497) *True Negative* (TN) sebesar (5623), *False Positive* (FP) sebesar (604), dan *False Negative* (FN) sebesar (3498). Berdasarkan nilai tersebut, model memperoleh *Accuracy* sebesar 66,44%, *Precision* sebesar 77,26%, *Recall* sebesar 38,88%, dan *F1-Score* sebesar 49,60%.




Fig. 23. Confusion Matrix K5

Berdasarkan Figure 23, hasil pengujian pada konfigurasi K=5 menghasilkan nilai *True Positive* (TP) sebesar (1794), *True Negative* (TN) sebesar (6052), *False Positive* (FP) sebesar (629), dan *False Negative* (FN) sebesar (3752). Berdasarkan nilai tersebut, model memperoleh *Accuracy* sebesar 64,17%, *Precision* sebesar 73,71%, *Recall* sebesar 31,08%, dan *F1-Score* sebesar 41,89%.




Fig. 24. Confusion Matrix K6

Berdasarkan Figure 24, hasil pengujian pada konfigurasi $K=6$ menghasilkan nilai *True Positive* (TP) sebesar (1733), *True Negative* (TN) sebesar (6099), *False Positive* (FP) sebesar (614), dan *False Negative* (FN) sebesar (3786). Berdasarkan nilai tersebut, model memperoleh *Accuracy* sebesar 64,03%, *Precision* sebesar 72,94%, *Recall* sebesar 30,04%, dan *F1-Score* sebesar 40,79%.




Fig. 25. Confusion Matrix K7

Berdasarkan Figure 25, hasil pengujian pada konfigurasi $K=7$ menghasilkan nilai *True Positive* (TP) sebesar (1651), *True Negative* (TN) sebesar (6143), *False Positive* (FP) sebesar (607), dan *False Negative* (FN) sebesar (3829). Berdasarkan nilai tersebut, model memperoleh *Accuracy* sebesar 63,73%, *Precision* sebesar 72,25%, *Recall* sebesar 28,99%, dan *F1-Score* sebesar 39,71%.




Fig. 26. Confusion Matrix K8

Berdasarkan Figure 26, hasil pengujian pada konfigurasi $K=8$ menghasilkan nilai *True Positive* (TP) sebesar (1273), *True Negative* (TN) sebesar (6403), *False Positive* (FP) sebesar (562), dan *False Negative* (FN) sebesar (3989). Berdasarkan nilai tersebut, model memperoleh *Accuracy* sebesar 62,78%, *Precision* sebesar 68,21%, *Recall* sebesar 23,29%, dan *F1-Score* sebesar 32,75%.




Fig. 27. Confusion Matrix K9

Berdasarkan Figure 27, hasil pengujian pada konfigurasi $K=9$ menghasilkan nilai *True Positive* (TP) sebesar (1204), *True Negative* (TN) sebesar (6592), *False Positive* (FP) sebesar (551), dan *False Negative* (FN) sebesar (4024). Berdasarkan nilai tersebut, model memperoleh *Accuracy* sebesar 62,59%, *Precision* sebesar 67,15%, *Recall* sebesar 22,19%, dan *F1-Score* sebesar 31,53%.




Fig. 28. Confusion Matrix K10

Berdasarkan Figure 28, hasil pengujian pada konfigurasi $K=10$ menghasilkan nilai *True Positive* (TP) sebesar (1024), *True Negative* (TN) sebesar (6592), *False Positive* (FP) sebesar (528), dan *False Negative* (FN) sebesar (4084). Berdasarkan nilai tersebut, model memperoleh *Accuracy* sebesar 62,28%, *Precision* sebesar 62,86%, *Recall* sebesar 18,88%, dan *F1-Score* sebesar 27,48%.

IV. KESIMPULAN

Penelitian ini berhasil menerapkan algoritma *K-Means Clustering* untuk membentuk zona *Support* dan *Resistance* pada saham Sektor Energi yang terdaftar di Bursa Efek Indonesia. Proses penelitian diawali dengan ekstraksi *Pivot Points* sebagai representasi titik perubahan harga, kemudian dilakukan standarisasi menggunakan metode *Z-Score* agar seluruh data memiliki skala yang seragam sebelum dikelompokkan. Selanjutnya, hasil klusterisasi digunakan untuk membentuk rentang zona yang kemudian dievaluasi menggunakan data pengujian (*out of sample*) periode 27 Desember 2023 hingga 26 Desember 2025. Rekapitulasi hasil evaluasi pada setiap variasi jumlah kluster disajikan pada

Tabel 3.

TABLE III
HASIL EVALUASI PENGAJUAN SETIAP KONFIGURASI JUMLAH KLASTER

Konfigurasi	Accuracy	Precision	Recall	F1-Score
K2	72,86%	86,01%	57,33%	67,24%
K3	70,32%	84,26%	48,35%	58,76%
K4	66,44%	77,26%	38,88%	49,60%
K5	64,17%	73,71%	31,08%	41,89%
K6	64,03%	72,94%	30,04%	40,79%
K7	63,73%	72,25%	28,99%	39,71%
K8	62,78%	68,21%	23,29%	32,75%
K9	62,59%	67,15%	22,19%	31,53%
K10	62,28%	62,86%	18,88%	27,48%

Berdasarkan Tabel 3, setiap variasi jumlah klaster menghasilkan nilai *Accuracy*, *Precision*, *Recall*, dan *F1-Score* yang berbeda. Konfigurasi K=2 memberikan hasil terbaik dengan *Accuracy* sebesar 72,86%, *Precision* sebesar 86,01%, *Recall* sebesar 57,33%, dan *F1-Score* sebesar 67,24%. Sementara itu, peningkatan jumlah klaster hingga K=10 menunjukkan kecenderungan penurunan nilai pada sebagian besar metrik evaluasi, terutama *Recall* dan *F1-Score*. Perbandingan performa model untuk seluruh variasi jumlah klaster ditampilkan pada Figure 29.




Fig. 29. Perbandingan Hasil Evaluasi Model

Berdasarkan Figure 29, terlihat bahwa performa model cenderung menurun seiring bertambahnya jumlah klaster. Nilai *Accuracy*, *Recall*, dan *F1-Score* mengalami penurunan dari konfigurasi K=2 hingga K=10. Hasil tersebut menunjukkan bahwa penggunaan jumlah klaster yang terlalu banyak menghasilkan pembagian zona yang semakin sempit sehingga memengaruhi kemampuan model dalam mengidentifikasi pergerakan harga.

Secara keseluruhan, konfigurasi K=2 dipilih sebagai model terbaik karena memberikan nilai *Accuracy*, *Precision*, *Recall*, dan *F1-Score* tertinggi dibandingkan konfigurasi lainnya. Hasil tersebut menunjukkan bahwa pembagian data ke dalam dua klaster mampu menghasilkan kualitas pengelompokan dan

kinerja klasifikasi yang paling baik pada penelitian ini.

REFERENSI

- [1] A. Awan, F. Bashir, N. Shahbaz, and I. Nasim, "The Macroeconomic Determinants of Stock Price Volatility in Pakistan: An Empirical Investigation," *IUB Journal of Social Sciences*, vol. 5, no. 2, pp. 205–221, Dec. 2023, doi: 10.52461/ijoss.v5i2.2349.
- [2] H. Ahir, N. Bloom, and D. Furceri, "60 Years of Uncertainty Our new index provides novel insights into an amorphous concept," Mar. 2020. Accessed: Dec. 25, 2025. [Online]. Available: <https://www.imf.org/external/pubs/ft/fandd/2020/03/pdf/imf-launches-world-uncertainty-index-wui-furceri.pdf>
- [3] A. Rochimah and I. Yuliana, "Eleven sectors' reaction to the political event 2023: evidence from Indonesia Stock Exchange," *Journal of Accounting and Investment*, vol. 25, no. 2, pp. 526–550, May 2024, doi: 10.18196/jai.v25i2.21000.
- [4] Sisdwinugraha et al, "Navigating Indonesia's Energy Transition at the Crossroads: A Pivotal Moment for Redefining the Future," vol. 5, p. 2025, 2025, Accessed: Jan. 01, 2026. [Online]. Available: <https://iesr.or.id/wp-content/uploads/2024/12/Indonesia-Energy-Transition-Outlook-2025-Digital-Version.pdf>
- [5] Harsh Gupta, Mrs. R Aafrein, Mrs. Rashmi Kumari, Mr. Swapnil Rajput, and Mrs. Nupur Puri, "Forecasting Commodity Prices using Machine Learning," *Int. J. Sci. Res. Sci. Technol.*, pp. 81–89, 2024, doi: 10.32628/ijrst52411110.
- [6] I Kadek Dwik Darmawan and Henny Rahyuda, "Technical Analysis of Stock Price Movements Using Fibonacci Retracement and Moving Average Convergence Divergence Approaches," *International Journal of Economics, Management and Accounting*, vol. 1, no. 4, pp. 430–449, Oct. 2024, doi: 10.61132/ijema.v1i4.293.
- [7] N. Nanda, "Strategi Momentum Dan Strategi Volatilitas Momentum Pada Saham Indeks Lq 45," *Jurnal Ilmu Manajemen*, vol. 9, no. 4, pp. 1308–1318, 2021, doi: 10.26740/jim.v9n4.p1308-1318.
- [8] S. Saqan, "Using Machine Learning to Locate Support and Resistance Lines for Stocks," 2021. [Online]. Available: <https://www.suhailsaqan.com/blog/ml/>
- [9] V. Sim, "Using K-means Clustering to Create Support and Resistance," Sep. 2020. [Online]. Available: <https://towardsdatascience.com/using-k-means-clustering-to-create-support-and-resistance-b13fdeba12/>
- [10] Y. E. Akdoğan, "WHEN MACHINES LEARN TECHNICAL ANALYSIS: AN APPLICATION ON TECHNICAL ANALYSIS WITH MACHINE LEARNING IN BORSA ISTANBUL," *Trakya Üniversitesi Sosyal Bilimler Dergisi*, vol. 27, no. IERFM 2025 Özel Sayı, pp. 275–302, Mar. 2025, doi: 10.26468/trakyasobed.1514346.
- [11] C. Öztürk, "Market Analysis with K-Means Clustering Algorithm: Identifying Support and Resistance Levels," Feb. 2024. [Online]. Available: <https://medium.com/@cemalozturk/market-analysis-with-k-means-clustering-algorithm-identifying-support-and-resistance-levels-f49b963924f5>
- [12] S. E. Saqila, I. P. Ferina, and A. Iskandar, "Analisis Perbandingan Kinerja Clustering Data Mining Untuk Normalisasi Dataset," *Jurnal Sistem Komputer dan Informatika (JSON)*, vol. 5, no. 2, p. 356, 2023, doi: 10.30865/json.v5i2.6919.
- [13] C. Wongoutong, "The impact of neglecting feature scaling in k-means clustering," *PLoS One*, vol. 19, no. 12, Dec. 2024, doi: 10.1371/journal.pone.0310839.
- [14] B. Math, O. Bevinakatti, S. Hosamani, and P. Patil, "Stock Market Prediction Using Machine Learning," *2024 5th International Conference for Emerging Technology, INCET 2024*, 2024, doi: 10.1109/INCET61516.2024.10593215.
- [15] Roopa Devi E M, "a Comprehensive Hybrid Machine Learning Model for Stock Price Prediction," *Journal of Informatics Education and Research*, vol. 5, no. 1, pp. 2720–2727, 2025, doi: 10.52783/jier.v5i1.2279.
- [16] M. Lee, J. Lin, and V. Stolz, "Evaluation of k-means time series clustering based on z-normalization and NP-Free," no. 3, 2024.
- [17] K. Yan et al., "Flexible Target Prediction for Quantitative Trading in the American Stock Market: A Hybrid Framework Integrating Ensemble Models, Fusion Models and Transfer Learning," *Entropy*, vol. 28, no. 1, pp. 1–21, 2026, doi: 10.3390/e28010084.

- [18] D. C. Alamsyah, H. Firmansyah, and S. Artikel, "Pergerakan Saham indonesia Menggunakan Metode K-Means Clustering Indonesian Stock Movement Using K-Means Clustering Method INFORMASI ARTIKEL ABSTRAK", [Online]. Available: <http://jurnal.utdtegal.ac.id/>
- [19] B. Phanthavong, S. Sengmanotham, S. Lusavong, and P. Souphamith, "Efficiency Evaluation of K-Means, K-Medians, and K-Mode Clustering Methods Using SSD," 2024, [Online]. Available: www.ijdsdr.org
- [20] Q. Chen, "Stock Price Prediction: A Comprehensive Review of Methods and Trends," *FinTech and Sustainable Innovation*, vol. 00, no. November 2025, pp. 1–12, 2026, doi: 10.47852/bonviewfsi62027630.