


***LIGHTWEIGHT HYBRID EEGNET-TCNET DENGAN  
EFFICIENT CHANNEL ATTENTION UNTUK KLASIFIKASI  
MOTOR IMAGERY BERDASARKAN  
ELECTROENCEPHALOGRAM***

**PROPOSAL TUGAS AKHIR**



**Oleh:**

**MUHAMAD RAMADIKA A.**

**152022101**

**PROGRAM STUDI INFORMATIKA  
FAKULTAS TEKNOLOGI INDUSTRI  
INSTITUT TEKNOLOGI NASIONAL  
BANDUNG**

**2025**

## KATA PENGANTAR

Puji dan syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa, karena atas berkat, rahmat, dan karunia-Nya, penulis dapat menyelesaikan penyusunan Proposal Tugas Akhir ini dengan judul “*Lightweight Hybrid EEGNet-TCNet Dengan Efficient Channel Attention Untuk Klasifikasi Motor Imagery Berdasarkan Electroencephalogram*”.

Proposal ini disusun sebagai salah satu syarat untuk melaksanakan penelitian Tugas Akhir pada Program Studi Informatika, Institut Teknologi Nasional (Itenas) Bandung. Penelitian ini berfokus pada pengembangan arsitektur *deep learning* hibrida yang mengintegrasikan EEGNet, *Temporal Convolutional Network* (TCN), dan mekanisme *Efficient Channel Attention* (ECA) untuk meningkatkan akurasi klasifikasi sinyal EEG pada perangkat *consumer-grade*.

Penulis menyadari bahwa penyusunan proposal ini tidak lepas dari bantuan, bimbingan, dan dukungan dari berbagai pihak. Oleh karena itu, pada kesempatan ini penulis ingin menyampaikan rasa terima kasih yang sebesar-besarnya kepada:

1. Ibunda tercinta serta seluruh keluarga besar, yang senantiasa memberikan kasih sayang, doa yang tiada henti, serta dukungan moril dan materiil yang menjadi kekuatan utama bagi penulis dalam menempuh pendidikan dan menyelesaikan proposal ini.
2. Bapak Yusup Miftahuddin, S.Kom., M.T., yang telah meluangkan waktu, tenaga, dan pikiran untuk memberikan bimbingan, arahan, serta masukan yang sangat berharga.
3. Seluruh Dosen Program Studi Informatika Itenas, yang telah dengan ikhlas membagikan ilmu pengetahuan dan pengalaman.
4. Seluruh anggota Himpunan Mahasiswa Informatika (HMIF) Itenas, atas kebersamaan, dukungan, dan pengalaman berorganisasi yang telah mewarnai perjalanan perkuliahan penulis.

5. Seluruh Mahasiswa Informatika Itenas Angkatan 2022, rekan-rekan seperjuangan yang telah memberikan semangat, inspirasi, dan diskusi yang membangun.

Penulis menyadari bahwa proposal ini masih jauh dari kesempurnaan. Oleh karena itu, penulis sangat mengharapkan kritik dan saran yang membangun demi perbaikan penelitian ini ke depannya.

Akhir kata, semoga proposal ini dapat diterima dan penelitian yang direncanakan dapat memberikan manfaat bagi pengembangan ilmu pengetahuan serta almamater tercinta.

Bandung, Desember 2025

Penulis

## DAFTAR ISI

|                                                                 |    |
|-----------------------------------------------------------------|----|
| KATA PENGANTAR.....                                             | 1  |
| DAFTAR ISI .....                                                | 4  |
| DAFTAR GAMBAR .....                                             | 7  |
| DAFTAR TABEL.....                                               | 8  |
| BAB I .....                                                     | 9  |
| 1.1 Latar Belakang .....                                        | 9  |
| 1.2 Rumusan Masalah .....                                       | 13 |
| 1.3 Ruang Lingkup.....                                          | 13 |
| 1.4 Tujuan Penelitian.....                                      | 14 |
| 1.5 Sistematika Penulisan .....                                 | 14 |
| BAB II.....                                                     | 16 |
| 2.1 <i>Brain-Computer Interface</i> (BCI) .....                 | 23 |
| 2.2 <i>Electroencephalography</i> (EEG).....                    | 24 |
| 2.2.1 Prinsip Kerja dan Karakteristik.....                      | 25 |
| 2.2.2 Perangkat EEG .....                                       | 26 |
| 2.2.3 <i>Muse S Gen 2 Headband</i> .....                        | 27 |
| 2.3 <i>Motor Imagery</i> (MI).....                              | 28 |
| 2.4 <i>Preprocessing Sinyal Electroencephalogram</i> (EEG)..... | 28 |
| 2.4.1 <i>Filtering</i> .....                                    | 29 |
| 2.4.2 <i>Artifact Removal</i> .....                             | 29 |
| 2.4.3 <i>Epoching dan Windowing</i> .....                       | 30 |
| 2.4.4 Normalisasi Data .....                                    | 31 |
| 2.5 <i>Deep Learning</i> Untuk Klasifikasi EEG .....            | 32 |
| 2.5.1 <i>Convolutional Neural Networks</i> (CNN).....           | 32 |

|                                                          |    |
|----------------------------------------------------------|----|
| 2.5.2 <i>Temporal Convolutional Networks (TCN)</i> ..... | 33 |
| 2.5.3 <i>Attention Mechanisms</i> .....                  | 33 |
| 2.6 <i>Arsitektur Deep Learning</i> .....                | 34 |
| 2.6.1 EEGNet .....                                       | 34 |
| 2.6.2 TCNet.....                                         | 36 |
| 2.6.3 <i>Efficient Channel Attention (ECA)</i> .....     | 39 |
| 2.7 <i>Evaluasi Model BCI</i> .....                      | 41 |
| 2.7.1 <i>Within-Subject Classification</i> .....         | 41 |
| 2.7.2 <i>Cross-Subject Classification</i> .....          | 42 |
| 2.7.3 <i>Metrik Evaluasi</i> .....                       | 43 |
| 3.1 <i>Kerangka Penelitian</i> .....                     | 45 |
| 3.2 <i>Pengumpulan Data</i> .....                        | 47 |
| 3.2.1 Dataset.....                                       | 47 |
| 3.2.2 <i>Perangkat Keras</i> .....                       | 48 |
| 3.2.3 <i>Protokol Eksperimen</i> .....                   | 49 |
| 3.2.4 <i>Pemilihan Trials dan Subjek</i> .....           | 50 |
| 3.3 <i>Preprocessing Sinyal</i> .....                    | 50 |
| 3.3.1 <i>Bandpass Filtering</i> .....                    | 50 |
| 3.3.2 <i>Artifact Removal</i> .....                      | 51 |
| 3.3.3 <i>Epoching dan Temporal Windowing</i> .....       | 51 |
| 3.3.4 <i>Normalization</i> .....                         | 52 |
| 3.4 <i>Dataset</i> .....                                 | 52 |
| 3.4.1 <i>Within-Subject</i> .....                        | 53 |
| 3.4.2 <i>Stratified 5-Fold Cross-Validation</i> .....    | 53 |
| 3.5 <i>Augmentasi Data</i> .....                         | 53 |

|                                              |    |
|----------------------------------------------|----|
| 3.5.1 <i>Time Shifting</i> .....             | 54 |
| 3.5.2 <i>Amplitude Scaling</i> .....         | 54 |
| 3.5.3 <i>Additive Noise</i> .....            | 54 |
| 3.6 <i>Model Development</i> .....           | 54 |
| 3.6.1 EEGNet .....                           | 55 |
| 3.6.2 EEGNet-TCNet.....                      | 55 |
| 3.6.3 EEGNet-ECA-TCNet.....                  | 56 |
| 3.6.4 Parameter.....                         | 57 |
| 3.7 <i>Training &amp; Optimization</i> ..... | 57 |
| 3.7.1 <i>Optimizer</i> .....                 | 57 |
| 3.7.2 <i>Loss Function</i> .....             | 58 |
| 3.7.3 <i>Callbacks</i> .....                 | 58 |
| 3.7.4 <i>Hyperparameter Tuning</i> .....     | 58 |
| 3.7.5 <i>Regularization</i> .....            | 59 |
| 3.8 <i>Evaluasi dan Analisis</i> .....       | 59 |
| 3.8.1 <i>Metrik Performa</i> .....           | 59 |
| 3.8.2 <i>Studi Ablasi</i> .....              | 60 |
| 3.8.3 <i>Analisis Deployment</i> .....       | 60 |
| 3.8.4 <i>Pengujian Statistik</i> .....       | 60 |
| 3.8.5 <i>Visualisasi</i> .....               | 61 |
| DAFTAR PUSTAKA .....                         | 62 |

## DAFTAR GAMBAR

|                                                                            |    |
|----------------------------------------------------------------------------|----|
| Gambar 2.1 Peta Referensi.....                                             | 23 |
| Gambar 2.3 Muse S Gen 2 (muse, n.d.).....                                  | 27 |
| Gambar 2.4 Arsitektur EEGNet (Rakhmatulin et al., 2024) .....              | 35 |
| Gambar 2.5 Arsitektur TCNet (Ingolfsson et al, 2020).....                  | 37 |
| Gambar 2.6 Module Efficient Channel Attention (ECA) (Wu et al., 2025)..... | 39 |
| Gambar 3.1 Kerangka Penelitian .....                                       | 45 |
| Gambar 3.2 Dataset Mentah.....                                             | 48 |

## **DAFTAR TABEL**

|                                 |    |
|---------------------------------|----|
| Tabel II.1 Studi Literatur..... | 16 |
|---------------------------------|----|



# BAB I

## PENDAHULUAN

### 1.1 Latar Belakang

*Brain-Computer Interface* (BCI) merupakan teknologi inovatif yang memungkinkan komunikasi langsung antara aktivitas otak manusia dengan perangkat eksternal tanpa melalui jalur saraf perifer atau otot (Al-Saegh et al., 2021). Teknologi BCI memiliki potensi aplikasi yang sangat luas, mulai dari rehabilitasi pasien stroke hingga meningkatkan kualitas hidup pasien dengan gangguan neurologis seperti *Parkinson* dan cedera tulang belakang (H. Zhang et al., 2024).

Salah satu paradigma BCI yang paling banyak diteliti adalah *Motor Imagery* (MI), yaitu proses membayangkan pergerakan anggota tubuh tertentu tanpa melakukan gerakan fisik secara nyata (Al-Saegh et al., 2021). Sinyal *Electroencephalogram* (EEG) yang direkam selama proses *Motor Imagery* mengandung pola aktivitas otak spesifik yang dapat diklasifikasikan untuk mengidentifikasi gerakan yang dibayangkan. Namun, pengolahan sinyal EEG dalam skenario *Motor Imagery* menghadapi tantangan yang kompleks. Sinyal MI-EEG memiliki rasio sinyal terhadap derau (*Signal-to-noise ratio*) yang sangat rendah, bersifat *non-stationer*, dan rentan terhadap sumber interferensi (Al-Saegh et al., 2021; Gu et al., 2025). Karakteristik ini memerlukan pendekatan komputasi yang canggih untuk mengenali pola-pola yang terbentuk selama proses pembayangan.

Dalam upaya mengatasi kompleksitas sinyal MI-EEG, berbagai arsitektur *deep learning* telah dikembangkan dan diuji oleh peneliti. Pada tahun 2024, penelitian yang dilakukan oleh (Agastya et al., 2024), dengan judul "Implementasi *Deep Learning* untuk klasifikasi *Motor Imagery* pada sinyal EEG", yang membandingkan empat arsitektur *deep learning* populer, diantaranya EEGNet, EEGConformer, EEGInception, dan EEGITNet. Ditemukan bahwa EEGConformer mencapai akurasi rata-rata tertinggi sebesar 72,41% dengan kinerja stabil, diikuti oleh EEGNet dengan akurasi 71,88%. Meskipun demikian, akurasi tersebut masih jauh dibawah metode *state-of-the-art* (SOTA) seperti FBCSP-CNN yang mencapai 89,3%, rendahnya

akurasi model *standalone* seperti EEGNet disebabkan oleh keterbatasan *receptive field* dari arsitektur konvolusi murni dalam memodelkan dependensi temporal jangka panjang yang merupakan ciri khas pola osilatori *motor imagery*. Hal ini mengindikasikan bahwa masih terdapat kesenjangan signifikan antara performa model-model yang ada dengan target akurasi yang ideal untuk aplikasi BCI praktis, yang umumnya memerlukan akurasi diatas 80% untuk memastikan reliabilitas dan keamanan sistem (Altaheri et al., 2025).

Penelitian terkini menunjukkan bahwa pendekatan *hybrid* yang menggabungkan arsitektur memberikan hasil lebih dari 80%. Penelitian mengusulkan model CNN-*Transformer* yang mencapai akurasi 83,91% (Ma et al., 2022). Studi lainnya memperkenalkan model *hybrid* baru bernama CLTNet, yang mengintegrasikan CNN, LSTM, dan *Transformer* mencatatkan akurasi 83,02% pada klasifikasi 4-kelas dan 87,11% pada klasifikasi 2-kelas (Gu et al., 2025). Demikian pula, CTNet mencapai akurasi 82,52% untuk 4-kelas dan 88,49% untuk 2-kelas (Zhao et al., 2024). Lebih lanjut, TCFormer yang mengintegrasikan Multi-Kernel CNN, *Transformer encoder* dengan *Grouped Query Attention*, dan *Temporal Convolutional Network* mencapai akurasi 84,79% pada klasifikasi 4-kelas dan 87,71% pada klasifikasi 2-kelas (Altaheri et al., 2025). Pola konsisten ini menunjukkan bahwa integrasi arsitektur meningkatkan akurasi klasifikasi hingga 10-15% dibandingkan model *standalone*, dengan berbagai model *hybrid* mencapai rentang akurasi 80-88% pada dataset standar BCI IV.

Selain permasalahan akurasi, kompleksitas model juga menjadi pertimbangan penting dalam pengembangan sistem BCI. Model-model *hybrid* yang kompleks seperti MSCFormer memiliki 145.900 parameter (Zhao et al., 2025), sementara model lain seperti CLTNet dan CTNet memiliki paling besar 80.000 parameter (Gu et al., 2025; Zhao et al., 2024). Kompleksitas yang tinggi ini tidak hanya meningkatkan beban komputasi dan waktu pelatihan, tetapi juga membatasi penerapan model pada perangkat dengan sumber daya terbatas seperti perangkat BCI portabel atau sistem *embedded* untuk aplikasi *real-time* (Altaheri et al., 2025).

Di sisi lain, adopsi perangkat EEG *consumer-grade* seperti Muse *headband*, Emotiv EPOC, atau NeuroSky yang memiliki jumlah *channel* terbatas (4-14 *channels*)

menawarkan solusi yang lebih *accessible* dan *portable* untuk aplikasi BCI praktis (Garcia-Moreno et al., 2020; Lee et al., 2024). Perangkat *consumer-grade* ini menghadapi tantangan tersendiri, termasuk keterbatasan informasi spasial, kualitas sinyal yang lebih rendah dengan *Signal-to-Noise Ratio* yang lebih buruk, dan kebutuhan akan model yang *robust* dengan data yang *sparse* (Garcia-Moreno et al., 2020; Lee et al., 2024). Penelitian sebelumnya melaporkan bahwa akurasi klasifikasi *motor imagery* pada perangkat *consumer-grade* berkisar antara 60-75% untuk konfigurasi *default* (Garcia-Moreno et al., 2020; Lee et al., 2024), meskipun studi terbaru menunjukkan bahwa dengan optimasi model yang tepat, akurasi hingga 95-98% dapat dicapai pada konfigurasi 4-*channel* dengan protokol *within-subject* dan *hyperparameter optimization* (Altaheri et al., 2025).

Penelitian terkini memperkenalkan EEG-TCNet yang mengintegrasikan EEGNet dan TCN secara serial, mencapai akurasi 77.35% pada BCI IV-2a dengan hanya ~37.000 parameter dan berhasil di-*deploy* pada ARM Cortex-M4F mikrokontroler dengan *inference time* 101ms dan konsumsi energi 4.28mJ per *trial* (Ingolfsson et al., 2020). Penelitian lainnya mengembangkan ATCNet yang menambahkan *multi-head self-attention* antara EEGNet dan TCN, meningkatkan akurasi hingga 85.38% namun dengan kompleksitas ~113.000 parameter (Altaheri et al., 2025). Penelitian terbaru pada CIACNet membuktikan bahwa penambahan *attention mechanism* sebelum TCN menghasilkan kontribusi signifikan terhadap performa model (Liao et al., 2025). Meskipun kombinasi EEGNet-TCN telah terbukti efektif dengan akurasi 77.35% dan kompleksitas yang ringan (~37.000 parameter), akurasi ini masih di bawah target BCI praktis (>80%). Kesenjangan kinerja ini mengindikasikan bahwa model tersebut kurang memiliki kemampuan adaptif untuk memprioritaskan *channel* atau fitur yang paling informatif, sebuah kelemahan yang krusial terutama pada perangkat *consumer-grade* dengan kualitas sinyal yang lebih rendah dan 4 *channel* terbatas, penggunaan *complex attention mechanism* seperti *multi-head self-attention* membatasi *feasibility deployment* pada perangkat IoT dengan sumber terbatas (Altaheri et al., 2025).

Untuk mengatasi keterbatasan *complex attention mechanisms* dalam konteks *IoT deployment*, mekanisme yang menjanjikan adalah *Efficient Channel Attention* (ECA),

sebagai versi simpel dari *Squeeze-and-Excitation* (SE) (Q. Wang et al., 2020). Dalam konteks BCI-MI, penelitian mengintegrasikan modul ECA ke dalam arsitektur AMEEGNet yang berbasis *multi-scale* EEGNet, dan berhasil meningkatkan akurasi *baseline* EEGNet dari 77.12% menjadi 81.17% pada dataset BCI *Competition* IV-2a dengan peningkatan lebih signifikan pada subjek dengan *noise* level tinggi (hingga +6.32%) (Wu et al., 2025). Studi ablasi menunjukkan bahwa ECA memberikan kontribusi *accuracy improvement* sebesar 0.77-3.72% dengan *computational overhead* minimal ( $\sim 0.05$  GFLOPs), membuktikan efektivitas ECA dalam *adaptive feature weighting* untuk sinyal EEG yang memiliki SNR rendah (Wu et al., 2025). Penelitian lain pada CIACNet menggunakan *improved Convolutional Block Attention Module* (CBAM) yang menggabungkan *channel* dan *spatial attention*, mencapai akurasi 85.15% pada BCI IV-2a, namun dengan *parameter count* yang lebih tinggi ( $\sim 5.000$ -10.000 parameter untuk attention module) dibandingkan ECA ( $\sim 500$  parameter). Perbandingan ini mengindikasikan bahwa ECA menawarkan *trade-off* optimal antara *parameter efficiency* dan *performance improvement* untuk aplikasi *lightweight* BCI, terutama pada perangkat dengan *channel* terbatas dimana *spatial attention* kurang relevan (Liao et al., 2025; Wu et al., 2025).

Berdasarkan analisis terhadap 12 penelitian terkini dalam klasifikasi *motor imagery* EEG menggunakan *deep learning*, teridentifikasi beberapa *research gap* utama. Pertama, meskipun kombinasi EEGNet-TCN telah terbukti efektif (Altaheri et al., 2025; Ingolfsson et al., 2020), mayoritas penelitian menggunakan dataset *research-grade* dengan 22-64 *channels*, sementara penelitian yang berfokus pada *consumer-grade* dengan *channel* terbatas masih sangat terbatas (Garcia-Moreno et al., 2020; Lee et al., 2024). Kedua, penelitian yang ada menggunakan *complex attention mechanism* seperti *multi-head self-attention*, sementara *lightweight attention* seperti *Efficient Channel Attention* (ECA) belum dieksplorasi dalam konteks EEGNet-TCN. Ketiga, hanya EEG-TCNet yang melakukan *comprehensive embedded deployment evaluation*, sementara penelitian lain tidak menyediakan analisis tersebut.

Untuk menjawab kesenjangan tersebut, penelitian ini mengusulkan pengembangan model *hybrid* EEGNet-TCN dengan *Efficient Channel Attention* (ECA) untuk

klasifikasi *motor imagery* pada perangkat *consumer-grade* berdasarkan *electroencephalogram* (EEG). Model yang diusulkan mengadopsi arsitektur serial *hierarchical*, di mana EEGNet berfungsi sebagai *feature extractor* lokal yang *compact* dan efisien untuk mengekstrak fitur *spatio-temporal* dari sinyal EEG 4-channel, kemudian dilanjutkan dengan modul *Efficient Channel Attention* (ECA) untuk *adaptive channel weighting* yang *lightweight*, dan diikuti oleh *Temporal Convolutional Network* (TCN) dengan 2 *residual blocks* yang menangkap dependensi temporal jangka panjang melalui *dilated causal convolutions*. Arsitektur ini dirancang untuk mencapai target kompleksitas model dengan akurasi tinggi dan *feasible* untuk *deployment* pada perangkat *Internet of Things* (IoT) dengan menggunakan perangkat *consumer-grade 4-channels*.

## 1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, rumusan masalah yang bisa diuraikan dalam penelitian diantaranya:

1. Bagaimana performa model dengan arsitektur *hybrid* yang mengintegrasikan arsitektur EEGNet, modul *Efficient Channel Attention* (ECA), dan arsitektur TCNet.
2. Bagaimana kontribusi dari modul *Efficient Channel Attention* (ECA) terhadap peningkatan akurasi klasifikasi *motor imagery* pada arsitektur *hybrid* EEGNet-TCNet.
3. Bagaimana efisiensi model yang diusulkan ditinjau dari kompleksitas parameter dan *computational overhead*.

## 1.3 Ruang Lingkup

Pada penelitian yang dilakukan terdapat beberapa batasan masalah yang di uraikan sebagai berikut:

1. Penelitian ini terbatas pada klasifikasi *binary motor imagery* (MI) menggunakan sinyal EEG.

2. Pengambilan data dilakukan secara mandiri (Data Primer) menggunakan perangkat EEG *consumer-grade* Muse S Gen 2 dengan konfigurasi 4 kanal (TP9, AF7, AF8, TP10) dan laju sampling 256 Hz.
3. Partisipan penelitian terdiri dari 16 subjek sehat dewasa (usia > 17 tahun) dengan protokol pengambilan data *cue-based* yang terkontrol.
4. Sistem yang dikembangkan berfokus pada pemrosesan *offline*, di mana model dilatih dan dievaluasi menggunakan data yang telah direkam sebelumnya, tidak mencakup pengendalian perangkat eksternal secara *real-time*.
5. Evaluasi performa model menggunakan skema *Within-Subject Classification* dengan validasi silang (*K-Fold Cross-Validation*), dan tidak mencakup evaluasi *Cross-Subject* (antar-subjek).
6. Fokus perbaikan model adalah pada aspek akurasi klasifikasi dan efisiensi parameter (*lightweight*) dibandingkan dengan model *baseline* (EEGNet standar), tanpa membahas aspek keamanan siber atau enkripsi data EEG.

#### **1.4 Tujuan Penelitian**

Penelitian ini bertujuan untuk mengembangkan arsitektur *hybrid* EEGNet-TCN dengan integrasi modul *Efficient Channel Attention* (ECA) untuk meningkatkan akurasi klasifikasi *binary motor imagery* pada perangkat *consumer-grade* EEG (4 *channels*) menggunakan data primer. Penelitian akan mengevaluasi performa model yang diusulkan dibandingkan dengan baseline EEGNet dan model *hybrid existing*, menganalisis kontribusi setiap komponen arsitektur (EEGNet, ECA, dan TCN) melalui studi ablasi, serta mengevaluasi efisiensi model ditinjau dari kompleksitas parameter dan *computational overhead*.

#### **1.5 Sistematika Penulisan**

Sistematika penulisan yang digunakan untuk memberikan gambaran isi dari laporan ini dijelaskan sebagai berikut:

### **BAB I PENDAHULUAN**

Bab ini menjelaskan tentang latar belakang, rumusan masalah, ruang lingkup, tujuan penelitian serta sistematika penulisan.

## **BAB II TINJAUAN PUSTAKA**

Bab ini menjelaskan tentang kajian literatur dari penelitian sebelumnya untuk mendukung teori yang digunakan dalam penelitian.

## **BAB III METODOLOGI**

Bab ini menjelaskan tentang metode yang digunakan di dalam penelitian beserta penerapannya.

## BAB II

### TINJAUAN PUSTAKA

Pada tinjauan pustaka, menampilkan beberapa studi literatur atau referensi untuk membantu dalam pelaksanaan penelitian ini.

Tabel II.1 Studi Literatur

| No | Judul                                                                      | Author                                                    | Tahun | Hasil Penelitian                                                                                                                                                                                                                                                                                                                                                      |
|----|----------------------------------------------------------------------------|-----------------------------------------------------------|-------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 1  | Implementasi Deep Learning untuk Klasifikasi Motor Imagery pada Sinyal EEG | I Made Artha Agastya, Robert Marco, Nila Feby Puspitasari | 2024  | Penelitian ini membandingkan kinerja empat arsitektur deep learning untuk klasifikasi motor imagery EEG, yaitu EEGNet, EEGConformer, EEGInception, dan EEGITNet. Hasil pengujian menunjukkan bahwa EEGConformer dan EEGNet adalah model yang paling efektif dan stabil. EEGConformer dengan 72,41%, diikuti oleh EEGNet dengan 71,88% akurasi.                        |
| 2  | Deep learning for motor imagery EEG-based classification: A review         | Ali Al-Saegh, Shefa A. Dawwd, Jassim M. Abdul-Jabbar      | 2021  | Tinjauan sistematis terhadap 40 makalah menemukan bahwa CNN dan arsitektur hibrida yang melibatkan CNN adalah arsitektur DNN yang paling dominan digunakan (sekitar 73% dan 13%, berturut-turut) dan memberikan kinerja tinggi untuk klasifikasi MI EEG. Ditemukan bahwa rentang frekuensi yang paling sering dianalisis untuk MI berada diantara 6-8 Hz hingga 38-40 |



|   |                                                                        |                                                                      |      |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |
|---|------------------------------------------------------------------------|----------------------------------------------------------------------|------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|   |                                                                        |                                                                      |      | Hz. Model juga menemukan bahwa klasifikasi tugas MI yang berhubungan dengan satu anggota tubuh, seperti jari yang berbeda, lebih menantang daripada tugas yang berhubungan dengan anggota tubuh yang berbeda.                                                                                                                                                                                                                                                                                                                                                                                                                               |
| 3 | CLTNet: A Hybrid Deep Learning Model for Motor Imagery Classification. | He Gu, Tingwei Chen, Xiao Ma, Mengyuan Zhang, Yan Sun, dan Jian Zhao | 2025 | Penelitian ini memperkenalkan CLTNet (penggabungan antara CNN, LSTM, dan Transformer) untuk meningkatkan klasifikasi sinyal MI EEG. Model ini terbukti unggul dibandingkan metode deep learning lainnya. CLTNet mencapai akurasi rata-rata 83,02% pada dataset BCI IV 2a dan 87,11% pada dataset BCI IV 2b. Keunggulan ini sebagian besar disebabkan oleh kemampuan model untuk mengekstrak fitur multidimensi, meliputi fitur lokal, dependensi temporal, dan dependensi global secara bersamaan. Analisis juga menunjukkan bahwa model ini memiliki kemampuan generalisasi yang kuat saat diuji pada subjek baru (Leave-One-Subject-Out). |
| 4 | Exploring Convolutional Neural                                         | Ildar Rakhmatulin,                                                   | 2024 | Makalah ini mengkategorikan arsitektur CNN untuk EEG ke                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                     |

|   |                                                                                                           |                                                                                                       |      |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          |
|---|-----------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------|------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|   | Network Architectures for EEG Feature Extraction.                                                         | Minh-Son Dao, Amir Nassibi, dan Danilo Mandic                                                         |      | dalam empat kelompok (implementasi standar, recurrent convolutional, arsitektur decoder, dan cascaded architecture) dan menyimpulkan bahwa CNN sangat cocok untuk ekstraksi fitur otomatis karena kemampuannya menangani ketergantungan non-linear dan beradaptasi pada berbagai aplikasi EEG.                                                                                                                                                                                                                                                                           |
| 5 | EEG-TCNet: An Accurate Temporal Convolutional Network for Embedded Motor-Imagery Brain-Machine Interfaces | Thorir Mar Ingolfsson, Michael Hersche, Xiaying Wang, Nobuaki Kobayashi, Lukas Cavigelli, Luca Benini | 2020 | Hasil utama penelitian ini adalah proposal EEG-TCNET, sebuah jaringan saraf konvolusional temporal (TCN) baru untuk klasifikasi EEG motor-imagery (MI). Dirancang untuk perangkat tersemat berdaya rendah, EEG-TCNET menggabungkan akurasi tinggi dengan efisiensi sumber daya ekstrem. Pada BCI Competition IV-2a, model ini mencapai akurasi 77.35% (tetap) dan 83.84% (variabel). Model ini hanya memerlukan 4272 parameter dan 6.8 MMACs per inferensi, menjadikannya model yang sangat ringkas dan akurat (Pareto optimal). EEG-TCNET juga menunjukkan generalisasi |


|   |                                                                                       |                                                                  |      |                                                                                                                                                                                                                                                                                                                                                                                                                      |
|---|---------------------------------------------------------------------------------------|------------------------------------------------------------------|------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|   |                                                                                       |                                                                  |      | yang baik pada Mother of All BCI Benchmarks (MOABB), menjadi SOA baru dengan mengungguli pendahulunya dengan meta-effect 0.25.                                                                                                                                                                                                                                                                                       |
| 6 | CTNet: a convolutional transformer network for EEG-based motor imagery classification | Wei Zhao, Xiaolu Jiang, Baocan Zhang, Shixiao Xiao, & Sujun Weng | 2024 | Model CTNet menunjukkan kinerja yang kuat dan konsisten dalam evaluasi pada dataset BCI IV-2a dan BCI IV-2b. Dalam evaluasi subject-specific, CTNet mencapai akurasi rata-rata 82,52% (BCI IV-2a) dan 88,49% (BCI IV-2b). Studi ablasi menegaskan peran penting modul Transformer dalam menangkap representasi global dan pentingnya data augmentation untuk menghindari overfitting pada dataset EEG yang terbatas. |
| 7 | A novel hybrid CNN-Transformer model for EEG Motor Imagery classification             | Yaxin Ma, Yonghao Song, dan Fei Gao                              | 2022 | Model hibrida CNN-Transformer yang diusulkan, yang dirancang dalam framework end-to-end untuk mengekstrak fitur spasial, spektral, dan temporal, menunjukkan kinerja yang luar biasa dalam klasifikasi MI EEG empat kelas pada dataset BCI Competition IV 2a. Hasilnya menunjukkan akurasi klasifikasi rata-rata 83,91% dan                                                                                          |

|   |                                                                                    |                                                                                                                                                |      |                                                                                                                                                                                                                                                                                                                                                                                                                                                 |
|---|------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------|------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|   |                                                                                    |                                                                                                                                                |      | <p>nilai Kappa 0,782, yang mengungguli metode state-of-the-art (SOTA) lainnya, termasuk metode tradisional FBCSP dan model deep learning berbasis CNN murni (seperti ConvNet, C2CM, dan MCNN). Studi ablas lebih lanjut menguatkan bahwa kinerja model hibrida ini secara signifikan lebih tinggi (peningkatan 37,23% dan 25,81% secara rata-rata) dibandingkan dengan penggunaan Transformer atau CNN secara terpisah.</p>                     |
| 8 | Brain-computer interfaces: the innovative key to unlocking neurological conditions | Hongyu Zhang, Le Jiao, Songxiang Yang, Haopeng Li, Xinzhan Jiang, Jing Feng, Shuhuai Zou, Qiang Xu, Jianheng Gu, Xuefeng Wang, dan Baojian Wei | 2024 | <p>Makalah tinjauan ini menggarisbawahi bahwa teknologi BCI adalah alat transformatif yang muncul untuk diagnosis, terapi, dan rehabilitasi gangguan neurologis. Poin-poin aplikasi utama yang ditekankan adalah BCI dapat meningkatkan efikasi pelatihan Motor Imagery (MI), mempercepat pemulihan fungsional, dan membantu pemulihan kognitif, sering kali menggunakan EEG. BCI dan Deep Brain Stimulation (DBS) yang canggih menunjukkan</p> |

|    |                                                                                            |                                                                                              |      |                                                                                                                                                                                                                                                                                                                                                                                                                                                    |
|----|--------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------|------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|    |                                                                                            |                                                                                              |      | konvergensi dalam memantau dan memodulasi aktivitas otak secara real-time untuk mengelola gejala motorik.                                                                                                                                                                                                                                                                                                                                          |
| 9  | Subject-independent EEG classification based on a hybrid neural network.                   | Hao Zhang, Hongfei Ji, Jian Yu, Jie Li, Lingjing Jin, Lingyu Liu, Zhongfei Bai, dan Chen Ye. | 2023 | Penelitian ini mengusulkan framework hibrida untuk klasifikasi Motor Imagery (MI) berbasis EEG yang subjek-independen, menggabungkan FBGAN untuk augmentasi data dan CRNN-DF untuk klasifikasi dengan fitur diskriminatif. Pada dataset BCI Competition IV-2a, metode ini mencapai akurasi rata-rata $72.74 \pm 10.44\%$ , meningkat 4.77% dibandingkan metode state-of-the-art, menunjukkan efektivitasnya dalam meningkatkan kinerja sistem BCI. |
| 10 | A composite improved attention convolutional network for motor imagery EEG classification. | Wenzhe Liao, Zipeng Miao, Shuaibo Liang, Linyan Zhang, dan Chen Li.                          | 2025 | Penelitian ini mengusulkan CIACNet, model ringan untuk klasifikasi MI-EEG yang menggabungkan CNN dual-branch, Improved CBAM dengan stochastic pooling, dan TCN. Model ini mencapai akurasi 85.15% (BCI IV-2a) dan 90.05% (BCI IV-2b) dengan kappa 0.80, serta unggul dalam efisiensi pelatihan dan ketahanan                                                                                                                                       |

|    |                                                                                       |                                                                        |      |                                                                                                                                                                                                                                                                                                                                                                                                                                      |
|----|---------------------------------------------------------------------------------------|------------------------------------------------------------------------|------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|    |                                                                                       |                                                                        |      | terhadap noise dibandingkan model state-of-the-art.                                                                                                                                                                                                                                                                                                                                                                                  |
| 11 | Temporal convolutional transformer for EEG based motor imagery decoding.              | Hamdi Altaheri, Fakhri Karray, & Amir-Hossein Karimi.                  | 2025 | Penelitian ini memperkenalkan TCFormer, model Temporal Convolutional Transformer yang ringkas dan efisien untuk decoding MI-EEG. Dengan menggabungkan Multi-Kernel CNN, Transformer dengan Grouped-Query Attention, dan TCN Head, TCFormer mencapai akurasi tinggi 84.79% (BCIC IV-2a), 87.71% (BCIC IV-2b), dan 96.27% (HGD) hanya dengan 77.8k parameter, menunjukkan efisiensi dan performa unggul dibandingkan model sebelumnya. |
| 12 | AMEEGNet: attention-based multiscale EEGNet for effective motor imagery EEG decoding. | Xuejian Wu, Yaqi Chu, Qing Li, Yang Luo, Yiwen Zhao, dan Xingang Zhao. | 2025 | Penelitian ini mengusulkan AMEEGNet, model lightweight deep learning berbasis Attention-based Multiscale EEGNet yang menggabungkan EEGNet paralel dengan fusion transmission dan Efficient Channel Attention (ECA) untuk meningkatkan ekstraksi fitur temporal-spatial dan ketajaman spasial. Model ini mencapai akurasi tertinggi 81.17% (BCI IV 2a), 89.83% (BCI IV 2b),                                                           |

|  |  |  |  |                                                                                                                                 |
|--|--|--|--|---------------------------------------------------------------------------------------------------------------------------------|
|  |  |  |  | dan 95.49% (HGD), serta menunjukkan robustness tinggi pada skenario cross-subject, melampaui model state-of-the-art sebelumnya. |
|--|--|--|--|---------------------------------------------------------------------------------------------------------------------------------|



Gambar II.1 Peta Referensi

2.1 Brain-Computer Interface (BCI)

*Brain-Computer Interface* (BCI) merupakan sistem yang mengukur aktivitas otak dan mengonversinya secara *real-time* menjadi output yang berguna secara fungsional untuk menggantikan, memulihkan, meningkatkan, melengkapi, atau memperbaiki output alami dari otak, sehingga mengubah interaksi berkelanjutan antara otak dan lingkungan eksternal atau internalnya (Chen et al., 2024). Teknologi BCI memfasilitasi komunikasi langsung antara aktivitas otak manusia dengan perangkat eksternal tanpa melalui jalur saraf perifer atau otot, menawarkan pendekatan transformatif dalam diagnosis, terapi, dan rehabilitasi berbagai kondisi neurologis (H. Zhang et al., 2024). Dalam konteks yang lebih teknis, BCI dapat didefinisikan sebagai sistem yang terdiri

dari dua bagian kunci esensial: sistem saraf pusat yang menghasilkan sinyal otak dan komputer yang menganalisis sinyal otak yang kompleks tersebut (Chen et al., 2024).

Sistem BCI terdiri dari empat komponen utama yang saling terintegrasi untuk mengubah aktivitas otak menjadi perintah yang dapat dijalankan. Komponen pertama adalah akuisisi sinyal, yaitu proses merekam aktivitas otak menggunakan berbagai modalitas seperti *Electroencephalography* (EEG), *functional Magnetic Resonance Imaging* (fMRI), *functional Near-Infrared Spectroscopy* (fNIRS), *Magnetoencephalography* (MEG), *Electrocorticography* (EcoG), atau *Stereoencephalography* (SEEG) (H. Zhang et al., 2024). Di antara semuanya, EEG paling populer karena bersifat non-invasif, portabel, murah, dan memiliki resolusi temporal tinggi, meskipun kurang akurat secara spasial dan sensitif terhadap noise (Sun et al., 2025).

Berdasarkan paradigma yang digunakan, BCI terbagi menjadi beberapa jenis utama. *Motor Imagery-based BCI* (MI-BCI) mendeteksi sinyal EEG saat pengguna membayangkan gerakan di area korteks motor untuk mengontrol perangkat seperti kursi roda, sistem rehabilitasi berbasis VR, atau alat komunikasi berbasis teks dengan memanfaatkan perubahan ritme  $\mu$  (mu) dan  $\beta$  (beta) (H. Zhang et al., 2024). Pendekatan ini bermanfaat bagi pasien stroke atau cedera tulang belakang dalam pemulihan fungsi motorik. Teknologi BCI telah berkembang pesat di bidang medis dan non-medis. Dalam rehabilitasi neurologis, BCI terbukti efektif membantu pasien stroke, di mana *BCI-enhanced motor imagery training* meningkatkan pemulihan fungsi motorik melalui peningkatan aktivitas otak pada band alpha dan beta (H. Zhang et al., 2024). Pada *Parkinson's disease*, integrasi BCI dengan *closed-loop Deep Brain Stimulation* (DBS) memungkinkan penyesuaian otomatis berdasarkan sinyal otak *real-time*, sehingga meningkatkan efektivitas terapi dan mengurangi ketergantungan obat (H. Zhang et al., 2024).

## **2.2 *Electroencephalography* (EEG)**

*Electroencephalography* (EEG) adalah metode non-invasif untuk merekam aktivitas listrik otak yang dihasilkan oleh ribuan neuron, dimana fluktuasi voltase direkam dari *multiple* elektroda yang ditempatkan pada kulit kepala dengan resolusi



temporal level milidetik (Sabio et al., 2024). EEG merupakan salah satu alat *neuroscience* paling populer karena non-invasif, portabel, murah, dan mudah digunakan, menjadikannya pilihan ideal untuk brain-computer interface dan penelitian neuroscience (H. Zhang et al., 2024). Dalam konteks *motor imagery*, EEG mendeteksi sinyal saat pengguna membayangkan gerakan di motor *cortex*, khususnya melalui perubahan ritme mu dan beta, untuk mengoperasikan perangkat seperti *robotic arms* atau *communication systems*.

### 2.2.1 Prinsip Kerja dan Karakteristik

Sinyal EEG bekerja dengan merekam perbedaan voltase antara elektroda berdasarkan standar 10-20 *electrode placement system*, yang memastikan *coverage* konsisten di *scalp regions* relevan terhadap task yang sedang dilakukan (X. Wang et al., 2023). Sinyal EEG bersifat non-stasioner, artinya karakteristik statistiknya berubah seiring waktu sesuai dengan perubahan aktivitas otak (Malan & Sharma, 2022). Karakteristik fundamental sinyal EEG adalah *Event-Related Desynchronization* (ERD) dan *Event-Related Synchronization* (ERS), dimana ERD merujuk pada penurunan power spektral dalam frekuensi tertentu yang menunjukkan aktivasi motor cortex, sementara ERS merujuk pada peningkatan power setelah penghentian aktivitas mental atau motorik (Malan & Sharma, 2022; X. Wang et al., 2023).

Sinyal EEG diklasifikasikan ke dalam *frequency bands* yang mencerminkan aktivitas otak dengan fungsi fisiologis berbeda. Pita mu (8–13 Hz) dan beta (13–30 Hz) paling relevan untuk *motor imagery* karena menunjukkan ERD/ERS khas selama aktivitas motorik kontralateral (X. Wang et al., 2023). Penelitian menunjukkan bahwa optimasi *bandpass filter* antara 4–30 Hz meningkatkan akurasi klasifikasi dengan menangkap fitur diskriminatif dari *multiple frequency sub-bands* (Malan & Sharma, 2022). Oleh karena itu, dalam preprocessing EEG untuk motor imagery, bandpass filter 8–30 Hz adalah standard practice untuk meningkatkan signal-to-noise ratio sambil preserving sinyal informatif dari mu dan beta rhythms (Malan & Sharma, 2022).

### 2.2.2 Perangkat EEG

Perangkat EEG umumnya dibagi menjadi *research-grade* dan *consumer-grade* dengan *trade-off* antara kualitas sinyal dan aksesibilitas, di mana *research-grade* menyediakan 22–64 elektroda dengan gel konduktif, *signal-to-noise ratio* tinggi, dan kalibrasi presisi untuk akuisisi data elektrofisiologi yang akurat, sedangkan *consumer-grade* biasanya menawarkan 4–14 elektroda kering atau semi-kering yang lebih portabel namun dengan *signal-to-noise* dan sampling rate lebih rendah sehingga menuntut *preprocessing* lebih agresif untuk kontrol *noise* (Al-Saegh et al., 2021; Sabio et al., 2024; H. Zhang et al., 2024).

*Scoping review* skala besar terhadap 916 studi menunjukkan perangkat Emotiv paling banyak digunakan di ranah *consumer-grade*, diikuti oleh NeuroSky MindWave, OpenBCI, Muse, dan MyndPlay, dengan distribusi aplikasi pada sistem BCI (44,54%), *experimental research* (31,22%), *signal processing* (12,01%), *clinical applications* (6,22%), dan *validation studies* (6,18%) (Sabio et al., 2024). Walau jumlah elektroda lebih sedikit dan *noise floor* lebih tinggi, studi validasi menunjukkan *consumer-grade* seperti Emotiv dan Muse tetap mampu merekam potensi terkait kejadian (ERP) dan pola *motor imagery* secara reliabel asalkan *pipeline preprocessing* yang ketat diterapkan, termasuk penolakan trial yang lebih banyak untuk menjaga kualitas sinyal (Al-Saegh et al., 2021; Sabio et al., 2024; Wu et al., 2025). Dengan demikian, *research-grade* unggul untuk presisi data dan validasi model, sedangkan *consumer-grade* menonjol dalam biaya, portabilitas, dan kemudahan penggunaan untuk pengumpulan data di luar laboratorium dan aplikasi BCI portabel, terutama ketika dikombinasikan dengan algoritme deep learning yang robust terhadap *noise* (Al-Saegh et al., 2021; H. Zhang et al., 2024).

### 2.2.3 Muse S Gen 2 Headband



Gambar II.2 Muse S Gen 2 (muse, n.d.)

Penelitian ini menggunakan Muse S Gen 2 sebagai perangkat EEG *consumer-grade* dengan empat kanal pada TP9, AF7, AF8, dan TP10 sesuai sistem 10–20, laju sampling 256 Hz, konektivitas *Bluetooth*, dan elektroda kering untuk pemasangan cepat yang portabel dan terjangkau bagi studi BCI berbasis *motor imagery*. Spesifikasi ini sejalan dengan deskripsi perangkat Muse seri S yang dirancang untuk perekaman EEG non-invasif di rumah, serta praktik umum penggunaan kanal temporal dan frontal untuk tugas MI ketika jumlah elektroda terbatas (Sabio et al., 2024; H. Zhang et al., 2024). Kelebihan utama perangkat ini adalah biaya rendah, nirkabel, dan kemudahan penggunaan tanpa gel konduktif sehingga cocok untuk pengumpulan data di luar laboratorium dan prototipe personal BCI, sementara keterbatasannya meliputi jumlah kanal yang sedikit, *signal-to-noise ratio* lebih rendah akibat elektroda kering, dan variabilitas impedansi antarsesi yang menuntut *preprocessing* agresif dan pemodelan yang robust. Konsekuensinya, arsitektur yang efisien seperti kombinasi *feature extractor* konvolusional dengan pemodelan temporal serta mekanisme perhatian kanal diperlukan agar tetap mencapai akurasi tinggi pada data 4-kanal dengan sumber daya komputasi terbatas (Al-Saegh et al., 2021; Wu et al., 2025).

### 2.3 Motor Imagery (MI)

*Motor imagery* (MI) adalah proses mental di mana seseorang membayangkan melakukan gerakan tanpa benar-benar melakukannya, seperti menggerakkan tangan atau kaki (Agastya et al., 2024). Proses ini melibatkan latihan kognitif gerakan motorik, mengaktifkan area otak terkait tanpa membutuhkan stimulus eksternal (Mustile et al., 2024). Dalam *brain-computer interface* (BCI), MI menjadi paradigma penting karena dapat diaktivasi secara mandiri dan tidak terganggu faktor lingkungan, sehingga memungkinkan kontrol langsung melalui aktivitas otak (Wu et al., 2025). Aplikasi MI-BCI meliputi rehabilitasi stroke, kontrol prostesis, navigasi kursi roda, terapi psikologis, pelatihan kognitif, serta penggunaan non-medis seperti kontrol kendaraan, gaming, pelatihan keterampilan, dan virtual reality (Liao et al., 2025).

Dasar neurofisiologis *motor imagery* (MI) didasarkan pada *functional equivalence hypothesis*, yang menyatakan bahwa MI dan eksekusi motorik nyata melibatkan area otak yang sama meskipun tanpa gerakan fisik (Mustile et al., 2024). Saat seseorang membayangkan gerakan, korteks motorik menghasilkan respons neuron serupa yang membantu pemulihan fungsi motorik dengan menghubungkan kembali intensi dan umpan balik sensorik (J. Zhang et al., 2023). Studi menggunakan mobile EEG menunjukkan bahwa MI dan eksekusi gerakan nyata memiliki pola aktivitas otak yang mirip, terutama pada tahap awal perencanaan aksi (Mustile et al., 2024). Namun, MI menimbulkan aktivasi otak yang lebih luas dan menuntut proses kognitif lebih besar karena memerlukan simulasi mental yang disengaja. Selama tugas MI, sinyal EEG memperlihatkan perubahan daya pada pita mu (8–13 Hz) dan beta (13–30 Hz), yang menunjukkan pola *event-related desynchronization* (ERD) dan *event-related synchronization* (ERS) khas aktivitas motor imagery (X. Wang et al., 2023).

### 2.4 Preprocessing Sinyal Electroencephalogram (EEG)

*Preprocessing* sinyal *Electroencephalogram* (EEG) merupakan tahap penting untuk membersihkan data mentah dari noise dan artefak agar siap dianalisis (Altaheri et al., 2025; J. Zhang et al., 2023). Sinyal EEG sangat rentan terhadap gangguan seperti noise elektromagnetik, gerakan mata, kepala, atau otot, serta gangguan dari kabel dan elektroda (Rakhmatulin et al., 2024). Karena sinyal EEG bersifat lemah, non-

stationary, dan memiliki signal-to-noise ratio rendah, tahap ini krusial untuk mengekstraksi informasi yang berguna (Al-Saegh et al., 2021). Tanpa preprocessing yang baik, kualitas sinyal akan menurun dan berdampak negatif pada performa sistem MI-BCI (Altaheri et al., 2025).

#### **2.4.1 Filtering**

*Filtering* merupakan salah satu teknik preprocessing paling mendasar yang digunakan untuk menghilangkan komponen frekuensi yang tidak diinginkan dari sinyal EEG mentah (Rakhmatulin et al., 2024; H. Zhang et al., 2023). *Bandpass filtering* diterapkan untuk mempertahankan komponen frekuensi yang relevan dengan tugas *motor imagery*, dimana pita frekuensi yang paling umum digunakan dalam penelitian MI-EEG adalah ritme mu pada rentang 8-12 Hz dan ritme beta pada rentang 13-30 Hz (Altaheri et al., 2025; Wu et al., 2025). Beberapa penelitian menggunakan *bandpass filter* dengan rentang yang lebih luas, seperti 4-40 Hz untuk mempertahankan aktivitas delta, theta, alpha, dan beta (Ma et al., 2022; H. Zhang et al., 2023), atau menggunakan *filter* yang lebih spesifik seperti 0.5-100 Hz dengan *notch filter* pada 50 Hz untuk menghilangkan *line noise* (Zhao et al., 2024). Studi terbaru menunjukkan bahwa pemilihan rentang frekuensi *bandpass filter* yang tepat dapat secara signifikan mempengaruhi akurasi model, dimana beberapa arsitektur dapat mencapai akurasi tinggi bahkan tanpa penerapan *bandpass filtering* jika arsitektur tersebut mampu mempelajari pola frekuensi secara otomatis (Altaheri et al., 2025). *Notch filter* secara khusus digunakan untuk menghilangkan *power line noise* pada frekuensi 50 Hz atau 60 Hz tergantung pada standar listrik regional, yang merupakan sumber interferensi elektromagnetik yang sangat umum dalam perekaman EEG (H. Zhang et al., 2023). Penelitian menunjukkan bahwa kombinasi bandpass filter dan notch filter yang tepat dapat meningkatkan signal-to-noise ratio secara signifikan, sehingga memfasilitasi ekstraksi fitur yang lebih akurat untuk klasifikasi MI-EEG (Rakhmatulin et al., 2024).

#### **2.4.2 Artifact Removal**

*Artifact removal* merupakan tahapan preprocessing yang sangat penting untuk menghilangkan kontaminasi dari sinyal EEG yang disebabkan oleh aktivitas fisiologis

non-neural dan gangguan eksternal. *Independent Component Analysis* (ICA) adalah teknik yang paling banyak digunakan untuk pemisahan artefak dari sinyal EEG multi-channel, dimana metode ini memisahkan sinyal EEG multi-komponen menjadi bagian-bagian independen, sehingga dapat menghilangkan *noise* dan interferensi yang disebabkan oleh kedipan mata, gerakan mata, kontraksi jantung, dan aktivitas otot. ICA terbukti menjadi alat yang berguna untuk membersihkan artefak dalam sampel EEG pendek tanpa memiliki kerugian yang terkait dengan *filter* digital, dimana distorsi pada aktivitas *interictal* yang diukur dengan analisis korelasi adalah minimal. Dalam konteks *deep learning* untuk MI-EEG, beberapa penelitian menunjukkan bahwa model *neural network* dapat dilatih untuk secara otomatis menghilangkan artefak tanpa *preprocessing* ICA eksplisit, namun pendekatan ICA tetap menjadi standar emas dalam banyak aplikasi karena dapat memisahkan komponen independen dengan tingkat akurasi yang tinggi. Studi terbaru menunjukkan bahwa pemilihan metode artifact removal yang tepat sangat bergantung pada karakteristik dataset dan tugas spesifik, dimana dalam beberapa kasus, artefak EEG bahkan dapat berkontribusi pada performa deep neural networks, menunjukkan bahwa penghapusan artefak yang terlalu agresif dapat menghilangkan informasi yang bermanfaat. (Rakhmatulin et al., 2024)

#### **2.4.3 Epoching dan Windowing**

*Epoching* dan *windowing* adalah proses segmentasi sinyal EEG kontinu menjadi potongan-potongan diskrit yang sesuai dengan event atau interval waktu tertentu untuk analisis (Altaheri et al., 2025). Dalam eksperimen motor imagery, sinyal EEG biasanya disegmentasi berdasarkan timing protokol eksperimental, dimana fase *cue* dan *motor imagery* merupakan periode kritis untuk menangkap sinyal dari otak (Wu et al., 2025; Zhao et al., 2024). *Windowing* dapat dilakukan dengan berbagai strategi, termasuk *sliding window* dengan *overlap* untuk meningkatkan jumlah *training samples* dan menangkap *dynamic temporal patterns*, dimana beberapa studi menggunakan *window size* 4 detik dengan *step size* 0.5 detik untuk membagi sinyal MI task menjadi *multiple time windows* (Altaheri et al., 2025). Teknik *epoching* yang tepat sangat penting untuk memastikan bahwa fitur temporal yang relevan dipertahankan, dimana pemilihan durasi *epoch* dan posisi *window* dapat secara signifikan mempengaruhi akurasi

klasifikasi MI-EEG (H. Zhang et al., 2023; J. Zhang et al., 2023). Dalam implementasi *deep learning*, *epoching* sering dikombinasikan dengan data *augmentation strategies* seperti *segmentation and recombination* (SR) dalam *time domain*, dimana setiap EEG *training trial* dibagi menjadi beberapa segmen *non-overlapping* dan kemudian *trial* artifisial baru dihasilkan dengan menggabungkan segmen-segmen ini dalam urutan temporal aslinya, masing-masing bersumber dari trial training yang berbeda namun dipilih secara acak dari kategori yang sama (Altaheri et al., 2025).

#### 2.4.4 Normalisasi Data

Normalisasi data merupakan tahapan *preprocessing* penting untuk memastikan sinyal EEG dari berbagai channel memiliki skala yang konsisten, sehingga meningkatkan efisiensi *training* model *deep learning* dan mencegah terjebak pada *local minima* (Altaheri et al., 2025; Rakhmatulin et al., 2024). Z-score normalization adalah metode yang paling umum digunakan, di mana setiap channel EEG dinormalisasi agar memiliki mean 0 dan standard deviation 1, dihitung dengan rumus:

$$x'_i = \frac{x_i - \mu}{\sigma} \quad (2.1)$$

Dengan  $x'_i$  adalah data mentah,  $\mu$  adalah mean, dan  $\sigma$  adalah *standard deviation* dari *training* dataset (Altaheri et al., 2025; Liao et al., 2025). Statistik ini dihitung dari *training* data saja dan diterapkan secara konsisten pada *validation* serta *test* data untuk menghindari data *leakage* (Altaheri et al., 2025). Beberapa variasi juga diusulkan, seperti *stratified normalization*, yang mengurangi variabilitas antar partisipan tanpa menghilangkan informasi emosional dalam data (Ma et al., 2022), serta *min-max normalization*, meskipun z-score tetap paling umum digunakan (Al-Saegh et al., 2021; Rakhmatulin et al., 2024). Dalam konteks CNN *architectures* untuk MI-EEG, normalisasi yang tepat dapat meningkatkan konvergensi dan stabilitas model, di mana minimal *preprocessing pipeline* dengan *standardization* terbukti efektif untuk aplikasi EEG *deep learning* (Rakhmatulin et al., 2024).

## 2.5 Deep Learning Untuk Klasifikasi EEG

*Deep learning* telah merevolusi bidang klasifikasi sinyal *Electroencephalogram* (EEG), khususnya dalam aplikasi *motor imagery* berbasis *Brain-Computer Interface* (MI-BCI), dengan kemampuannya untuk secara otomatis mengekstraksi fitur kompleks dari data mentah tanpa memerlukan *feature engineering manual* (Rakhmatulin et al., 2024; H. Zhang et al., 2023). Berbeda dengan metode pembelajaran mesin tradisional yang bergantung pada ekstraksi fitur *handcrafted* seperti *Common Spatial Pattern* (CSP) dan transformasi *Fourier* yang rentan terhadap derau dan memerlukan pengetahuan domain yang ekstensif, arsitektur *deep learning* mampu mempelajari representasi hierarkis dari sinyal EEG melalui *multiple layers of abstraction*, memungkinkan deteksi pola yang lebih *robust* dan generalisasi yang lebih baik pada data yang tidak terlihat sebelumnya (Al-Saegh et al., 2021).

### 2.5.1 Convolutional Neural Networks (CNN)

*Convolutional Neural Networks* (CNN) efektif mengekstraksi pola spasial dan temporal lokal dari sinyal EEG multi-kanal melalui operasi konvolusi dan *pooling* yang bekerja pada representasi matriks  $\text{channels} \times \text{time}$ , sehingga fitur relevan dapat dipelajari langsung dari data mentah tanpa rekayasa fitur manual (Al-Saegh et al., 2021). EEGNet menjadi rujukan *lightweight* karena memadukan temporal *convolution* untuk menangkap karakteristik frekuensi, *depthwise convolution* untuk filter spasial per-channel, dan *separable convolution* untuk memperdalam representasi temporal dengan jumlah parameter sangat kecil sehingga cocok untuk dataset MI skala terbatas (Lawhern et al., 2018). Perkembangan mutakhir menambahkan jalur multi-skala melalui cabang paralel dan mekanisme atensi untuk meningkatkan cakupan frekuensi-waktu, seperti varian multiskala yang menunjukkan kenaikan akurasi MI sekaligus menjaga efisiensi parameter pada konfigurasi ringan (Rakhmatulin et al., 2024; Wu et al., 2025). Meski demikian, keterbatasan *receptive field* membuat CNN murni kurang optimal dalam menangkap dependensi temporal jangka panjang, sehingga dikombinasikan dengan modul khusus temporal pada arsitektur hibrida modern (Zhang et al., 2023).



### 2.5.2 Temporal Convolutional Networks (TCN)

*Temporal Convolutional Networks* (TCN) memodelkan dinamika temporal EEG menggunakan *dilated causal convolution* sehingga *receptive field* meluas eksponensial tanpa menaikkan kedalaman berlebihan, sekaligus mempertahankan kausalitas urutan waktu untuk skenario *decoding real-time* (Ingolfsson et al., 2020). Arsitektur ini memanfaatkan residual connections untuk memperlancar aliran gradien dan stabilitas pelatihan, serta sepenuhnya paralelisasi di GPU/CPU modern sehingga lebih efisien dibanding RNN/LSTM pada deret panjang (Altaheri et al., 2025; Ingolfsson et al., 2020). Pada ranah neuro, TCN terbukti kompetitif untuk *decoding motor imagery* dan deteksi kejang karena mampu menangkap pola osilatori dan transien lintas skala waktu dengan kompleksitas komputasi terukur, terutama ketika ditempatkan setelah ekstraktor fitur spasial berbasis CNN (Al-Saegh et al., 2021; Zhao et al., 2024).

### 2.5.3 Attention Mechanisms


*Attention Mechanisms* meningkatkan *signal-to-noise ratio* dengan memfokuskan model pada kanal atau fitur yang paling informatif. *Channel attention* seperti *Squeeze-and-Excitation* (SE) melakukan re-kalibrasi respons kanal melalui *squeeze-excitation*, sedangkan *Efficient Channel Attention* (ECA) menghilangkan *fully connected bottleneck* dan memakai *local cross-channel interaction* sehingga jauh lebih ringan untuk perangkat terbatas (Wu et al., 2025). *Spatial attention* menonjolkan lokasi spasial penting pada representasi fitur, sementara *self-attention* berbasis *Transformer* menangkap dependensi global lintas waktu dengan *multi-head* namun berbiaya parameter dan FLOPs lebih tinggi; karya hibrida terkini menurunkan biaya dengan desain grouped-query atau local-global attention agar tetap efisien di EEG (Altaheri et al., 2025; Zhao et al., 2024). Dalam konteks *lightweight*, ECA berada pada kelas sangat ringan (~ratusan parameter) dibanding CBAM pada kelas menengah (~ribuan hingga puluhan ribu parameter) dan *multi-head self-attention* pada kelas berat (~puluhan ribu parameter), sehingga menjadi pilihan tepat untuk pipeline 4-kanal yang menuntut efisiensi tanpa mengorbankan akurasi (Al-Saegh et al., 2021; Wu et al., 2025).

## 2.6 Arsitektur *Deep Learning*

Klasifikasi sinyal *Motor Imagery Electroencephalography* (MI-EEG) merupakan salah satu tantangan utama dalam pengembangan sistem *Brain-Computer Interface* (BCI). Arsitektur *deep learning* telah menunjukkan kemampuan unggul dalam mengekstraksi fitur temporal-spasial secara otomatis dari sinyal EEG mentah, menghilangkan ketergantungan pada ekstraksi fitur manual yang kompleks (Al-Saegh et al., 2021). Berbagai arsitektur telah dikembangkan untuk mengatasi karakteristik sinyal EEG yang kompleks, termasuk rasio sinyal-ke-derau rendah, sifat *non-stationary*, dan variabilitas tinggi antar subjek (Gu et al., 2025). Sub-bab ini akan membahas arsitektur-arsitektur kunci yang menjadi dasar pengembangan model *hybrid* untuk klasifikasi MI-EEG, mulai dari arsitektur individual yang efisien hingga model-model *hybrid state-of-the-art*.

### 2.6.1 EEGNet

EEGNet merupakan arsitektur *Convolutional Neural Network* (CNN) yang kompak dan efisien, dirancang khusus untuk klasifikasi sinyal EEG pada *brain-computer interface* (Lawhern et al., 2018). Arsitektur ini mengatasi keterbatasan CNN konvensional untuk data EEG dengan mengadopsi prinsip *depthwise separable convolution* yang memisahkan operasi konvolusi menjadi dua tahap: (1) *depthwise convolution* untuk pembelajaran filter spasial per-kanal, dan (2) *pointwise convolution* ( $1 \times 1$ ) untuk kombinasi linear antarkanal, menghasilkan desain yang sangat efisien secara parameter (Rakhmatulin et al., 2024; Wu et al., 2025).



Gambar II.3 Arsitektur EEGNet (Rakhmatulin et al., 2024)

Struktur pada Gambar 2.3 terdiri dari beberapa blok konvolusional utama. Blok pertama adalah temporal convolution menggunakan  $F_1$  filter dengan ukuran kernel  $(1, K)$  untuk mengekstraksi fitur frekuensi temporal dari sinyal EEG input berukuran  $(C, T)$  di mana  $C$  adalah jumlah kanal EEG dan  $T$  adalah jumlah sampel temporal (Lawhern et al., 2018). Blok kedua adalah depthwise convolution dengan ukuran kernel  $(C, 1)$  yang memungkinkan model mempelajari filter spasial secara terpisah untuk setiap peta fitur temporal; parameter *depth multiplier*  $D$  menentukan jumlah filter spasial yang dipelajari untuk setiap peta fitur (Rakhmatulin et al., 2024). Blok ketiga adalah *separable convolution* yang terdiri dari *depthwise convolution* diikuti *pointwise convolution*  $(1 \times 1)$  untuk menghasilkan  $F_2$  peta fitur akhir yang mengintegrasikan informasi temporal dan spasial secara efisien (Rakhmatulin et al., 2024).

Formulasi matematis *depthwise separable convolution*:

$$Y_c = X_c * K_c \quad (2.1)$$

di mana:

- $Y_c$  = peta fitur keluaran kanal- $c$  setelah *depthwise convolution*
- $X_c$  = peta fitur masukan kanal- $c$
- $K_c$  = kernel filter spasial untuk kanal- $c$

Setelah *depthwise, pointwise convolution* ( $1 \times 1$ ) menggabungkan kanal:

$$Z_m = \sum_{c=1}^C Y_c * P_{c,m} \quad (2.2)$$

di mana:

- $Z_m$  = peta fitur keluaran untuk *feature map*  $m$
- $P_{c,m}$  = bobot pointwise  $1 \times 1$  dari kanal  $c$  ke *feature map*  $m$
- $C$  = jumlah total kanal masuk


Pada kompleksitas komputasi, konvolusi standar memiliki kompleksitas  $O(K^2CM)$ , sedangkan *depthwise separable* menurunkannya menjadi  $O(K^2C + CM)$ , di mana  $K$  ukuran kernel,  $C$  kanal masuk, dan  $M$  kanal keluar; penghematan ini membuat EEGNet layak untuk perangkat terbatas (Rakhmatulin et al., 2024).

Keunggulan utama EEGNet terletak pada efisiensi arsitektur dengan jumlah parameter sangat rendah. Pada dataset BCI *Competition* IV-2a dengan 22 kanal EEG, EEGNet hanya memiliki sekitar 2,9 ribu parameter, jauh lebih sedikit dibandingkan arsitektur CNN konvensional seperti ShallowConvNet (46,1K parameter), namun tetap menunjukkan performa kompetitif dengan akurasi rata-rata 71,88% pada dataset BCI IV-2a dan 87,71% pada dataset IV-2b dalam evaluasi *subject-specific* (Lawhern et al., 2018; Rakhmatulin et al., 2024). Keterbatasan utama EEGNet adalah tidak memodelkan dependensi temporal jangka panjang dan tidak memiliki mekanisme atensi untuk fokus pada kanal yang informatif (Rakhmatulin et al., 2024).

### 2.6.2 TCNet

*Temporal Convolutional Network* (TCN) merupakan arsitektur berbasis *dilated causal convolution* yang dirancang untuk memodelkan dependensi temporal jangka panjang pada data deret waktu seperti sinyal EEG (Ingolfsson et al., 2020). TCN mengatasi keterbatasan *receptive field* terbatas pada CNN standar dengan menggunakan dilasi (*dilation*) yang memperluas jangkauan temporal secara eksponensial tanpa meningkatkan kedalaman jaringan secara berlebihan, sekaligus

mempertahankan kausalitas urutan yang penting untuk *decoding real-time* (Ingolfsson et al., 2020).



Gambar II.4 Arsitektur TCNet (Ingolfsson et al, 2020)

Gambar 2.4 merupakan arsitektur dari TCNet, blok residual TCN terdiri dari dua lapis dilated causal convolution yang masing-masing diikuti *Batch Normalization*, aktivasi ELU (*Exponential Linear Unit*), dan dropout untuk regularisasi; terdapat *shortcut connection* (opsional dengan  $1 \times 1$  conv untuk menyesuaikan dimensi) yang menjaga kecocokan dimensi saat penjumlahan residual, sehingga gradien dapat mengalir lebih lancar dan pelatihan lebih stabil (Ingolfsson et al., 2020).

Formulasi *dilated causal convolution*:

$$(x *_d f)(t) = \sum_{i=0}^{k-1} f(i)x(t - d \cdot i) \quad (2.3)$$

di mana:

- $x$  = sinyal input deret waktu.
- $f$  = kernel filter konvolusi dengan Panjang  $k$ .
- $d$  = faktor dilasi (*dilation rate*) yang menentukan seberapa jauh sampel dilompati.

- $t$  = indeks waktu; dilasi memperluas *receptive field* tanpa menambah banyak parameter.

*Receptive field* efektif pada stack TCN:

$$RF = 1 + \sum_{l=1}^L (k_l - 1) \prod_{j=1}^l d_j \quad (2.4)$$

di mana:

- $RF$  = *receptive field* total (jangkauan temporal) yang dapat "dilihat" oleh model.
- $L$  = jumlah *layer* (blok residual) dalam stack.
- $k_l$  = ukuran kernel pada layer  $l$ .
- $d_j$  = faktor dilasi pada layer  $j$ ; kombinasi dilasi bertingkat (mis. 1, 2, 4, 8) memperluas RF secara eksponensial.

Residual block dalam TCN:

$$y = x + F(x; \theta) \quad (2.5)$$

di mana:


- $y$  = *output* blok residual.
- $x$  = *input* ke blok residual.
- $F(x; \theta)$  = transformasi melalui dua *dilated causal conv*–BN–ELU–Dropout.
- *Shortcut*  $x$  memfasilitasi *gradient flow* yang lebih baik dan mencegah degradasi akurasi saat jaringan dalam

Penumpukan beberapa blok residual dengan dilasi bertingkat (1, 2, 4, 8) memungkinkan TCN menangkap pola osilatori MI pada berbagai skala waktu, dari pola lokal hingga dependensi jangka panjang, dengan kausalitas terjaga untuk inferensi real-time (Ingolfsson et al., 2020). Ketika dikombinasikan dengan EEGNet sebagai *spatial feature extractor*, arsitektur EEG-TCNet dilaporkan mencapai akurasi sekitar 77,35% dengan total parameter ~4,27K pada konfigurasi ringan, menunjukkan sinergi

kuat antara ekstraksi spasial EEGNet dan pemodelan temporal TCN (Ingolfsson et al., 2020).

### 2.6.3 Efficient Channel Attention (ECA)

*Efficient Channel Attention* (ECA) merupakan mekanisme atensi yang ringan dan efisien, dirancang untuk menangkap dependensi antar-kanal dalam jaringan neural konvolusional tanpa *overhead* komputasi signifikan (Q. Wang et al., 2020). ECA dikembangkan sebagai alternatif lebih efisien terhadap *Squeeze-and-Excitation* (SE) block yang melibatkan reduksi dimensi dan ekspansi melalui dua *fully connected layers*; ECA menghindari reduksi dimensi dengan menggunakan konvolusi 1D yang menangkap dependensi kanal lokal secara efisien, sehingga jumlah parameter yang ditambahkan hanya ratusan (Q. Wang et al., 2020; Wu et al., 2025).



Gambar II.5 Module Efficient Channel Attention (ECA) (Wu et al., 2025)

Gambar 2.5 mengilustrasikan mekanisme kerja modul ECA secara detail. Proses dimulai dengan penerapan *Global Average Pooling* (GAP) pada dimensi spasial untuk menghasilkan *channel descriptor* berupa vektor dengan ukuran  $C$  (jumlah kanal), di mana setiap elemen merepresentasikan informasi global dari kanal bersangkutan (Wu et al., 2025).

Formulasi Global Average Pooling (GAP):

$$z_c = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W X_c(i, j) \quad (2.6)$$

di mana:

- $z_c$  = deskriptor kanal ke- $c$  hasil GAP.

- $X_c(i, j)$  = peta fitur kanal ke- $c$  pada posisi spasial.
- $H$  dan  $W$  = tinggi dan lebar peta fitur spasial.
- Operasi ini merangkum informasi global kanal ke- $c$  menjadi satu nilai skalar.

Penentuan ukuran kernel adaptif:

$$k = \left\lceil \frac{\log_2 C}{\gamma} + b \right\rceil_{\text{odd}} \quad (2.7)$$

di mana:

- $k$  = ukuran kernel konvolusi 1D pada ECA.
- $C$  = jumlah kanal input.
- $\gamma$  dan  $b$  = hyperparameter.
- Operasi  $\lceil \cdot \rceil_{\text{odd}}$  = memastikan  $k$  bilangan ganjil agar konvolusi simetris; ukuran kernel kecil namun proporsional terhadap  $C$ .

Skor atensi kanal:

$$a = \sigma(\text{Conv1D}_k(z)) \quad (2.8)$$

di mana:

- $a$  = vektor bobot atensi kanal.
- $\text{Conv1D}_k(z)$  = konvolusi 1D ukuran  $k$  pada deskriptor kanal  $z$ .
- $\sigma$  = fungsi aktivasi sigmoid untuk menormalisasi bobot ke rentang (0,1)
- Bobot  $a$  mengindikasikan kepentingan relatif setiap kanal untuk tugas klasifikasi.

Re-kalibrasi peta fitur:

$$\widetilde{X}_c = a_c \cdot X_c \quad (2.9)$$

di mana:

- $\widetilde{X}_c$  = peta fitur kanal ke- $c$  setelah dikalibrasi ulang.
- $a_c$  = bobot atensi untuk kanal ke- $c$ .
- $X_c$  = peta fitur asli kanal ke- $c$ .



- Operasi  $\cdot$  = perkalian *element-wise* (*channel-wise*); kanal dengan  $a_c$  tinggi diperkuat, kanal dengan  $a_c$  rendah ditekan.

Dalam konteks klasifikasi MI-EEG, ECA terbukti efektif meningkatkan performa model dengan overhead komputasi minimal. Penelitian mengintegrasikan ECA setelah lapisan konvolusi *depthwise* pada arsitektur AMEEGNet, di mana kombinasi linear dari kanal asli diperlakukan sebagai kanal baru yang mempertahankan informasi berharga dari sinyal EEG; hasilnya mencapai peningkatan akurasi sekitar +4,05% dibanding baseline multiskala tanpa ECA (Wu et al., 2025).

## 2.7 Evaluasi Model BCI

Evaluasi model *Brain-Computer Interface* (BCI) merupakan tahapan krusial untuk menilai performa sistem dalam mengklasifikasikan sinyal *Electroencephalography* (EEG) berbasis *Motor Imagery* (MI). Proses evaluasi mencakup pemilihan strategi validasi, metrik evaluasi yang tepat, serta analisis kontribusi komponen model melalui *ablation study* (H. Zhang et al., 2023). Pemilihan metodologi evaluasi yang sesuai sangat penting karena perbedaan strategi dapat menghasilkan perbedaan signifikan dalam interpretasi performa model, terutama dalam konteks aplikasi BCI praktis yang memerlukan reliabilitas tinggi (Gu et al., 2025).

### 2.7.1 *Within-Subject Classification*

Within-subject classification merujuk pada pendekatan evaluasi di mana data pelatihan dan pengujian berasal dari subjek yang sama (Gu et al., 2025). Metode ini sering menggunakan teknik *cross-validation*, seperti *k-fold cross-validation* atau *hold-out validation*, untuk membagi data dari satu sesi atau beberapa sesi subjek yang sama (H. Zhang et al., 2023). Pada dataset BCI *Competition IV-2a* yang merupakan *benchmark* standar dalam penelitian MI-EEG, *within-subject evaluation* biasanya menggunakan dua skema: (1) sesi pertama untuk pelatihan dan sesi kedua untuk pengujian, atau (2) menggabungkan kedua sesi untuk *k-fold cross-validation* (H. Zhang et al., 2023; Zhao et al., 2024).

Pendekatan within-subject umumnya menghasilkan akurasi klasifikasi yang lebih tinggi dibandingkan cross-subject karena model dapat menyesuaikan dengan pola

EEG spesifik individu (Altaheri et al., 2025). Studi oleh Gu et al. (2025) menunjukkan bahwa model CLTNet mencapai akurasi rata-rata 83,02% dengan nilai Cohen's Kappa 0,77 pada dataset BCI *Competition IV-2a* menggunakan evaluasi *within-subject five-fold cross-validation*. Pada evaluasi *within-subject* serupa, model CTNet mencapai akurasi 82,52% ( $\kappa=0,7670$ ) pada BCI IV-2a dan 88,49% ( $\kappa=0,7697$ ) pada BCI IV-2b, menunjukkan konsistensi performa yang tinggi dengan variance yang rendah (Zhao et al., 2024).

Keuntungan utama pendekatan *within-subject* adalah kemampuan model untuk menangkap variabilitas sinyal EEG yang unik untuk setiap subjek, termasuk perbedaan anatomis struktur otak, kondisi psikofisiologis, karakteristik *noise* individual, dan preferensi strategi *motor imagery* (Liao et al., 2025; H. Zhang et al., 2023). Namun, metode ini memerlukan data kalibrasi yang cukup dari subjek target dan kurang efektif untuk aplikasi *plug-and-play* BCI yang memerlukan penggunaan langsung tanpa fase kalibrasi ekstensif (H. Zhang et al., 2023). Untuk perangkat *consumer-grade* dengan jumlah *channel* terbatas, *within-subject approach* menjadi lebih praktis karena dapat mencapai performa *reliable* dengan prosedur kalibrasi yang singkat (5-10 menit) dibandingkan dengan *cross-subject approach* yang memerlukan data dari banyak subjek (Garcia-Moreno et al., 2020).

### **2.7.2 Cross-Subject Classification**

*Cross-subject classification* mengacu pada skenario evaluasi di mana model dilatih menggunakan data dari beberapa subjek dan diuji pada subjek yang belum pernah dilihat sebelumnya (*unseen subject*) (H. Zhang et al., 2023). Metode *Leave-One-Subject-Out* (LOSO) merupakan pendekatan yang paling umum digunakan dalam evaluasi *cross-subject*, di mana data dari N-1 subjek digunakan untuk pelatihan dan satu subjek sisanya untuk pengujian, proses ini diulang N kali untuk setiap subjek sehingga setiap subjek menjadi *test subject* sekali (Altaheri et al., 2025; H. Zhang et al., 2023). Skema evaluasi ini memberikan estimasi yang lebih realistis tentang kemampuan generalisasi model pada populasi yang lebih luas (Gu et al., 2025).

*Cross-subject evaluation* menghadapi tantangan signifikan karena variabilitas antar-subjek yang tinggi dalam sinyal EEG, termasuk perbedaan distribusi spasial

elektroda, karakteristik spektral sinyal, dan rasio *signal-to-noise* yang bervariasi antar individu (H. Zhang et al., 2023). Zhang et al. (2023) melaporkan bahwa meskipun model CRNN-DF mereka mencapai akurasi rata-rata 63,52% pada evaluasi cross-subject di BCI IV-2a, terdapat standar deviasi yang cukup besar (10,70%) yang mengindikasikan variasi performa antar subjek yang substansial. Model TCFormer yang diusulkan oleh Altaheri et al. (2024) mencapai akurasi cross-subject sebesar 63,0% pada BCI IV-2a dan 81,34% pada BCI IV-2b, menunjukkan performa yang lebih baik pada dataset *binary classification*.

### 2.7.3 Metrik Evaluasi

Evaluasi performa model BCI memerlukan metrik yang *robust* untuk mengukur kemampuan klasifikasi secara komprehensif. Tiga metrik utama yang digunakan dalam penelitian MI-EEG adalah *accuracy*, *Cohen's Kappa coefficient*, dan *F1-Score* (Gu et al., 2025; Liao et al., 2025; Zhao et al., 2025).

*Accuracy* merupakan metrik paling fundamental yang mengukur proporsi prediksi yang benar terhadap total prediksi, dihitung dengan formula:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (2.6)$$

di mana TP (True Positive), TN (True Negative), FP (False Positive), dan FN (False Negative) merepresentasikan jumlah sampel pada setiap kategori *confusion matrix* (Al-Saegh et al., 2021). *Accuracy* memberikan gambaran intuitif tentang performa keseluruhan model dan mudah diinterpretasikan, namun dapat menyesatkan pada dataset dengan distribusi kelas yang tidak seimbang karena model dapat mencapai *accuracy* tinggi dengan hanya memprediksi kelas mayoritas (Gu et al., 2025).

*Cohen's Kappa coefficient* merupakan metrik yang menormalisasi *accuracy* dengan mempertimbangkan kemungkinan kesepakatan acak (*chance agreement*), dihitung dengan:

$$\kappa = \frac{P_o - P_e}{1 - P_e} \quad (2.7)$$

Dimana  $P_o$  adalah *observer agreement* (*accuracy* aktual) dan  $P_e$  adalah *expected agreement* dari klasifikasi acak (Gu et al., 2025; Zhao et al., 2025). dihitung berdasarkan distribusi prediksi dan *ground truth*:  $P_e = \sum_{i=1}^M p_i \times q_i$  dimana  $p_i$  adalah proporsi prediksi kelas  $i$  dan  $q_i$  adalah proporsi *ground truth* kelas  $i$  (Zhao et al., 2024). Nilai Kappa berkisar antara -1 (*perfect disagreement*) hingga 1 (*perfect agreement*), dengan interpretasi:  $\kappa < 0,4$  (*poor*),  $0,4 \leq \kappa < 0,6$  (*moderate*),  $0,6 \leq \kappa < 0,8$  (*substantial*), dan  $\kappa \geq 0,8$  (*almost perfect agreement*) (Gu et al., 2025).

F1-Score mengkombinasikan *precision* dan *recall* melalui *harmonic mean*, memberikan ukuran yang seimbang terutama untuk klasifikasi dengan kelas yang tidak seimbang:

$$\text{F1-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (2.8)$$


di mana  $\text{Precision} = \text{TP}/(\text{TP}+\text{FP})$  mengukur proporsi prediksi positif yang benar, dan  $\text{Recall} = \text{TP}/(\text{TP}+\text{FN})$  mengukur proporsi sampel positif aktual yang terdeteksi (Liao et al., 2025). Untuk klasifikasi multi-kelas, F1-Score dapat dihitung per-kelas dan kemudian di-*aggregate* menggunakan *macro-averaging* (rata-rata aritmatik F1 setiap kelas) atau *weighted-averaging* (rata-rata tertimbang berdasarkan jumlah sampel per kelas) (Liao et al., 2025).

## BAB III

### METODE PENELITIAN

#### 3.1 Kerangka Penelitian

Penelitian ini mengadopsi pendekatan *end-to-end* yang terdiri dari tujuh tahapan utama, mengikuti kerangka metodologi eksperimental dari EEG-TCNet (Ingolfsson et al., 2020) dengan modifikasi strategis untuk perangkat *consumer-grade* Muse S Gen 2 (4-kanal) dan penambahan modul *Efficient Channel Attention* (ECA) dari AMEEGNet (Wu et al., 2025) sebagai novelty penelitian. Kerangka ini dirancang untuk mengembangkan model klasifikasi *motor imagery* berbasis EEG yang efisien, akurat, dan layak untuk *deployment embedded*. Gambar 3.1 mengilustrasikan alur penelitian secara komprehensif, yang akan dijelaskan detail teknisnya pada subpoin berikutnya.



Gambar III.1 Kerangka Penelitian

Penelitian ini mengadopsi pendekatan *end-to-end* yang terdiri dari tujuh tahapan utama, berikut penjelasannya:

- *Data Acquisition*

Tahap pertama melibatkan pengumpulan data sinyal EEG menggunakan Muse S Gen 2 (4 kanal: TP9, AF7, AF8, TP10) dengan protokol *cue-based motor imagery*. Setiap subjek (N=[jumlah] partisipan) melakukan minimal 80 *trials*

dengan durasi 4 detik MI period, direkam pada sampling rate 256 Hz untuk menangkap ritme  $\mu$  dan  $\beta$  (Ingolfsson et al., 2020; Sabio et al., 2024).

- *Signal Preprocessing*

Sinyal mentah diproses melalui *pipeline preprocessing* standar: *bandpass filtering* 8–30 Hz untuk isolasi ritme MI, *artifact removal* berbasis *threshold* untuk eliminasi *noise*, *epoching* 4,5 detik per trial (0,5s *pre-cue* hingga 4s *post-cue*), dan *standardization z-score* per-channel dari statistik *training set* (Ingolfsson et al., 2020; Rakhmatulin et al., 2024).

- *Evaluasi Cross-Validation*

Berbeda dengan pembagian data statis, penelitian ini menerapkan skema evaluasi *Within-Subject 5-Fold Cross-Validation* untuk mengatasi keterbatasan jumlah sampel (80 trials per subjek). Data dipartisi menjadi 5 bagian (*folds*) yang seimbang. Pada setiap iterasi, 4 *fold* digunakan untuk pelatihan dan validasi internal, sedangkan 1 *fold* digunakan sebagai data uji. Proses ini diulang sebanyak 5 kali hingga seluruh data pernah menjadi data uji, menghasilkan estimasi performa yang lebih objektif dan tidak bias.

- *Data Augmentation*

Untuk mengatasi keterbatasan jumlah data (80 *trials*), diterapkan teknik *augmentation time shifting*, *amplitude scaling*, dan *additive noise* hanya pada *training set* untuk meningkatkan generalisasi model tanpa mengubah karakteristik temporal fundamental MI (Rakhmatulin et al., 2024).

- *Model Development*

Tahap ini merancang *baseline* model (EEGNet standalone, EEGNet+TCN) dan proposed model EEGNet-ECA-TCN yang mengintegrasikan tiga komponen serial: (a) EEGNet untuk *spatial-spectral feature extraction* (~1,700 params), (b) ECA untuk *adaptive channel attention* (~500 params), dan (c) TCN untuk *temporal modeling* (~2,600 params) (Ingolfsson et al., 2020; Wu et al., 2025).

- *Training & Optimization*

Model dilatih menggunakan Adam *optimizer* ( $lr=0,001$ ), *categorical cross-entropy loss*, batch size 64, dan maksimal 200 *epoch* dengan *early stopping* (*patience*=20) dan model *checkpointing* untuk mencegah *overfitting*

(Ingolfsson et al., 2020). Hyperparameter tuning sistematis dilakukan untuk *learning rate*, *dropout*, dan konfigurasi TCN/ECA.

- *Evaluation and Analysis*

Evaluasi komprehensif dilakukan dalam tiga perspektif: (1) metrik performa (*accuracy*, *kappa*, *precision*, *recall*, F1, AUC-ROC) pada test set, (2) studi ablasi untuk mengukur kontribusi ECA dan TCN terhadap baseline, dan (3) *deployment analysis* untuk memvalidasi *feasibility embedded* (Ingolfsson et al., 2020; Wu et al., 2025).

### **3.2 Pengumpulan Data**

Tahap pengumpulan data dirancang untuk mengumpulkan sinyal EEG *motor imagery* dengan kualitas optimal menggunakan perangkat Muse S Gen 2. Protokol akuisisi mengikuti standar yang telah ditetapkan dalam kompetisi BCI *Competition IV-2a* dengan penyesuaian untuk perangkat 4 kanal, sehingga data yang terkumpul dapat digunakan secara efektif untuk mengevaluasi performa model EEGNet-ECA-TCN yang diusulkan dalam penelitian ini.

#### **3.2.1 Dataset**

Dataset yang direkam menggunakan Muse S Gen 2 menghasilkan data EEG dalam bentuk deretan waktu (time-series) yang mencakup 4 kanal elektroda dengan frekuensi sampling 256 Hz. Struktur data mentah yang dihasilkan sangat kompleks, terdiri dari 44 kolom yang mencakup sinyal EEG mentah, data akselerometer, giroskop, indikator kualitas sinyal (HSI), serta nilai daya spektral (Alpha, Beta, Delta, Theta) yang telah diproses sebelumnya oleh algoritma internal Muse.

|    |                                                                                                                                 |
|----|---------------------------------------------------------------------------------------------------------------------------------|
| 1  | TimeStamp,Delta_TP9,Delta_AF7,Delta_AF8,Delta_TP10,Theta_TP9,Theta_AF7,Theta_AF8,Theta_TP10,Alpha_TP9,Alpha_AF7,Alpha_AF8,      |
| 2  | 2025-10-22 15:24:59.233,,,,,,,,,,,,,/muse/event/connected MuseS-92C1                                                            |
| 3  | 2025-10-22 15:24:59.250,0.38178006,-0.095506124,-0.52369237,0.50341105,0.42759016,0.43913642,-0.020086985,0.72804594,0.6164815  |
| 4  | 2025-10-22 15:24:59.574,,,,,,,,,,,,,/muse/elements/blink                                                                        |
| 5  | 2025-10-22 15:25:00.256,0.09605719,-0.085592814,0.14117923,0.3341238,0.48436585,0.5076906,0.11855464,0.58932376,0.475153,0.190  |
| 6  | 2025-10-22 15:25:00.795,,,,,,,,,,,,,/muse/elements/blink                                                                        |
| 7  | 2025-10-22 15:25:01.262,0.18239842,0.387198,0.643161,0.35989672,0.4428398,0.28051195,-0.039299008,0.5609392,0.3542757,0.053772  |
| 8  | 2025-10-22 15:25:02.171,,,,,,,,,,,,,/muse/elements/blink                                                                        |
| 9  | 2025-10-22 15:25:02.284,0.18239842,0.867828,0.3412943,0.35989672,0.4428398,0.35311338,-0.03215742,0.5609392,0.3542757,0.033373  |
| 10 | 2025-10-22 15:25:03.301,0.18239842,0.90810925,0.55588686,0.35989672,0.4428398,0.47172582,0.0017730431,0.5609392,0.3542757,0.19  |
| 11 | 2025-10-22 15:25:03.369,,,,,,,,,,,,,/muse/elements/blink                                                                        |
| 12 | 2025-10-22 15:25:04.313,0.18239842,0.0136270905,0.4429486,0.35989672,0.4428398,-0.08420086,0.027515244,0.5609392,0.3542757,0.1  |
| 13 | 2025-10-22 15:25:04.697,,,,,,,,,,,,,/muse/elements/blink                                                                        |
| 14 | 2025-10-22 15:25:05.323,-0.08391505,-0.07247934,-0.030777808,0.35989672,0.15748033,-0.10764863,-0.19613571,0.5609392,0.6009239, |
| 15 | 2025-10-22 15:25:05.899,,,,,,,,,,,,,/muse/elements/blink                                                                        |
| 16 | 2025-10-22 15:25:06.343,0.1441936,-0.49748105,-0.47261006,0.98560065,-0.008177601,-0.29923725,-0.3321668,0.9530046,0.56809044,0 |
| 17 | 2025-10-22 15:25:07.218,,,,,,,,,,,,,/muse/elements/blink                                                                        |
| 18 | 2025-10-22 15:25:07.352,0.30752343,-0.48038715,-0.5019864,0.62959677,0.10495402,-0.24436314,-0.18933679,0.9215891,0.49024308,0. |
| 19 | 2025-10-22 15:25:08.354,0.04395669,0.6914105,0.26774403,0.62959677,-0.17714361,0.43193778,0.17763889,0.9215891,0.3763238,0.338  |

Gambar III.2 Dataset Mentah

Gambar 3.2 memvisualisasikan sampel awal dari dataset mentah. Dari total 44 kolom yang tersedia, penelitian ini melakukan seleksi kolom (*column selection*) secara spesifik untuk tahap pemrosesan selanjutnya. Hanya lima kolom utama yang digunakan, yaitu:

1. *TimeStamp*: Digunakan sebagai referensi waktu untuk sinkronisasi *event marker* dan proses pemotongan sinyal (*epoching*).
2. *Raw TP9*, *Raw AF7*, *Raw AF8*, dan *Raw TP10*: Empat kolom ini berisi data tegangan listrik otak murni (dalam mikrovolt) yang menjadi input utama bagi model.

Kolom-kolom data sekunder seperti daya spektral (Absolut Alpha/Beta) dan indikator HSI tidak digunakan dan dieliminasi pada tahap *preprocessing*. Hal ini dilakukan karena arsitektur *Deep Learning* (EEGNet-ECA-TCNet) dirancang untuk mengekstrak fitur spasial dan temporal secara otomatis langsung dari data mentah (*raw data*), sehingga tidak memerlukan fitur yang telah direkayasa sebelumnya (*hand-crafted features*) dari perangkat lunak bawaan. Data penanda kejadian (*event markers*) seperti kedipan mata (teks merah pada gambar) digunakan terpisah hanya untuk keperluan *artifact removal*.

### 3.2.2 Perangkat Keras

Penelitian ini menggunakan Muse S Gen 2 EEG *Headband* sebagai perangkat utama untuk merekam sinyal EEG. Perangkat ini menggunakan 4 kanal aktif yang



ditempatkan pada posisi TP9, AF7, AF8, dan TP10. Elektroda menggunakan material polimer kering yang tidak memerlukan gel konduktif sehingga lebih praktis dan nyaman untuk digunakan dalam jangka waktu lama dibandingkan elektroda basah. (Sabio et al., 2024)

Pemilihan Muse S Gen 2 didasarkan pada beberapa pertimbangan utama yaitu aksesibilitas dan efektivitas biaya dimana harga perangkat jauh lebih terjangkau dibanding sistem *research-grade* dan portabilitas serta kenyamanan pengguna dengan desain nirkabel.

### 3.2.3 Protokol Eksperimen

Protokol eksperimen mengikuti paradigma cue-based *motor imagery* yang digunakan pada BCI *Competition IV-2a* dengan adaptasi untuk klasifikasi sesuai fokus penelitian. Setiap trial mengikuti struktur temporal yang terdiri dari empat fase utama sebagai berikut:

- Fase pertama adalah periode istirahat atau baseline selama 0-2 detik dimana subjek diminta untuk rileks sambil meminimalkan kedipan mata untuk menetapkan aktivitas otak baseline yang digunakan untuk normalisasi sinyal.
- Fase Kedua adalah munculnya cue selama 2-2,5 detik dimana panah visual muncul di layar dengan arah yang ditentukan dan bunyi beep pendek sebagai penanda awal tugas *motor imagery*.
- Fase Ketiga adalah periode *motor imagery* selama 4 detik penuh dimana panah tetap ditampilkan di layar dan subjek diminta untuk membayangkan gerakan membuka dan menutup tangan secara berulang sesuai arah panah.
- Fase keempat adalah periode relaksasi selama 2 detik dimana layar menjadi kosong dan subjek diminta untuk berhenti membayangkan gerakan dan beristirahat sebelum trial berikutnya untuk mencegah akumulasi kelelahan.

Lingkungan perekaman diatur sedemikian rupa untuk meminimalkan gangguan eksternal dengan ruangan yang tenang dan tingkat pencahayaan yang sedang. Subjek duduk di kursi yang nyaman dengan sandaran untuk menstabilkan posisi.

### 3.2.4 Pemilihan *Trials* dan Subjek

Penelitian ini menetapkan konfigurasi pengumpulan data dengan 16 subjek yang masing masing melakukan 80 *trials* dari 40 *trials* tangan kiri dan 40 *trials* tangan kanan. Pemilihan kombinasi jumlah subjek dan *trials* ini dirancang secara strategis berdasarkan perbandingan dengan dataset standar BCI Competition IV-2a untuk memastikan volume data yang *comparable* sambil mengoptimalkan validitas statistik.

Dataset BCI IV-2a menggunakan 9 subjek dengan 288 *trials* per subjek untuk klasifikasi 4 kelas, dengan 144 *trials* pada masing masing kelas yang menghasilkan total 9 subjek dengan 144 *trials* adalah 1.296 *trials*. Penelitian ini mengimplementasikan *trade-off* optimal antara jumlah subjek dan *trials* per subjek untuk mencapai total dataset yang hampir identik dengan BCI IV-2a, konfigurasi 16 subjek dengan 80 *trials* mengumpulkan total 1.280 *trials* yang hampir setara dengan total dataset BCI IV-2a

## 3.3 Preprocessing Sinyal

Tahap *preprocessing* sinyal dirancang untuk mengubah data EEG mentah menjadi format yang optimal untuk pembelajaran model deep learning. *Pipeline preprocessing* yang diterapkan dalam penelitian ini mengadaptasi protokol standar BCI Competition IV-2a (Tangermann et al., 2012) dengan penyesuaian spesifik untuk karakteristik perangkat Muse S Gen 2 dan kebutuhan arsitektur EEGNet-ECA-TCN.

### 3.3.1 Bandpass Filtering

Filtering frekuensi dilakukan menggunakan Butterworth bandpass filter orde ke-4 dengan rentang frekuensi 8-30 Hz mengisolasi komponen frekuensi yang relevan dengan aktivitas *motor imagery*. Rentang frekuensi ini mencakup ritme mu 8-13 Hz dan beta 13-30 Hz yang terkait dengan *event-related desynchronization* dan *event-related desynchronization* pada korteks sensorimotor selama pembayangan gerakan tangan (Al-Saegh et al., 2021).

Implementasi dilakukan menggunakan `scipy.signal.butter` dengan metode *forward-backward filtering* `filtfilt` untuk memastikan *zero-phase distortion* sehingga tidak menggeser komponen temporal sinyal EEG. Berbeda dengan penelitian EEG-TCNet

yang tidak menggunakan *bandpass filtering* tambahan karena BCI IV-2a sudah *pre-filtered* (Ingolfsson et al., 2020), *filtering* pada penelitian ini merupakan langkah *necessary* untuk mengkompensasi ketiadaan hardware *filtering* pada Muse S Gen 2 dan memastikan sinyal berada pada rentang frekuensi optimal untuk klasifikasi *deep learning*.

### **3.3.2 Artifact Removal**

*Artifact removal* dilakukan melalui *automatic trial rejection* berbasis deteksi kedipan mata dan monitoring kualitas kontak elektroda yang mengikuti prinsip *trial rejection* pada BCI IV-2a dimana 9.41% trial dieksklusikan berdasarkan EOG *marking* (Tangermann et al., 2012). Kedipan mata merupakan sumber artifak dominan pada kanal frontal AF7 dan AF8 yang dapat menghasilkan amplitudo hingga 200  $\mu\text{V}$ , jauh melebihi amplitudo normal sinyal EEG *motor imagery* sekitar 10–50  $\mu\text{V}$  (Al-Saegh et al., 2021). Sistem deteksi kedipan mata menggunakan penanda otomatis dari Muse SDK yang mengidentifikasi *event /muse/elements/blink* berdasarkan analisis *spectral power* dan *sudden amplitude change* pada kanal frontal.

### **3.3.3 Epoching dan Temporal Windowing**

*Epoching* dilakukan dengan mengekstrak jendela temporal 0.5 detik sebelum *cue onset* hingga 4 detik setelah *cue onset* menghasilkan total durasi 4.5 detik atau 1.152 sampel pada *sampling rate* 256 Hz yang identik dengan protokol BCI IV-2a menggunakan 1.125 sampel pada 250 Hz (Tangermann et al., 2012). Jendela temporal ini dipilih untuk menangkap *baseline activity* selama 0.5 detik pre-cue yang digunakan untuk *baseline correction* dan 4 detik post-cue yang mencakup periode motor *imagery* lengkap dimana ERD dan ERS terjadi secara maksimal pada rentang 1–3 detik setelah *cue onset* (Ingolfsson et al., 2020).

*Baseline correction* dilakukan dengan mengurangi rata-rata amplitudo dari periode 0.5 detik pre-cue pada setiap kanal untuk menghilangkan DC *offset* dan *low-frequency drift* yang dapat mempengaruhi kualitas klasifikasi (Wu et al., 2025). Metode mean subtraction dipilih dibanding high-pass filtering untuk baseline removal karena lebih sederhana secara komputasi dan tidak menimbulkan phase distortion yang

dapat mempengaruhi temporal features yang critical untuk TCN. Setiap epoch kemudian disimpan dalam format *array* 3D dengan dimensi *trials*  $\times$  *channels*  $\times$  *timepoints* untuk memudahkan *batch processing* pada tahap *training* model. Konsistensi *epoching window* dengan BCI IV-2a memastikan *comparability* hasil klasifikasi dengan literatur *existing* dan memungkinkan *direct comparison* dengan *baseline performance* EEG-TCNet yang mencapai 77.35% akurasi pada BCI IV-2a (Ingolfsson et al., 2020).

### 3.3.4 Normalization

*Normalization* dilakukan menggunakan *z-score standardization* per-channel untuk memastikan setiap kanal EEG memiliki mean 0 dan standar deviasi 1 yang mempercepat konvergensi *training* dan mengurangi sensitivitas terhadap *amplitude variations* antar subjek (Al-Saegh et al., 2021). Statistik mean dan standar deviasi dihitung dari training set untuk setiap kanal secara independen, diterapkan pada *validation* dan *test set* untuk mencegah data *leakage* yang dapat menyebabkan *overestimation performance*.

*Z-score standardization* dipilih dibanding *min-max normalization* karena lebih *robust* terhadap *outliers* yang sering muncul pada sinyal EEG akibat *sudden movement artifacts* atau *electrical interference* (Rakhmatulin et al., 2024). *Normalization* ini konsisten dengan praktik standar pada penelitian EEG-TCNet dan *multiple winning entries* pada BCI Competition IV yang menggunakan *per-channel standardization* untuk meningkatkan akurasi klasifikasi (Ingolfsson et al., 2020; Tangermann et al., 2012).

## 3.4 Dataset

Mengingat tingginya variabilitas sinyal EEG antar-subjek dan keterbatasan jumlah *trial* (80 *trials* per subjek), penelitian ini menerapkan strategi evaluasi yang ketat untuk menjamin validitas statistik. Pendekatan yang digunakan adalah kombinasi skema Within-Subject dan Stratified 5-Fold Cross-Validation.

### 3.4.1 *Within-Subject*

Skema evaluasi *within-subject* digunakan dalam penelitian ini, di mana model dilatih dan diuji secara independen untuk setiap subjek. Pendekatan ini dipilih karena variabilitas sinyal antar-individu (*inter-subject variability*) pada data EEG sangat tinggi. Penelitian terdahulu pada dataset standar BCI *Competition IV-2a* membuktikan bahwa pendekatan *within-subject* menghasilkan performa yang lebih adil dan optimal dibandingkan penggabungan data antar-subjek, sebagaimana direkomendasikan dalam studi baseline EEG-TCNet dan AMEEGNet. Model akan beradaptasi dengan pola otak spesifik dari masing-masing partisipan tanpa terganggu oleh perbedaan karakteristik sinyal dari partisipan lain.

### 3.4.2 *Stratified 5-Fold Cross-Validation*

Untuk mengatasi masalah keterbatasan data dan menghindari bias pada hasil pengujian, evaluasi performa dilakukan menggunakan skema *Stratified 5-Fold Cross-Validation*. Prosedur ini dilakukan dengan tahapan sebagai berikut:

1. Total 80 trials dari satu subjek diacak dan dipartisi menjadi 5 bagian (*folds*) yang saling lepas. Setiap *fold* berisi 16 *trials*, yang terdiri dari proporsi seimbang 8 *trials* kelas tangan kiri dan 8 *trials* kelas tangan kanan.
2. Proses pelatihan dan pengujian dilakukan dalam 5 kali iterasi.
3. Pada setiap iterasi, satu *fold* (16 *trials*) berfungsi sebagai Data Uji (*Testing Set*) untuk mengukur performa model, sedangkan 4 *fold* sisanya (64 *trials*) digabungkan menjadi Data Latih (*Training Set*).
4. Untuk keperluan mekanisme *Early Stopping* guna mencegah *overfitting*, sebagian kecil data dari *Training Set* (20%) dipisahkan secara otomatis sebagai Data Validasi Internal selama proses pelatihan berlangsung.
5. Skor performa akhir (Akurasi, F1-Score, dan Kappa) dihitung berdasarkan nilai rata-rata dari kelima iterasi tersebut.

## 3.5 Augmentasi Data

Augmentasi data merupakan teknik penting dalam pengolahan sinyal EEG, khususnya untuk tugas klasifikasi *motor imagery* (MI) yang menghadapi keterbatasan

jumlah data dan tingginya variabilitas antar subjek. Tujuannya adalah untuk memperkaya ragam data pelatihan sehingga model dapat belajar pola yang lebih *robust* dan mengurangi risiko overfitting (Wu et al., 2025). Penelitian terkini menunjukkan bahwa augmentasi yang efektif dapat meningkatkan akurasi model sebesar 1–2% (Rommel et al., 2022).

### **3.5.1 Time Shifting**

*Time shifting* dilakukan dengan menggeser sinyal EEG secara temporal sekitar  $\pm 0,2$  detik. Teknik ini sejalan dengan prinsip kausalitas yang diusung dalam *Temporal Convolutional Networks* (TCN), dimana output pada waktu  $t$  hanya bergantung pada input hingga waktu  $t$  dan sebelumnya (Ingolfsson et al., 2020). Pergeseran kecil ini menguji kemampuan model dalam menangkap pola temporal yang bergeser dan meningkatkan generalisasi.

### **3.5.2 Amplitude Scaling**

*Amplitude scaling* menskalakan amplitudo sinyal EEG secara proporsional dalam rentang 0,8 hingga 1,2 kali nilai aslinya. Teknik ini mendorong model untuk tahan terhadap variabilitas sinyal yang berasal dari penggunaan perangkat EEG *consumer-grade* yang cenderung memiliki fluktuasi sensitivitas dan noise yang lebih tinggi (Wu et al., 2025). Amplitude scaling juga membantu model mengenali pola independen terhadap intensitas sinyal yang bervariasi.

### **3.5.3 Additive Noise**

Tambahan noise Gaussian dengan *signal-to-noise ratio* (SNR) sekitar  $N$  dB diterapkan pada sinyal EEG untuk mensimulasikan gangguan riil seperti artifak otot atau lingkungan elektromagnetik (Rommel et al., 2022). Penambahan noise ini melatih model agar tahan terhadap kualitas sinyal yang buruk dan memperkuat performa di lingkungan dunia nyata yang penuh gangguan.

## **3.6 Model Development**

Pengembangan model dalam penelitian ini melibatkan tiga tahap model utama sebagai *baseline* dan model usulan, yaitu: EEGNet *standalone*, EEGNet yang dikombinasikan dengan *Temporal Convolutional Network* (EEG-TCNet asli), dan

model *hybrid* novel EEGNet-Efficient Channel Attention-TCN (EEGNet-ECA-TCNet). Pendekatan ini bertujuan menguji efektivitas dan efisiensi parameter sekaligus performa klasifikasi *motor imagery* berbasis EEG.

### 3.6.1 EEGNet

EEGNet (Lawhern et al., 2018) adalah arsitektur konvolusi efisien yang dirancang untuk sinyal EEG dengan jumlah parameter relatif kecil serta kemampuan komputasi yang rendah, sehingga ideal untuk perangkat *embedded*. Model ini memiliki tiga blok konvolusi utama:

- *Temporal Convolution*  
Layer konvolusi 1D dengan  $F_1 = 8$  filter, kernel ukuran 64 pada dimensi waktu untuk menangkap pola temporal awal.
- *Depthwise Spatial Convolution*  
Menggunakan *depthwise convolution* dengan multiplier *depthwise*  $D = 2$  untuk mengekstrak fitur spasial dari kanal EEG.
- *Separable Convolution*  
Untuk mengatasi kompleksitas dan *overfitting* dengan memisahkan konvolusi *channel* dan temporal

Konfigurasi meliputi *dropout* dengan nilai 0.25 untuk regularisasi serta *batch normalization* untuk stabilisasi *training*. Fungsi aktivasi yang digunakan adalah ELU (*Exponential Linear Unit*).

### 3.6.2 EEGNet-TCNet

Model EEG-TCNet mengadopsi integrasi EEGNet dengan *Temporal Convolutional Network* (TCN) untuk meningkatkan kemampuan ekstraksi fitur temporal yang lebih panjang dan kompleks (Ingolfsson et al., 2020). Struktur TCN memiliki fitur utama:

- *Residual Block*  
Dua buah blok residual dengan konvolusi dilasi untuk memperluas *receptive field*.

- *Dilated Convolution*

Kernel convolusi 1D berukuran 4 dengan dilasi yang meningkat secara eksponensial.

- *Receptive Field Size (RFS)*

Mencapai 17 langkah waktu yang memungkinkan model meng-*capture* pola temporal jangka panjang.

### 3.6.3 EEGNet-ECA-TCNet

Model usulan ini merupakan pengembangan dari EEG-TCNet yang mengintegrasikan mekanisme Efficient Channel Attention (ECA) untuk meningkatkan kemampuan model dalam memfokuskan fitur penting antar kanal EEG dengan beban komputasi minimal (Wu et al., 2025). Komponen model terstruktur sebagai berikut:

- EEGNet

Layer-by-layer mengikuti konfigurasi dasar EEGNet:

- Temporal convolution dengan  $F_1 = 8$ , kernel waktu 64.
- Depthwise convolution dengan multiplier depthwise  $D = 2$ .
- Separable convolution dilengkapi batch normalization, dropout 0.25, dan ELU aktivasi.

- ECA Module

- Mekanisme *attention* saluran yang efisien tanpa pengurangan dimensi convolusi.
- Ukuran kernel  $k = 3$ , yang dihitung dengan metode adaptif  $\text{kernel\_size} = \left\lceil \frac{\log_2 C}{\gamma} + b \right\rceil_{\text{odd}}$ , untuk  $C$  jumlah channel EEG (Wu et al., 2025).
- ECA membantu model memberikan bobot lebih kepada kanal yang lebih informatif tanpa meningkatkan parameter secara signifikan.

- TCNet

- Dua *residual blocks* dengan kernel size 4 dan dilasi eksponensial untuk *receptive field size* 17.
- Konvolusi temporal 1D yang meng-*capture* dependensi jangka panjang dalam data EEG.



- c. Struktur residual membantu mengatasi *gradient vanishing*.
- Classifier
  - a. *Global Average Pooling* (GAP) untuk mereduksi dimensi fitur.
  - b. *Fully Connected layer* (FC) linear.
  - c. *Softmax layer* sebagai layer output untuk klasifikasi binary.

#### 3.6.4 Parameter

Perkiraan kasar jumlah parameter model usulan dilakukan dengan menghitung kontribusi tiap lapisan penting sebagai berikut. Konvolusi temporal pada EEGNet modul memerlukan sekitar 2048 parameter ( $8 \text{ filter} \times \text{kernel } 64 \times 4 \text{ kanal input}$ ). *Depthwise convolution* dan *separable convolution* menambah beberapa ratus parameter secara keseluruhan. Modul ECA, dengan kernel 3, meningkatkan parameter hanya sebesar belasan hingga puluhan. Residual blocks TCN diperkirakan menambahkan sekitar 640 parameter. Fully connected layer berukuran 8 input ke 2 output menambahkan 18 parameter. Secara total, model ini dirancang memiliki sekitar 13.000 hingga 15.000 parameter yang jauh lebih ringan dibanding EEG-TCNet asli (37.000 parameter), sekaligus memberikan kapasitas ekstraksi fitur yang optimal untuk klasifikasi sinyal EEG pada perangkat *consumer-grade* dengan keterbatasan daya dan komputasi.

### 3.7 Training & Optimization

Pelatihan model merupakan tahap krusial dalam pengembangan sistem klasifikasi untuk memastikan model tidak hanya mampu belajar pola dari data pelatihan, tetapi juga mampu melakukan generalisasi dengan baik pada data baru. Bab ini memaparkan secara rinci strategi pelatihan dan optimasi yang akan diterapkan pada model EEGNet-ECA-TCN.

#### 3.7.1 Optimizer

Metode optimasi model menggunakan Adam *optimizer* dengan *learning rate* awal 0,001. Adam dipilih karena kemampuannya mengadaptasi *learning rate* untuk setiap parameter secara individual melalui kombinasi momentum historis dan variansi gradien, yang mempercepat konvergensi dan menstabilkan proses pelatihan jaringan

neural dalam domain EEG (Ingolfsson et al., 2020). *Learning rate* ini dapat disesuaikan secara dinamis dengan mekanisme penurunan selama pelatihan agar model tidak terjebak dalam minimum lokal.

### 3.7.2 Loss Function

Fungsi loss yang digunakan adalah *categorical cross-entropy*, yang cocok untuk mengukur jarak antara distribusi prediksi model dan distribusi label asli dalam kasus klasifikasi, baik biner maupun multi-kelas. *Cross-entropy* memberikan sinyal gradien yang jelas dan mendalam untuk memaksimalkan probabilitas output yang benar, sehingga sangat efektif untuk tugas klasifikasi motor imagery menggunakan EEG (Lawhern et al., 2018; Wu et al., 2025).

### 3.7.3 Callbacks

Untuk meningkatkan efisiensi pelatihan dan kualitas model, dua mekanisme callback diterapkan:

- *Early Stopping*

Mekanisme ini memantau metrik loss pada data validasi internal (yang diambil dari pecahan data latih pada setiap iterasi cross-validation). Proses pelatihan akan dihentikan secara otomatis jika validation loss tidak menunjukkan penurunan atau perbaikan selama 20 epoch berturut-turut (*patience* = 20). Hal ini bertujuan untuk mencegah model menghafal data (*overfitting*) dan memastikan efisiensi waktu komputasi (Wu et al., 2025).

- *Reduce Learning Rate*

Jika performa validasi datar atau memburuk selama 5 *epoch*, *learning rate* akan dikurangi secara otomatis, memungkinkan training untuk mencapai minimum yang lebih dalam dengan langkah pelatihan yang lebih kecil (Ingolfsson et al., 2020).

### 3.7.4 Hyperparameter Tuning

Pelatihan model dilakukan dengan eksplorasi parameter optimal melalui *grid search* terhadap kombinasi fungsi *learning rate* (0.001, 0.0005, 0.0001), *dropout rate* (0.2, 0.3, 0.4), dan *batch size* (32, 64, 128). Pendekatan ini memungkinkan seleksi

konfigurasi terbaik berdasarkan validasi sehingga model mendapat generalisasi terbaik (Wu et al., 2025).

### 3.7.5 Regularization

*Dropout* diaplikasikan secara strategis pada *layer convolutional* dan *fully connected* untuk mengurangi *overfitting*. Nilai *dropout* berkisar antara 0.2 sampai 0.4, menonaktifkan neuron secara acak selama *training* agar model tidak terlalu tergantung pada fitur tertentu dan mampu belajar representasi yang lebih umum (Lawhern et al., 2018). Hal ini sangat penting mengingat data EEG memang rentan noise dan variabilitas antar subjek.

## 3.8 Evaluasi dan Analisis

Evaluasi dan analisis hasil eksperimen merupakan tahap penting untuk mengukur performa model, validitas hasil, dan potensi penerapan nyata dalam sistem *Brain-Computer Interface*. Beberapa aspek evaluasi yang akan dilakukan meliputi metrik performa klasifikasi, studi ablasi, analisis pengembangan, pengujian statistik, dan visualisasi hasil.

### 3.8.1 Metrik Performa

Model akan diukur menggunakan metrik akurasi sebagai ukuran utama, yaitu proporsi prediksi benar dibanding total prediksi:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

Selain itu, digunakan juga *Cohen's Kappa* untuk menilai kesepakatan antara prediksi dan label yang memperhitungkan prediksi kebetulan:

$$\kappa = \frac{P_o - P_e}{1 - P_e}$$

dengan  $P_o$  adalah proporsi observasi yang cocok dan  $P_e$  proporsi yang diharapkan benar secara kebetulan.

Metrik F1-Score yang merupakan harmonisasi precision dan recall juga dihitung:

$$\text{F1-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Akurasi Under the Curve (AUC) dari Receiver Operating Characteristics (ROC) digunakan sebagai indikator kemampuan diskriminasi model terhadap dua kelas (Ingolfsson et al., 2020; Wu et al., 2025).

### 3.8.2 Studi Ablasi

Studi Ablasi dilakukan secara sistematis untuk menguji kontribusi masing-masing komponen model. Perbandingan dibuat antara:

- EEGNet *standalone*,
- EEGNet + TCN,
- *Proposed* model EEGNet + ECA + TCN.

Dengan menghilangkan atau menambahkan modul, pengaruhnya terhadap akurasi dan metrik lain akan dianalisis. Hal penting untuk menjustifikasi manfaat modul *Efficient Channel Attention* dan TCNet dalam *pipeline* klasifikasi *motor imagery* (Wu et al., 2025).

### 3.8.3 Analisis Deployment

Analisis *deployment* dilakukan dengan mengukur waktu inferensi model, penggunaan memori, dan jumlah parameter di lingkungan perangkat nyata atau simulasi. Target utama adalah waktu kurang dari 200 ms dan ukuran memori dibawah 1 MB untuk mendukung pemrosesan *real-time* pada perangkat *consumer-grade low-resource* (Ingolfsson et al., 2020).

### 3.8.4 Pengujian Statistik

Pengujian statistik dilakukan untuk memastikan signifikan tidaknya perbedaan performa dengan *baseline*.

- *Paired t-test*

*Paired t-test* akan digunakan untuk menguji perbedaan akurasi antar model pada subjek yang sama, dengan hipotesis nol bahwa perbedaan rata-rata adalah nol.

- *Wilcoxon signed-rank test*

*Wilcoxon signed-rank test* sebagai alternatif non-parametrik yang tidak mengasumsikan distribusi normal pada data.

Interpretasi  $p\text{-value} < 0.05$  dianggap signifikan, sehingga model *proposed* dikatakan secara statistik lebih unggul (Wu et al., 2025)

### **3.8.5 Visualisasi**

Visualisasi berupa confusion matrix akan membantu melihat distribusi prediksi benar dan salah per kelas. ROC curve menampilkan *trade-off* sensitivitas dan spesifisitas model. Selain itu, heatmaps dari *attention mechanism* (ECA) akan divisualisasi untuk menginterpretasikan fokus kanal EEG yang paling berkontribusi pada prediksi model (Wu et al., 2025)

## DAFTAR PUSTAKA

- Agastya, A., Marco, R., & Puspitasari, N. F. (2024). *Implementasi Deep Learning untuk Klasifikasi Motor Imagery pada Sinyal EEG* (Vol. 7, Issue 1).
- Al-Saegh, A., Dawwd, S. A., & Abdul-Jabbar, J. M. (2021). Deep learning for motor imagery EEG-based classification: A review. In *Biomedical Signal Processing and Control* (Vol. 63). Elsevier Ltd. <https://doi.org/10.1016/j.bspc.2020.102172>
- Altaheri, H., Karray, F., & Karimi, A. H. (2025). Temporal convolutional transformer for EEG based motor imagery decoding. *Scientific Reports*, 15(1). <https://doi.org/10.1038/s41598-025-16219-7>
- Chen, Y., Wang, F., Li, T., Zhao, L., Gong, A., Nan, W., Ding, P., & Fu, Y. (2024). Considerations and discussions on the clear definition and definite scope of brain-computer interfaces. *Frontiers in Neuroscience*, 18. <https://doi.org/10.3389/fnins.2024.1449208>
- Garcia-Moreno, F. M., Bermudez-Edo, M., Garrido, J. L., & Rodríguez-Fórtiz, M. J. (2020). Reducing Response Time in Motor Imagery Using A Headband and Deep Learning. *Sensors*, 20(23), 6730. <https://doi.org/10.3390/s20236730>
- Gu, H., Chen, T., Ma, X., Zhang, M., Sun, Y., & Zhao, J. (2025). CLTNet: A Hybrid Deep Learning Model for Motor Imagery Classification. *Brain Sciences*, 15(2). <https://doi.org/10.3390/brainsci15020124>
- Ingolfsson, T. M., Hersche, M., Wang, X., Kobayashi, N., Cavigelli, L., & Benini, L. (2020). EEG-TCNet: An Accurate Temporal Convolutional Network for Embedded Motor-Imagery Brain–Machine Interfaces. *2020 IEEE International Conference on Systems, Man, and Cybernetics (SMC)*, 2958–2965. <https://doi.org/10.1109/SMC42975.2020.9283028>
- Lawhern, V. J., Solon, A. J., Waytowich, N. R., Gordon, S. M., Hung, C. P., & Lance, B. J. (2018). EEGNet: a compact convolutional neural network for EEG-based brain–computer interfaces. *Journal of Neural Engineering*, 15(5), 056013. <https://doi.org/10.1088/1741-2552/aace8c>

- Lee, S., Kim, M., & Ahn, M. (2024). Evaluation of consumer-grade wireless EEG systems for brain-computer interface applications. *Biomedical Engineering Letters*, 14(6), 1433–1443. <https://doi.org/10.1007/s13534-024-00416-w>
- Liao, W., Miao, Z., Liang, S., Zhang, L., & Li, C. (2025). A composite improved attention convolutional network for motor imagery EEG classification. *Frontiers in Neuroscience*, 19. <https://doi.org/10.3389/fnins.2025.1543508>
- Ma, Y., Song, Y., & Gao, F. (2022). A novel hybrid CNN-Transformer model for EEG Motor Imagery classification. *Proceedings of the International Joint Conference on Neural Networks*, 2022-July. <https://doi.org/10.1109/IJCNN55064.2022.9892821>
- Malan, N. S., & Sharma, S. (2022). Motor Imagery EEG Spectral-Spatial Feature Optimization Using Dual-Tree Complex Wavelet and Neighbourhood Component Analysis. *IRBM*, 43(3), 198–209. <https://doi.org/10.1016/j.irbm.2021.01.002>
- muse. (n.d.). *Muse S plus Muse 2 | Muse® EEG Mental Fitness & Sleep Headband*. Retrieved November 6, 2025, from <https://choosemuse.com/pages/shop?srsId=AfmBOopRnz4unkBZBoRXS5zWBdE6x-ZvAUQlXeaKr9nR0EDwhAvIBKZs>
- Mustile, M., Kourtis, D., Edwards, M. G., Donaldson, D. I., & Ietswaart, M. (2024). Neural correlates of motor imagery and execution in real-world dynamic behavior: evidence for similarities and differences. *Frontiers in Human Neuroscience*, 18. <https://doi.org/10.3389/fnhum.2024.1412307>
- Rakhmatulin, I., Dao, M. S., Nassibi, A., & Mandic, D. (2024). Exploring Convolutional Neural Network Architectures for EEG Feature Extraction. *Sensors*, 24(3). <https://doi.org/10.3390/s24030877>
- Rommel, C., Paillard, J., Moreau, T., & Gramfort, A. (2022). Data augmentation for learning predictive models on EEG: a systematic comparison. *Journal of Neural Engineering*, 19(6), 066020. <https://doi.org/10.1088/1741-2552/aca220>

- Sabio, J., Williams, N. S., McArthur, G. M., & Badcock, N. A. (2024). A scoping review on the use of consumer-grade EEG devices for research. *PLOS ONE*, *19*(3), e0291186. <https://doi.org/10.1371/journal.pone.0291186>
- Sun, Y., Chen, X., Liu, B., Liang, L., Wang, Y., Gao, S., & Gao, X. (2025). Signal acquisition of brain–computer interfaces: A medical-engineering crossover perspective review. *Fundamental Research*, *5*(1), 3–16. <https://doi.org/10.1016/j.fmre.2024.04.011>
- Wang, Q., Wu, B., Zhu, P., Li, P., Zuo, W., & Hu, Q. (2020). ECA-Net: Efficient Channel Attention for Deep Convolutional Neural Networks. *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 11531–11539. <https://doi.org/10.1109/CVPR42600.2020.01155>
- Wang, X., Dai, X., Liu, Y., Chen, X., Hu, Q., Hu, R., & Li, M. (2023). Motor imagery electroencephalogram classification algorithm based on joint features in the spatial and frequency domains and instance transfer. *Frontiers in Human Neuroscience*, *17*. <https://doi.org/10.3389/fnhum.2023.1175399>
- Wu, X., Chu, Y., Li, Q., Luo, Y., Zhao, Y., & Zhao, X. (2025). AMEEGNet: attention-based multiscale EEGNet for effective motor imagery EEG decoding. *Frontiers in Neurorobotics*, *19*. <https://doi.org/10.3389/fnbot.2025.1540033>
- Zhang, H., Ji, H., Yu, J., Li, J., Jin, L., Liu, L., Bai, Z., & Ye, C. (2023). Subject-independent EEG classification based on a hybrid neural network. *Frontiers in Neuroscience*, *17*. <https://doi.org/10.3389/fnins.2023.1124089>
- Zhang, H., Jiao, L., Yang, S., Li, H., Jiang, X., Feng, J., Zou, S., Xu, Q., Gu, J., Wang, X., & Wei, B. (2024). Brain-computer interfaces: the innovative key to unlocking neurological conditions. In *International journal of surgery (London, England)* (Vol. 110, Issue 9, pp. 5745–5762). <https://doi.org/10.1097/JS9.0000000000002022>



- Zhang, J., Li, K., Yang, B., & Han, X. (2023). Local and global convolutional transformer-based motor imagery EEG classification. *Frontiers in Neuroscience*, 17. <https://doi.org/10.3389/fnins.2023.1219988>
- Zhao, W., Jiang, X., Zhang, B., Xiao, S., & Weng, S. (2024). CTNet: a convolutional transformer network for EEG-based motor imagery classification. *Scientific Reports*, 14(1). <https://doi.org/10.1038/s41598-024-71118-7>
- Zhao, W., Zhang, B., Zhou, H., Wei, D., Huang, C., & Lan, Q. (2025). Multi-scale convolutional transformer network for motor imagery brain-computer interface. *Scientific Reports*, 15(1). <https://doi.org/10.1038/s41598-025-96611-5>